Московский государственный технический университет им. Н.Э. Баумана
Факультет «Информатика и системы управления»
Кафедра «Системы обработки информации и управления»

Лабораторная работа №6
по дисциплине «Методы машинного обучения»
«Обучение на основе глубоких Q-сетей»

ИСПОЛНИТЕЛЬ:

Алехин С.С.
Группа ИУ5-23М

_____

ПРОВЕРИЛ:

Балашов А.М.

_____

Москва, 2023

Задание

- На основе рассмотренных на лекции примеров реализуйте алгоритм DQN.
- В качестве среды можно использовать классические среды (в этом случае используется полносвязная архитектура нейронной сети).
- В качестве среды можно использовать игры Atari (в этом случае используется сверточная архитектура нейронной сети).
- В случае реализации среды на основе сверточной архитектуры нейронной сети +1 балл за экзамен.

Lab6

June 22, 2023

[ ]:
```
import gymnasium as gym
import math
import random
import matplotlib.pyplot as plt
from collections import namedtuple, deque
import torch
import torch.nn as nn
import torch.optim as optim
import torch.nn.functional as F
```

[ ]:
```
#
CONST_ENV_NAME = 'Acrobot-v1'

#         GPU
CONST_DEVICE = torch.device('cuda' if torch.cuda.is_available() else 'cpu')

#      ReplayMemory
Transition = namedtuple('Transition', ('state', 'action', 'next_state',␣
 ↪'reward'))
```

0.0.1 Relay Memory

[ ]:
```
#            Replay Memory
class ReplayMemory(object):
  def __init__(self, capacity):
    self.memory = deque([], maxlen=capacity)

  def push(self, *args):
    '''
                ReplayMemory
    '''

    self.memory.append(Transition(*args))

  def sample(self, batch_size):
    '''
                          batch_size
    '''
```

```
    return random.sample(self.memory, batch_size)

  def __len__(self):
    return len(self.memory)
```

0.0.2 DQN Model

[ ]:
```
class DQN_Model(nn.Module):
  def __init__(self, n_observations, n_actions):
    '''

    '''

    super(DQN_Model, self).__init__()
    self.layer1 = nn.Linear(n_observations, 128)
    self.layer2 = nn.Linear(128, 64)
    self.layer3 = nn.Linear(64, n_actions)

  def forward(self, x):
    '''


                    ,
        batch
    '''

    x = F.relu(self.layer1(x))
    x = F.relu(self.layer2(x))
    return self.layer3(x)
```

0.0.3 DQN Agent

[ ]:
```
class DQN_Agent:
  def __init__(
    self,
    env,
    BATCH_SIZE = 128,
    GAMMA = 0.99,
    EPS_START = 0.1,
    EPS_END = 0.5,
    EPS_DECAY = 1000,
    TAU = 0.005,
    LR = 0.0001,
  ):
    #
    self.env = env
    #        Q-
```

```
    self.n_actions = env.action_space.n
    state, _ = self.env.reset()
    self.n_observations = len(state)
    #
    self.BATCH_SIZE = BATCH_SIZE
    self.GAMMA = GAMMA
    self.EPS_START = EPS_START
    self.EPS_END = EPS_END
    self.EPS_DECAY = EPS_DECAY
    self.TAU = TAU
    self.LR = LR

    #
    #
    self.policy_net = DQN_Model(self.n_observations, self.n_actions).
↪to(CONST_DEVICE)

    #              ,
    #                          TAU
    #             Double DQN
    self.target_net = DQN_Model(self.n_observations, self.n_actions).
↪to(CONST_DEVICE)
    self.target_net.load_state_dict(self.policy_net.state_dict())

    #
    self.optimizer = optim.AdamW(self.policy_net.parameters(), lr=self.LR,␣
↪amsgrad=True)

    # Replay Memory
    self.memory = ReplayMemory(10000)

    #
    self.steps_done = 0

    #
    self.episode_durations = []

 def select_action(self, state):
    '''

    '''

    sample = random.random()
    eps = self.EPS_END + (self.EPS_START - self.EPS_END) * math.exp(-1. * self.
↪steps_done / self.EPS_DECAY)
    self.steps_done += 1
    if sample > eps:
```

```
      with torch.no_grad():
        #                eps
        #               ,                  Q-
        # t.max(1)
        # [1]
        return self.policy_net(state).max(1)[1].view(1, 1)
    else:
      #               eps
      #
      return torch.tensor([[self.env.action_space.sample()]],␣
↪device=CONST_DEVICE, dtype=torch.long)

  def plot_durations(self, show_result=False):
    plt.figure(1)
    durations_t = torch.tensor(self.episode_durations, dtype=torch.float)
    if show_result:
      plt.title('     ')
    else:
      plt.clf()
      plt.title('     ')
      plt.xlabel('    ')
      plt.ylabel('                ')
      plt.plot(durations_t.numpy())
      plt.pause(0.001) #

  def optimize_model(self):
    '''

    '''

    if len(self.memory) < self.BATCH_SIZE:
      return

    transitions = self.memory.sample(self.BATCH_SIZE)
    #           batch'
    #        batch-       Transition
    #   Transition batch-     .
    batch = Transition(*zip(*transitions))

    #                                        batch'
    non_final_mask = torch.tensor(tuple(map(lambda s: s is not None, batch.
↪next_state)), device=CONST_DEVICE, dtype=torch.bool)
    non_final_next_states = torch.cat([s for s in batch.next_state if s is not␣
↪None])
    state_batch = torch.cat(batch.state)
    action_batch = torch.cat(batch.action)
    reward_batch = torch.cat(batch.reward)
```

```
    #       Q(s_t, a)
    state_action_values = self.policy_net(state_batch).gather(1, action_batch)

    #       V(s_{t+1})
    next_state_values = torch.zeros(self.BATCH_SIZE, device=CONST_DEVICE)

    with torch.no_grad():
      next_state_values[non_final_mask] = self.
↪target_net(non_final_next_states).max(1)[0]

    #                   Q
    expected_state_action_values = (next_state_values * self.GAMMA) +␣
↪reward_batch

    #       Huber loss
    criterion = nn.SmoothL1Loss()
    loss = criterion(state_action_values, expected_state_action_values.
↪unsqueeze(1))

    #
    self.optimizer.zero_grad()
    loss.backward()

    # gradient clipping
    torch.nn.utils.clip_grad_value_(self.policy_net.parameters(), 100)
    self.optimizer.step()

  def play_agent(self):
    '''

    '''

    env2 = gym.make(CONST_ENV_NAME, render_mode='human')
    state = env2.reset()[0]
    state = torch.tensor(state, dtype=torch.float32, device=CONST_DEVICE).
↪unsqueeze(0)
    res = []

    terminated = False
    truncated = False

    while not terminated and not truncated:
      action = self.select_action(state)
      action = action.item()
      observation, reward, terminated, truncated, _ = env2.step(action)
      env2.render()
```

```
    res.append((action, reward))

    state = torch.tensor(observation, dtype=torch.float32,␣
↪device=CONST_DEVICE).unsqueeze(0)

  print('done!')
  print('          : ', res)

def train(self):
  '''

  '''

  if torch.cuda.is_available():
    num_episodes = 600
  else:
    num_episodes = 50

  for i_episode in range(num_episodes):
    #
    state, info = self.env.reset()
    state = torch.tensor(state, dtype=torch.float32, device=CONST_DEVICE).
↪unsqueeze(0)

    terminated = False
    truncated = False

    iters = 0
    while not terminated and not truncated:
      action = self.select_action(state)
      observation, reward, terminated, truncated, _ = self.env.step(action.
↪item())
      reward = torch.tensor([reward], device=CONST_DEVICE)

      if terminated:
        next_state = None
      else:
        next_state = torch.tensor(observation, dtype=torch.float32,␣
↪device=CONST_DEVICE).unsqueeze(0)

      #             Replay Memory
      self.memory.push(state, action, next_state, reward)

      #
      state = next_state

      #
```

```
        self.optimize_model()

        #           target-
        #   ←    + (1 -   )
        target_net_state_dict = self.target_net.state_dict()
        policy_net_state_dict = self.policy_net.state_dict()

        for key in policy_net_state_dict:
          target_net_state_dict[key] = policy_net_state_dict[key] * self.TAU +␣
↪target_net_state_dict[key] * (1 - self.TAU)

        self.target_net.load_state_dict(target_net_state_dict)
        iters += 1

      self.episode_durations.append(iters)
      self.plot_durations()
```

[ ]:
```
env = gym.make(CONST_ENV_NAME)
agent = DQN_Agent(env)
agent.train()
agent.play_agent()
```

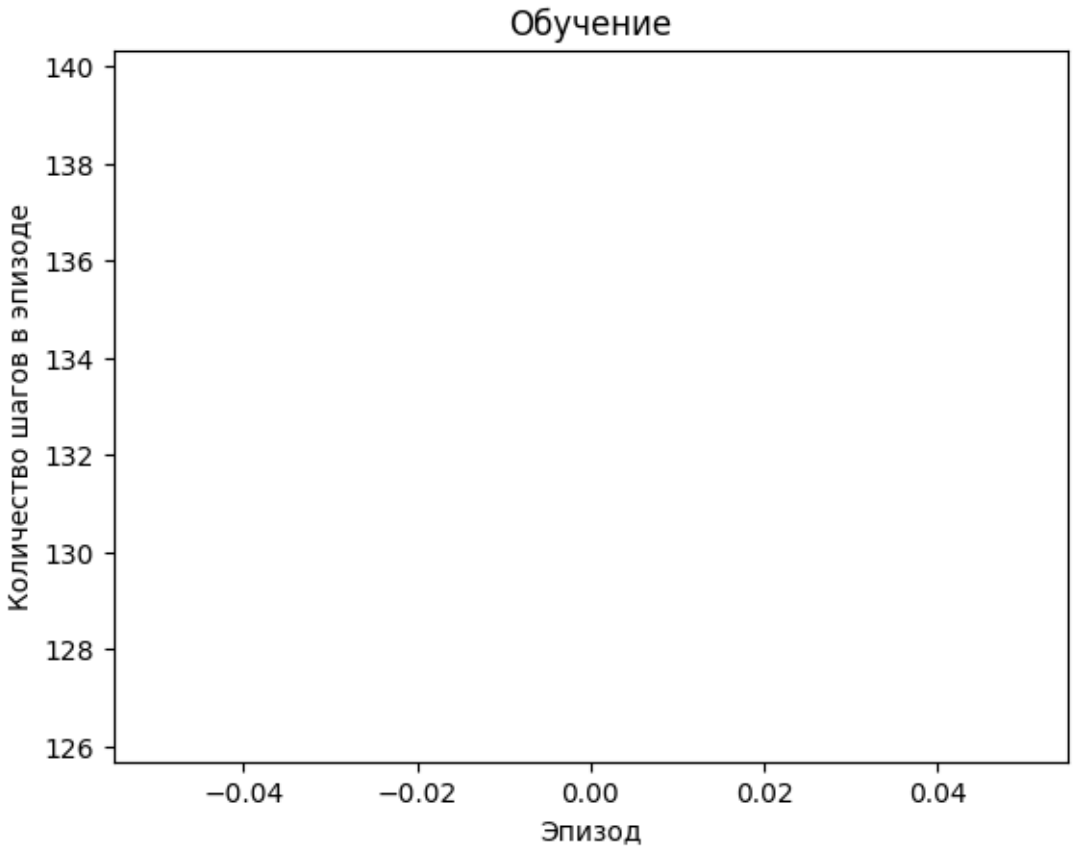

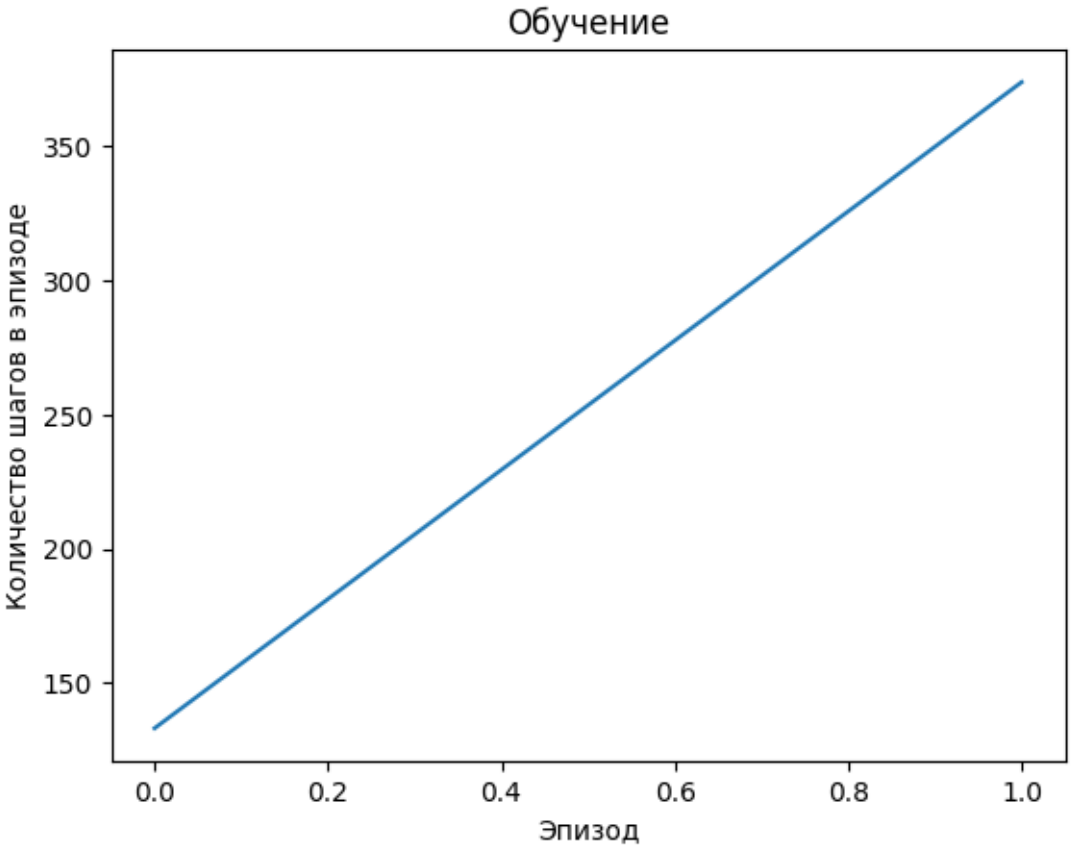
Обучение
Количество шагов в эпизоде
350
300
250
200
150
0.0
0.2
0.4
0.6
0.8
1.0
Эпизод

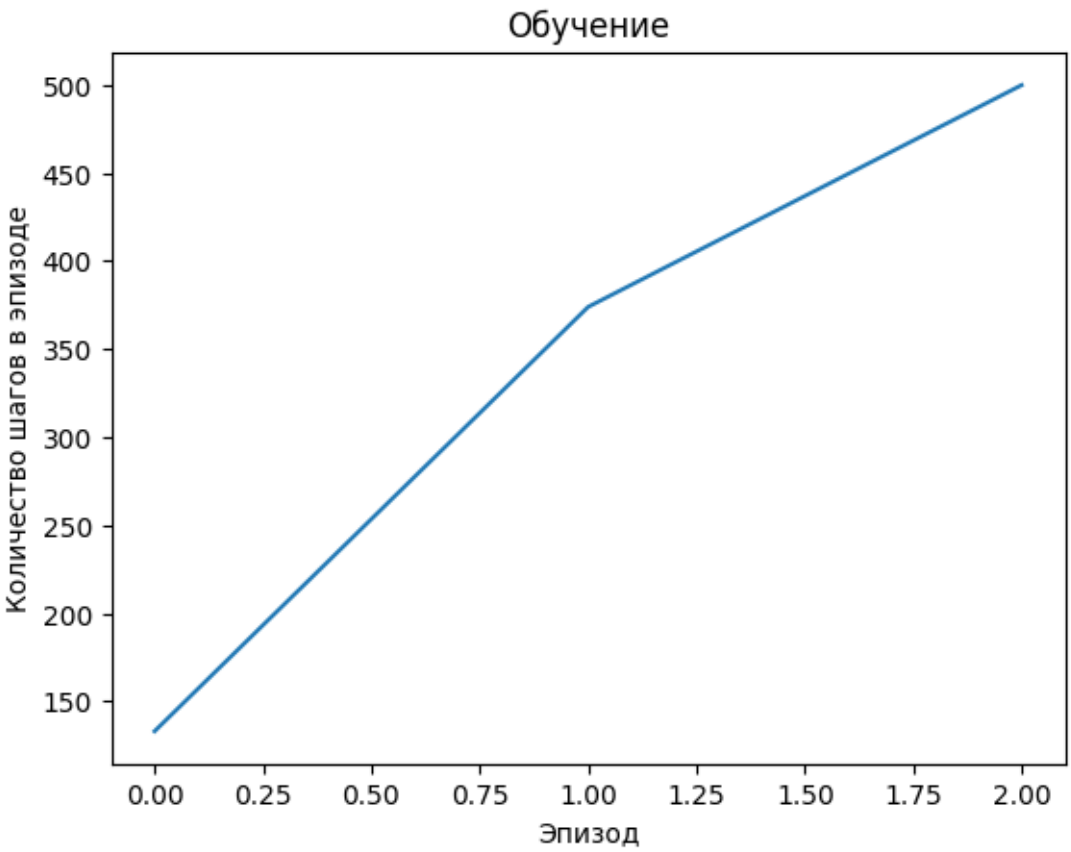
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0.00
0.25
0.50
0.75
1.00
1.25
1.50
1.75
2.00
Эпизод

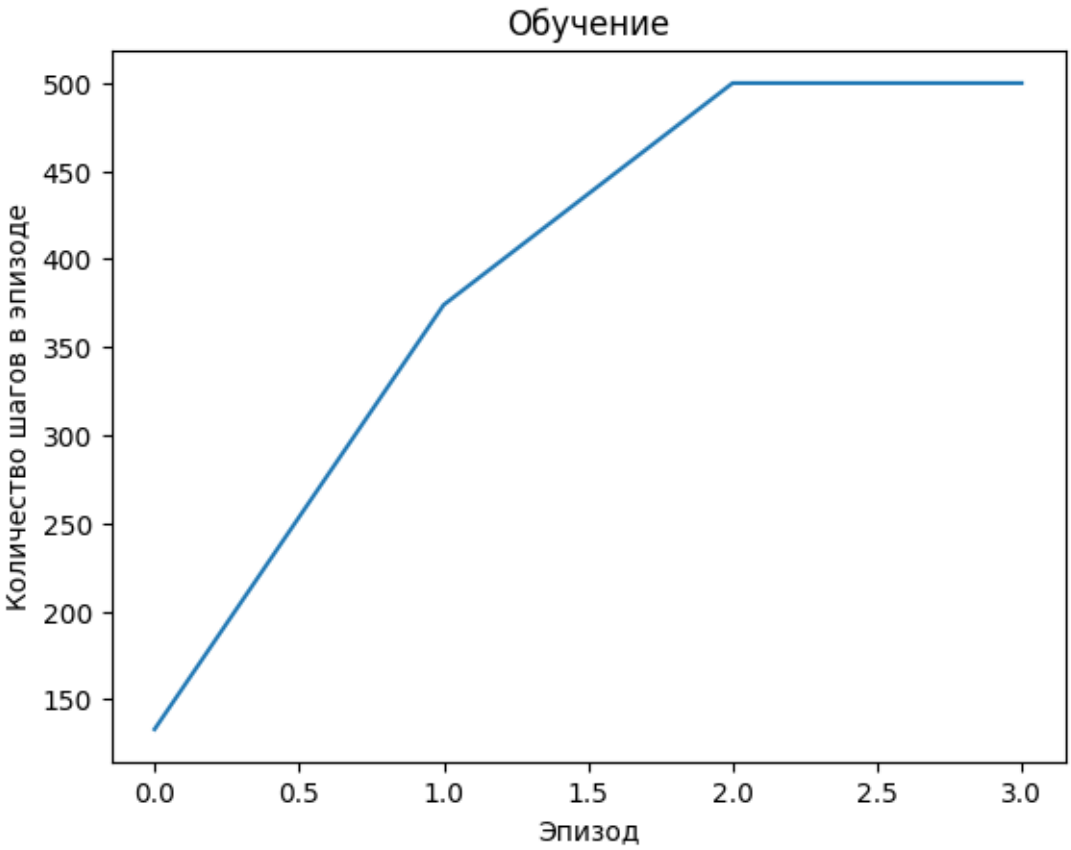
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0.0
0.5
1.0
1.5
2.0
2.5
3.0
Эпизод

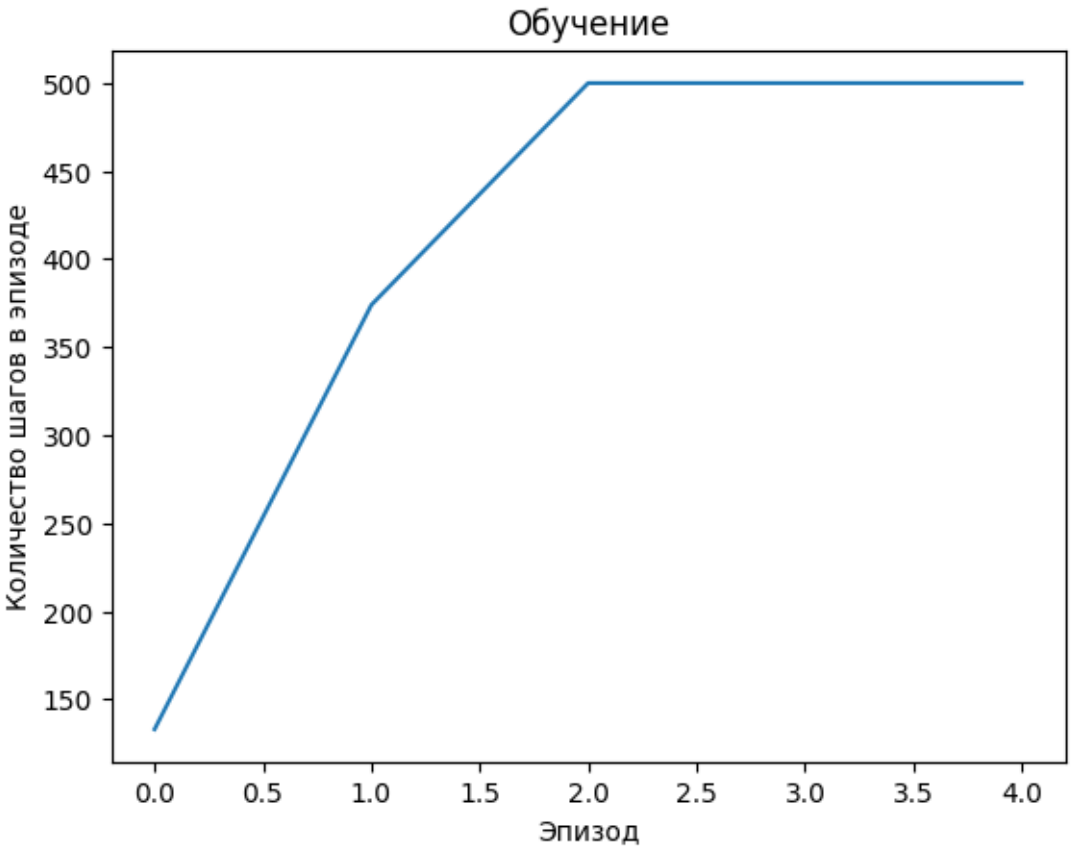
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0.0
0.5
1.0
1.5
2.0
2.5
3.0
3.5
4.0
Эпизод

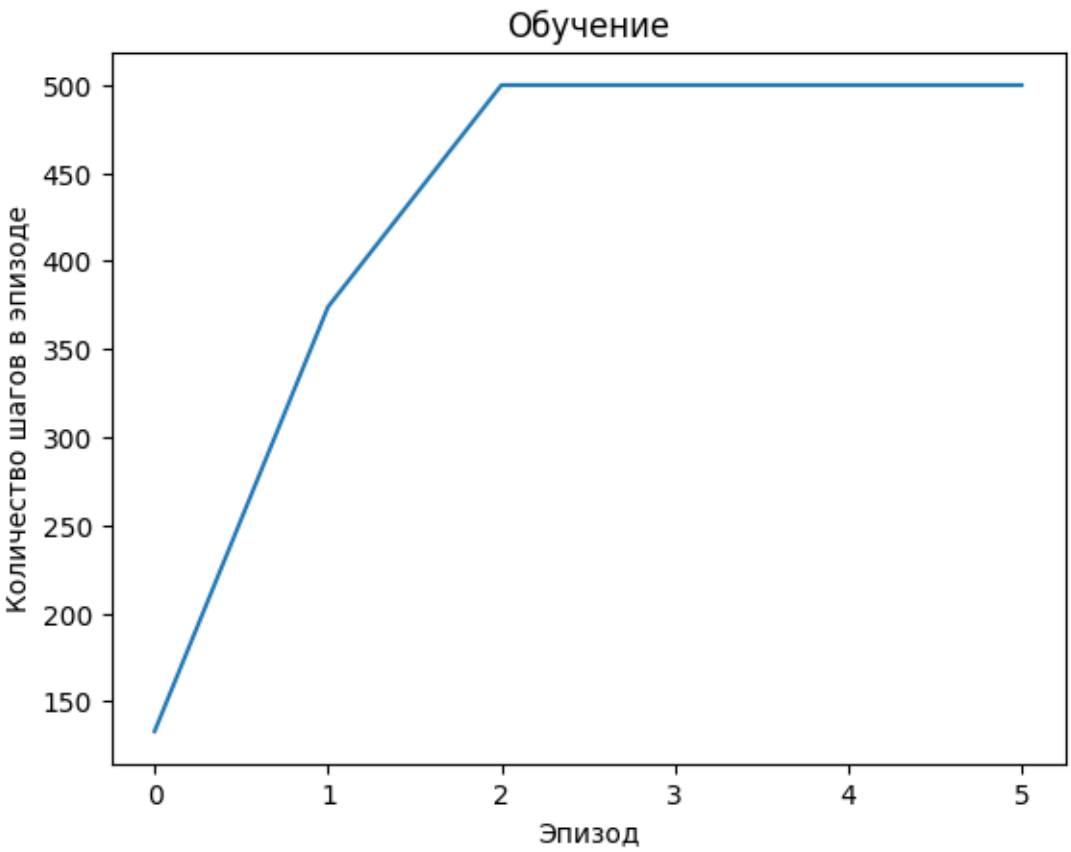
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0
1
2
3
4
5
Эпизод

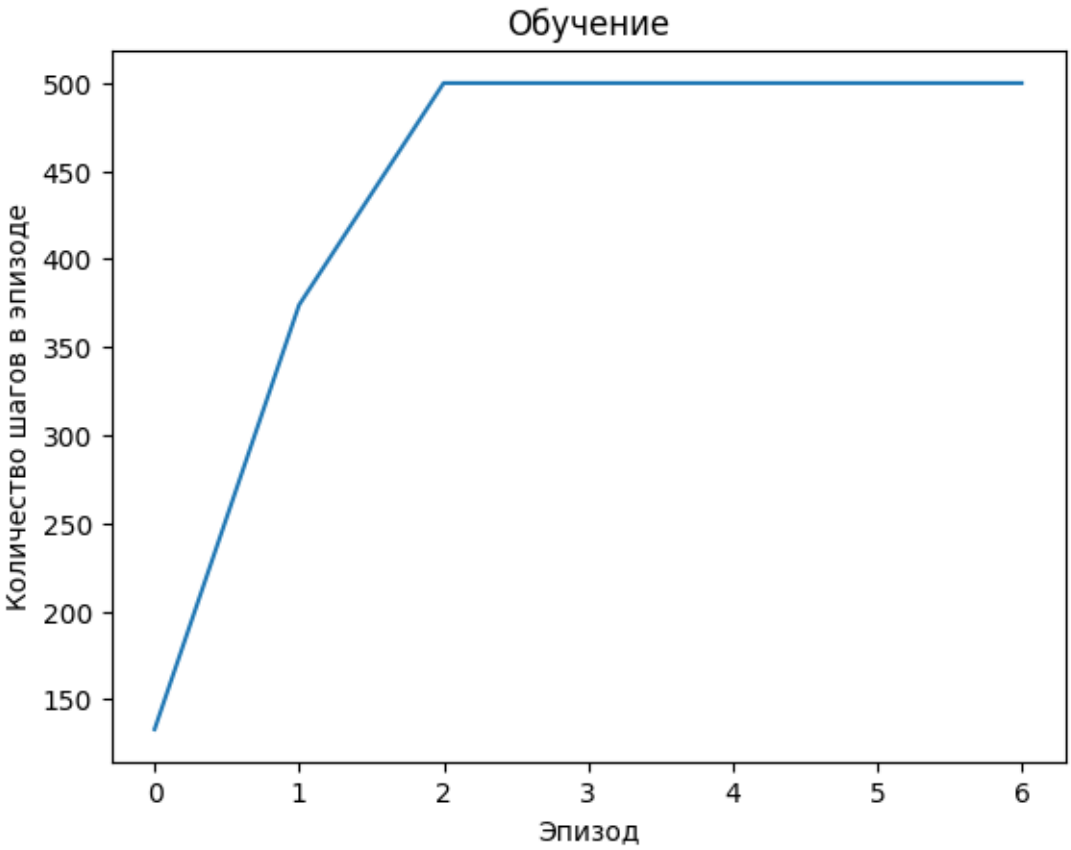
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0
1
2
3
4
5
6
Эпизод

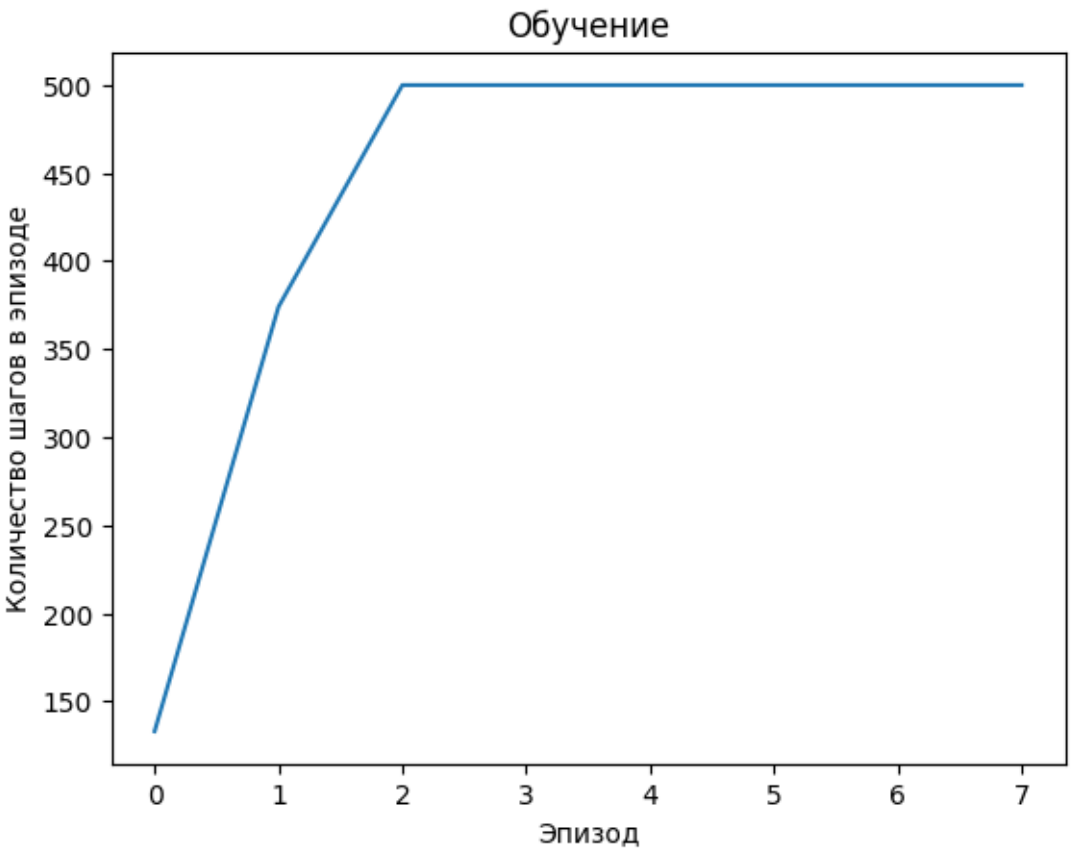
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0
1
2
3
4
5
6
7
Эпизод

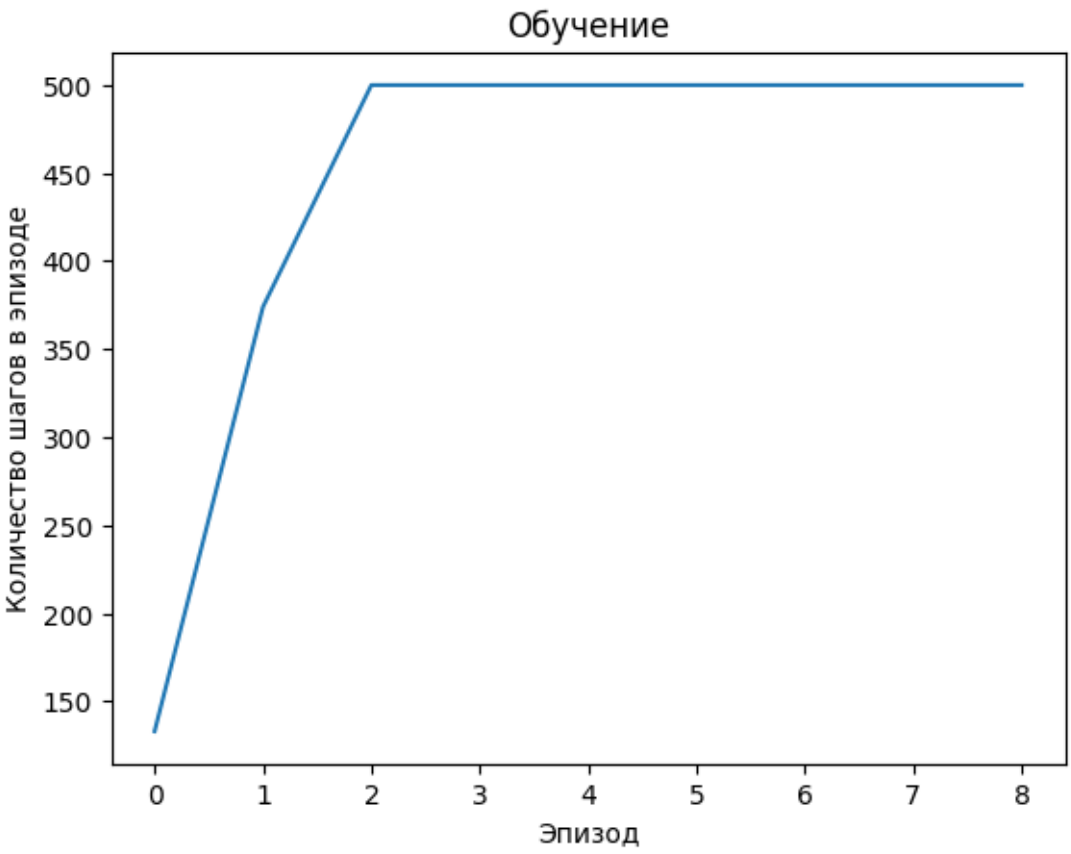
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0
1
2
3
4
5
6
7
8
Эпизод

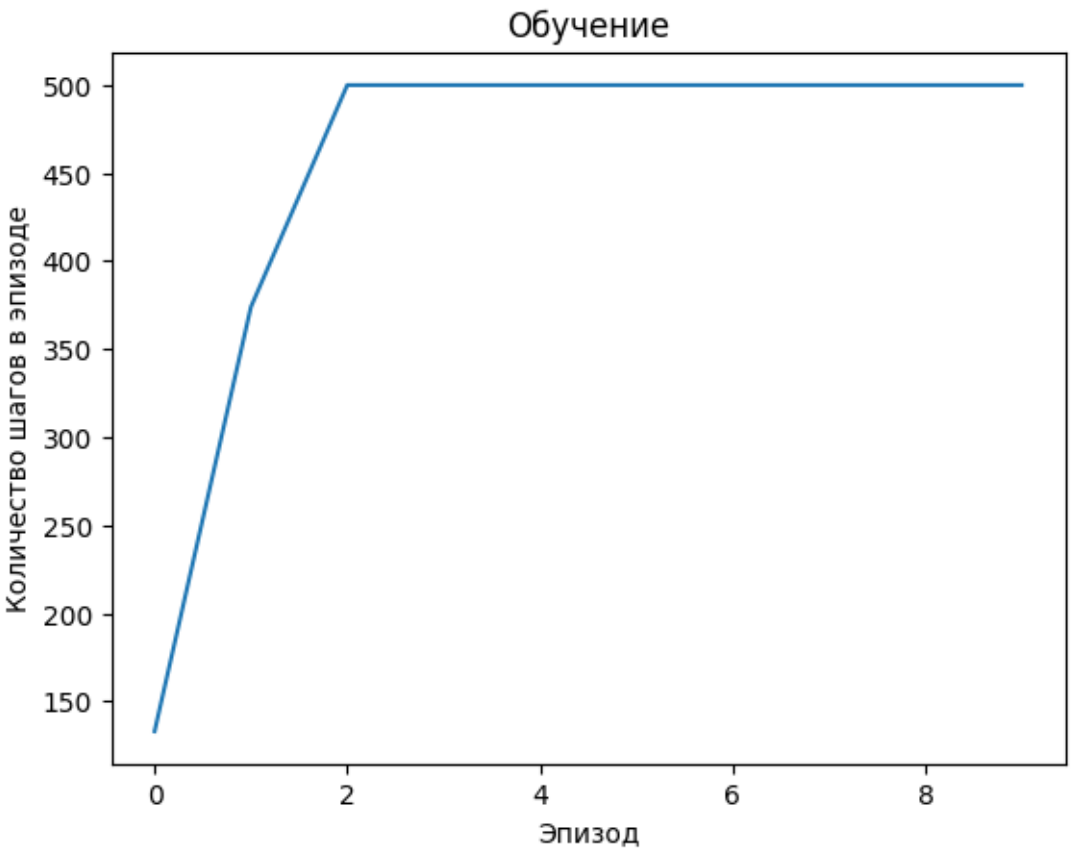
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0
2
4
6
8
Эпизод

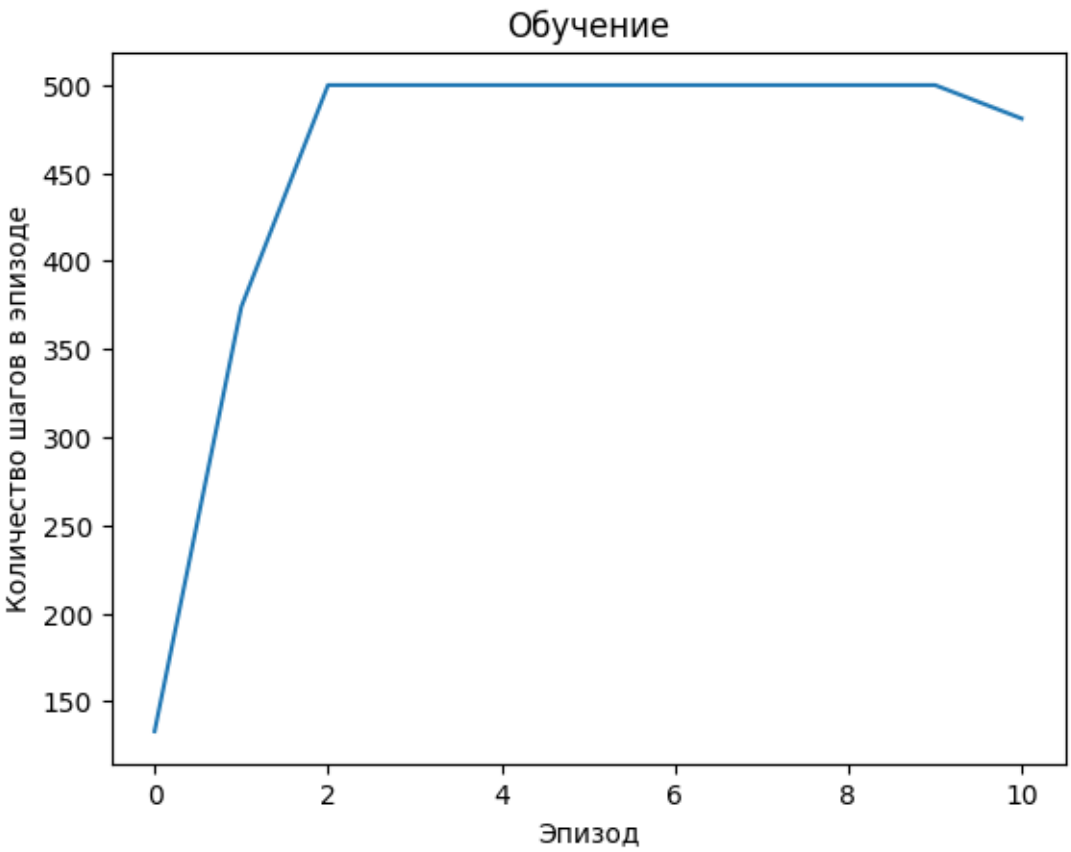
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0
2
4
6
8
10
Эпизод

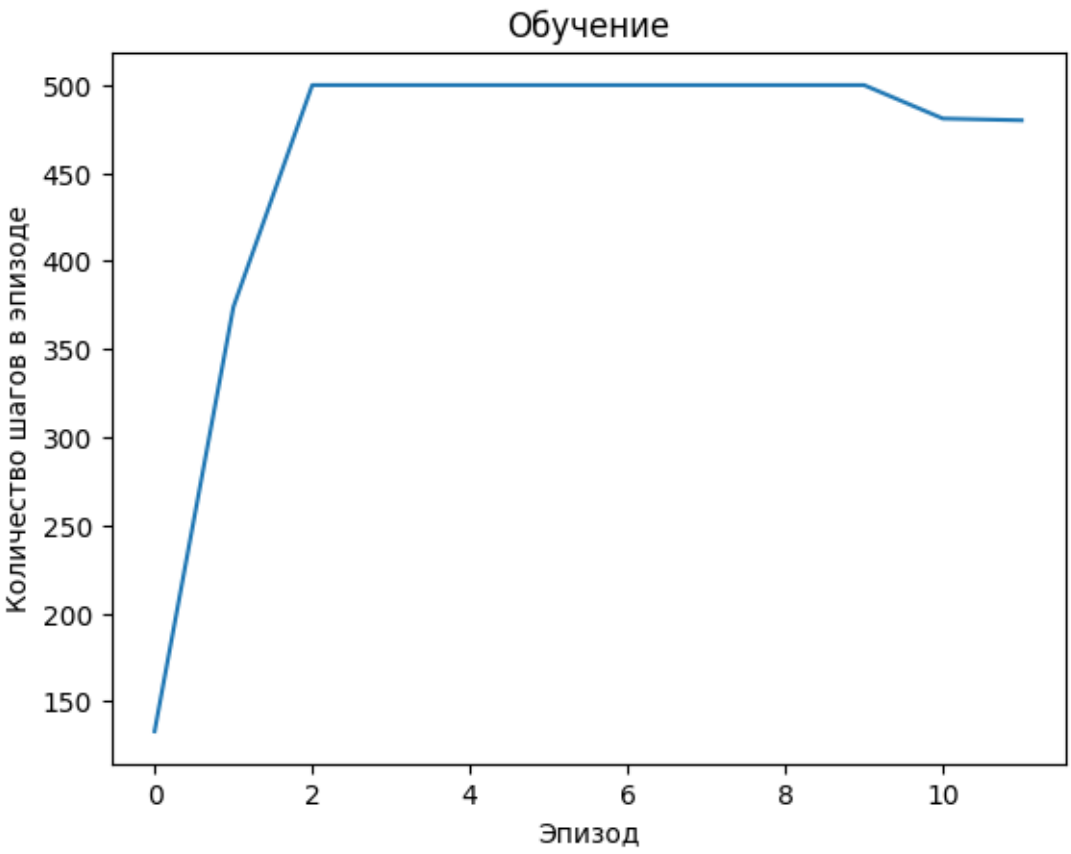
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0
2
4
6
8
10
Эпизод

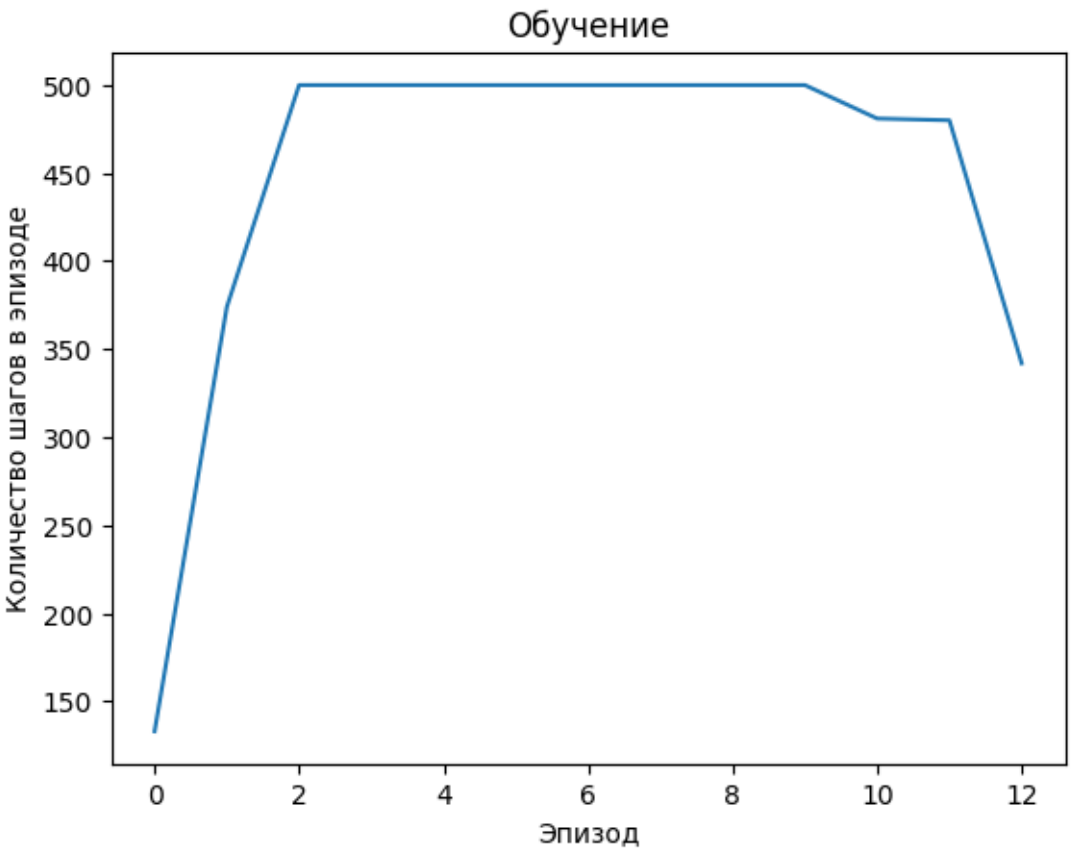
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0
2
4
6
8
10
12
Эпизод

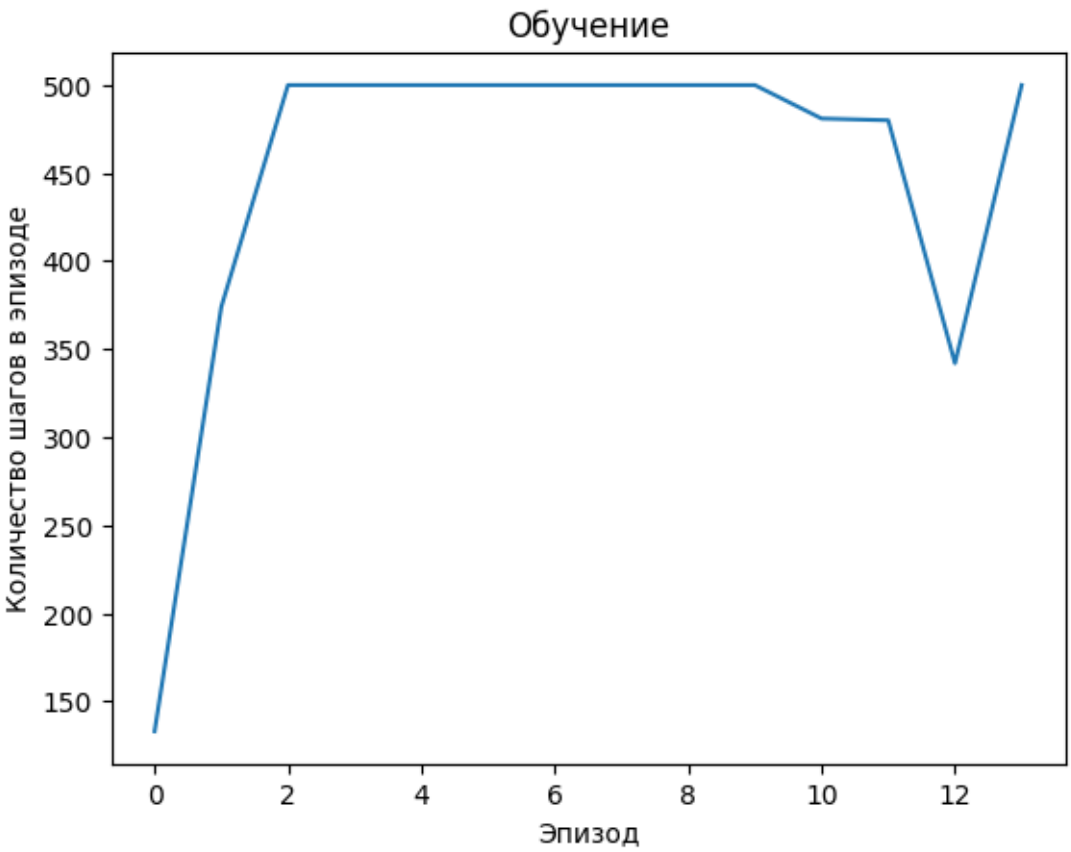
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0
2
4
6
8
10
12
Эпизод

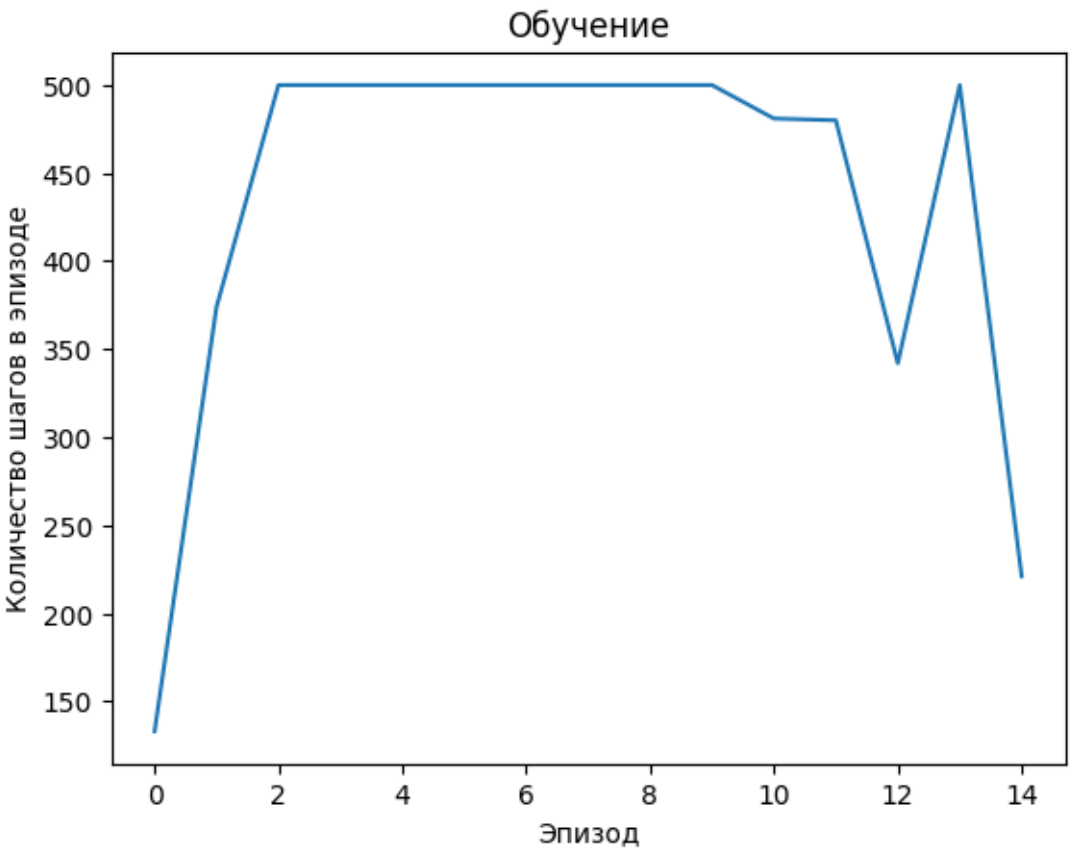
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0
2
4
6
8
10
12
14
Эпизод

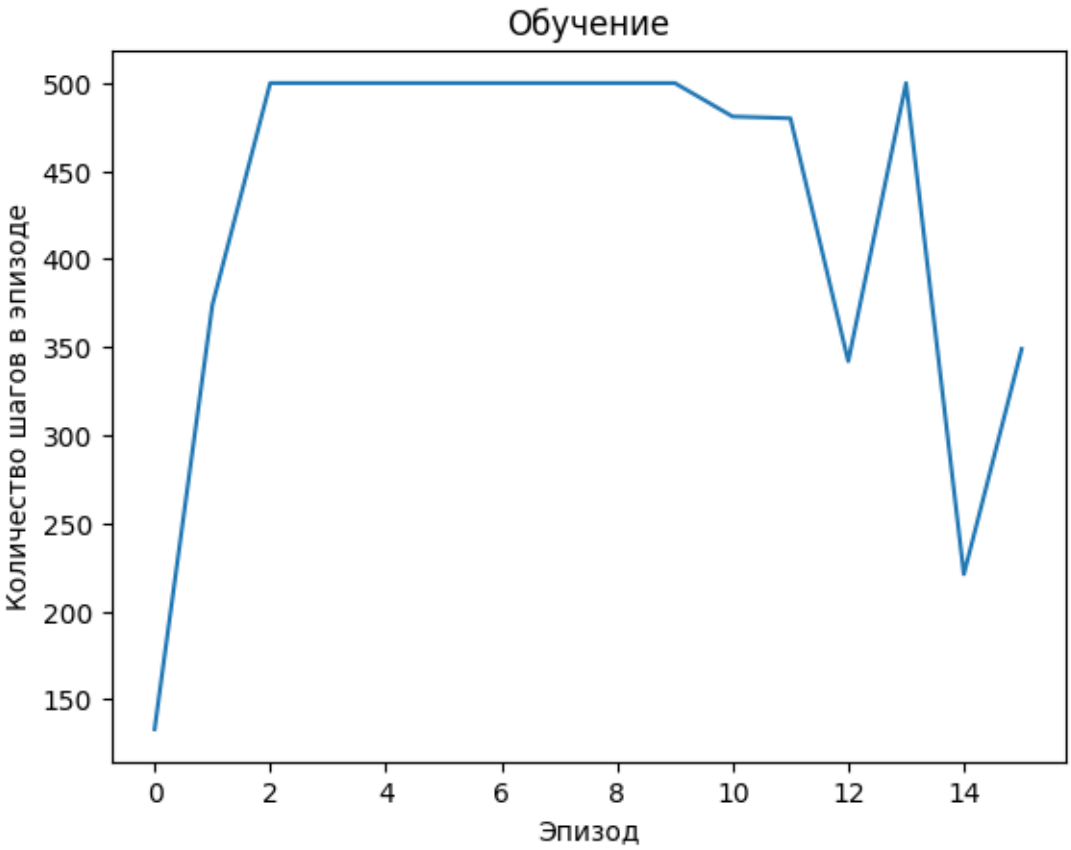
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0
2
4
6
8
10
12
14
Эпизод

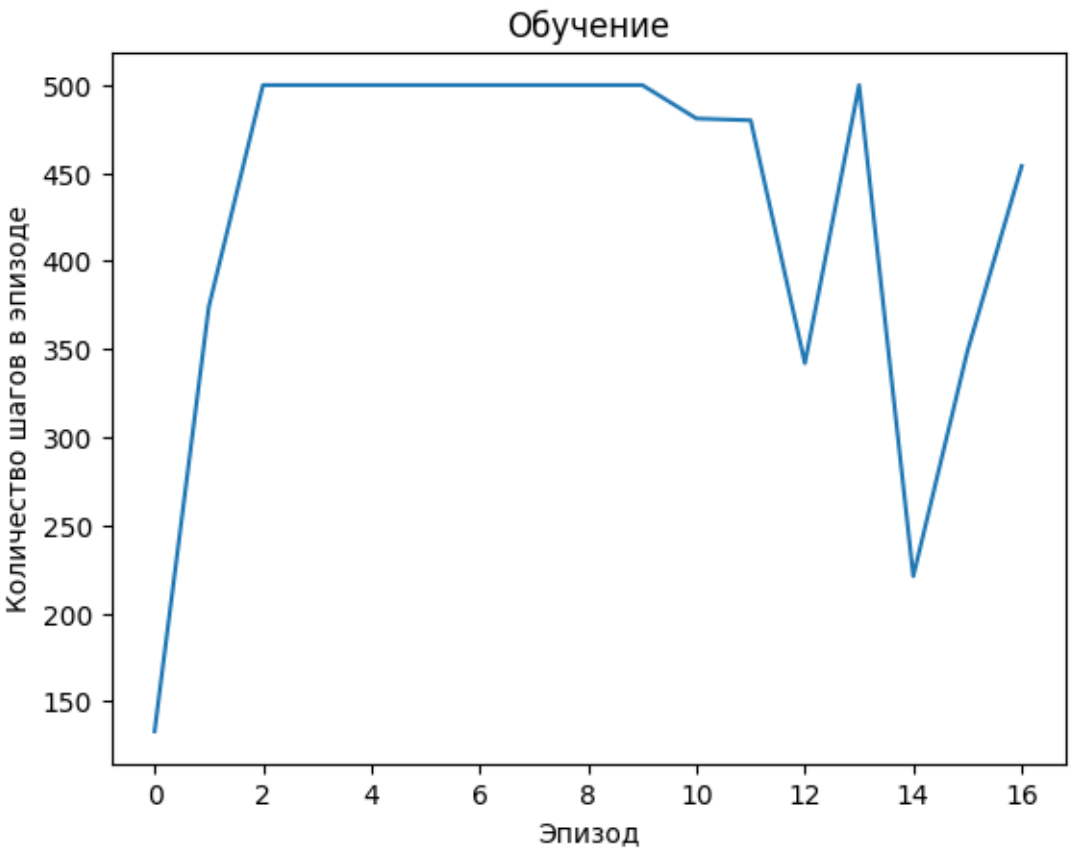
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
0
2
4
6
8
10
12
14
16

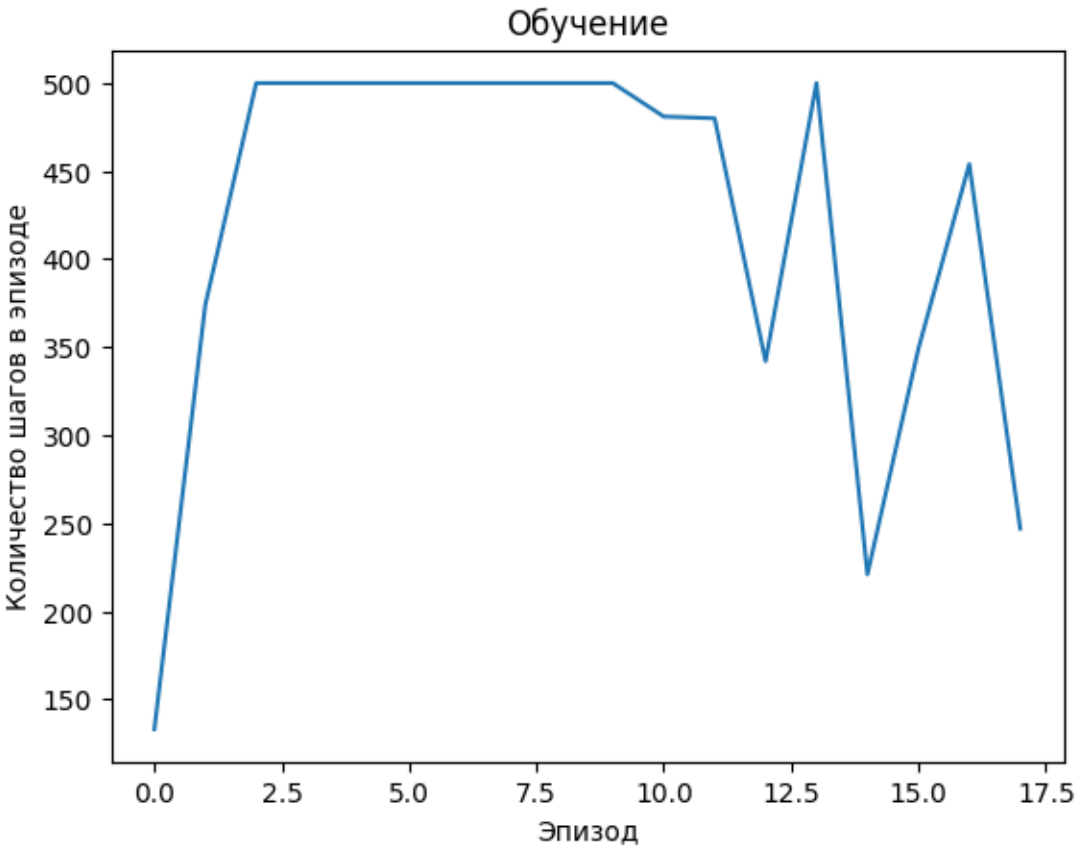
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5
Эпизод

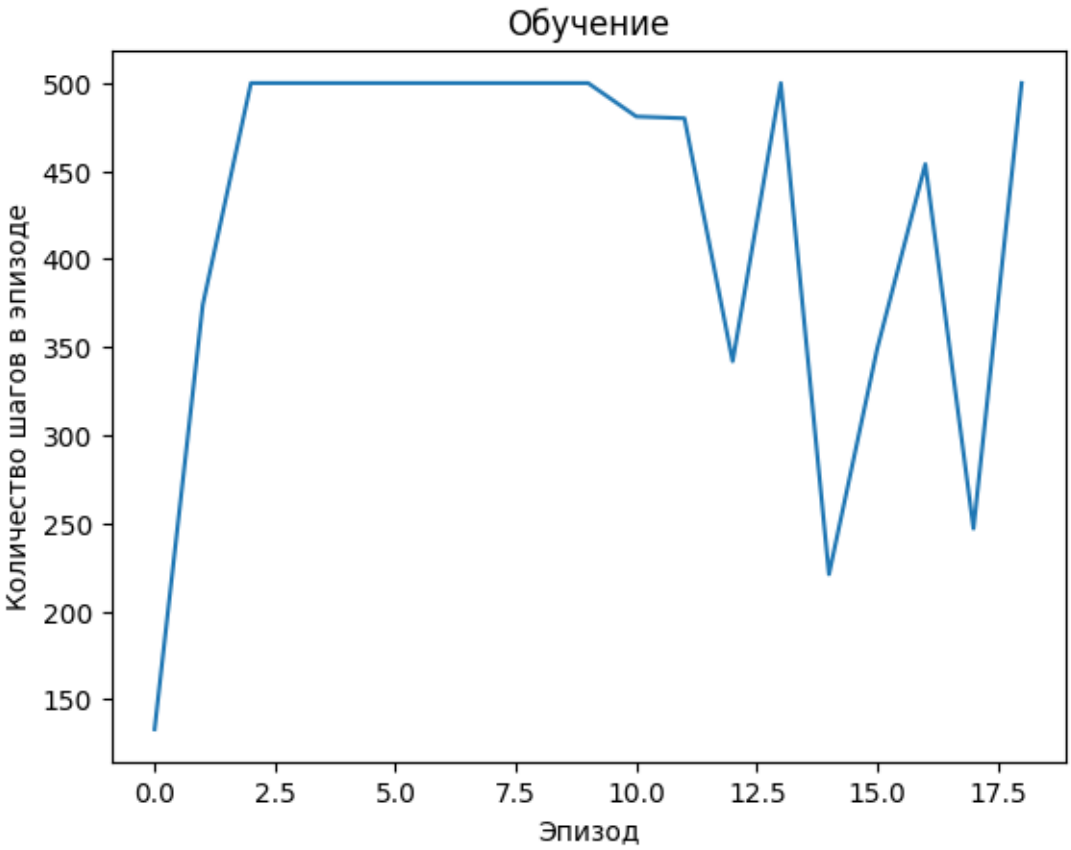
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5
Эпизод

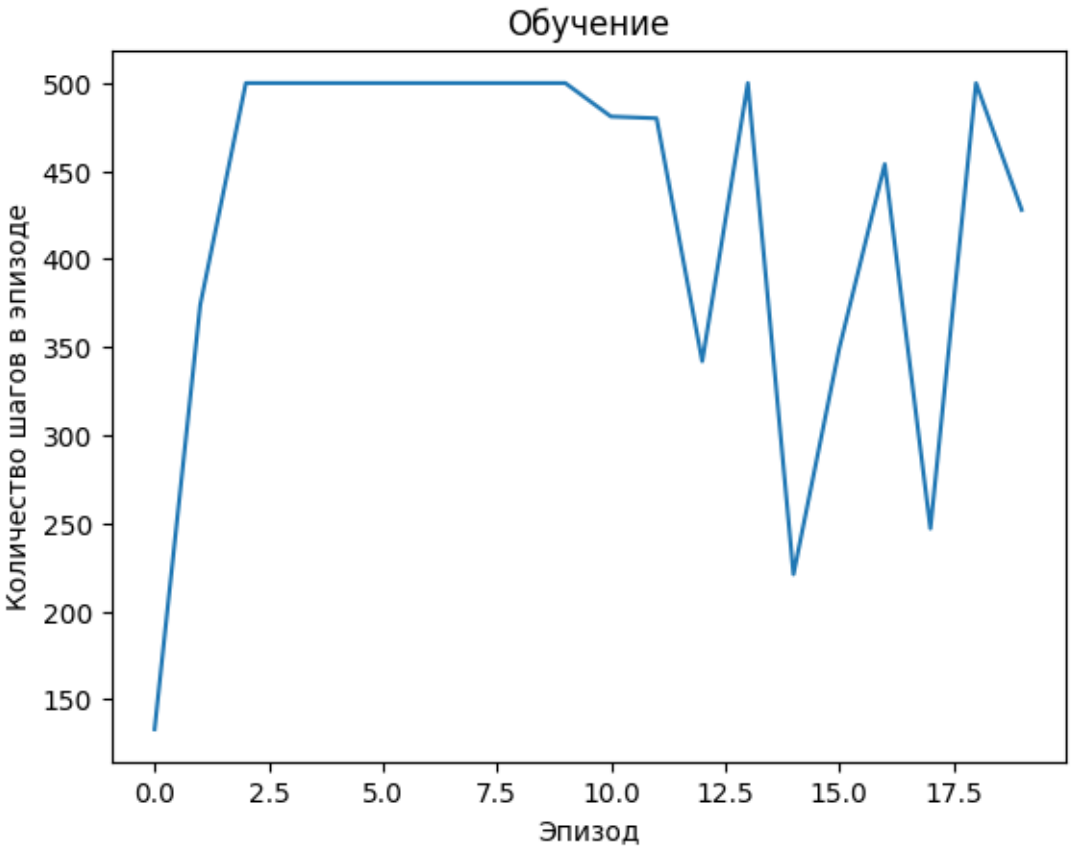
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5
Эпизод

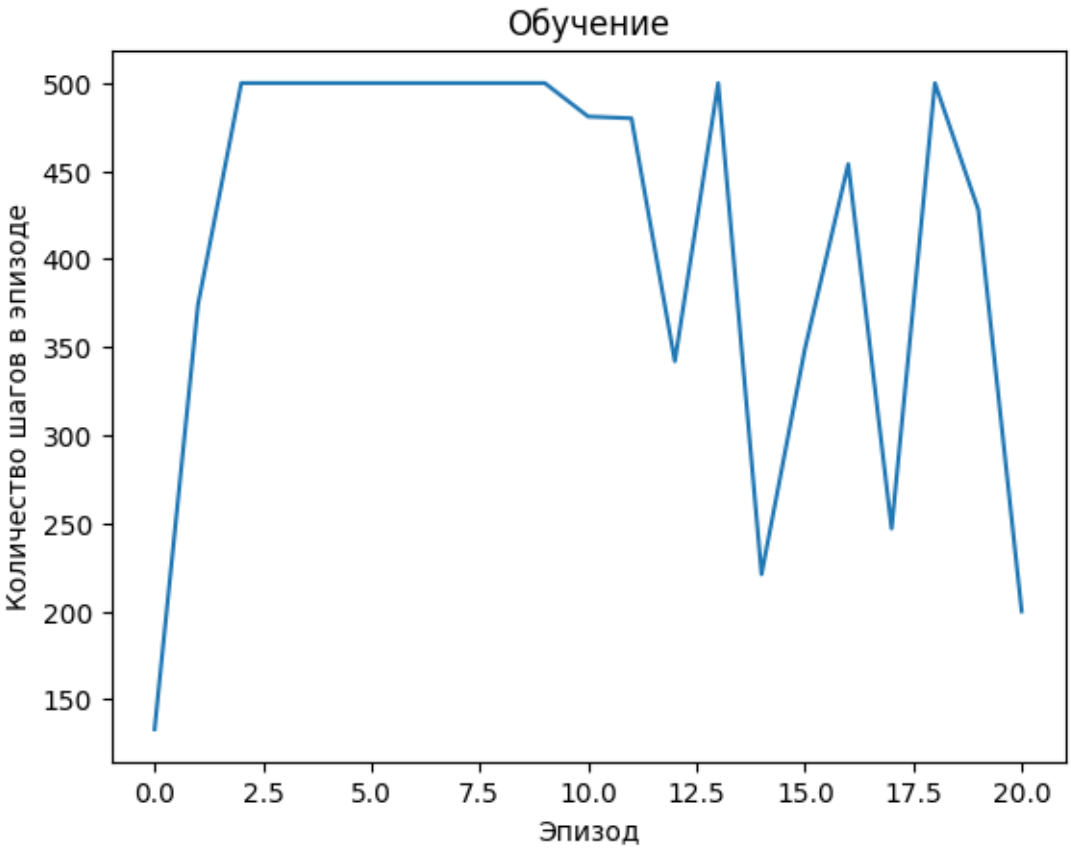
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5
20.0
Эпизод

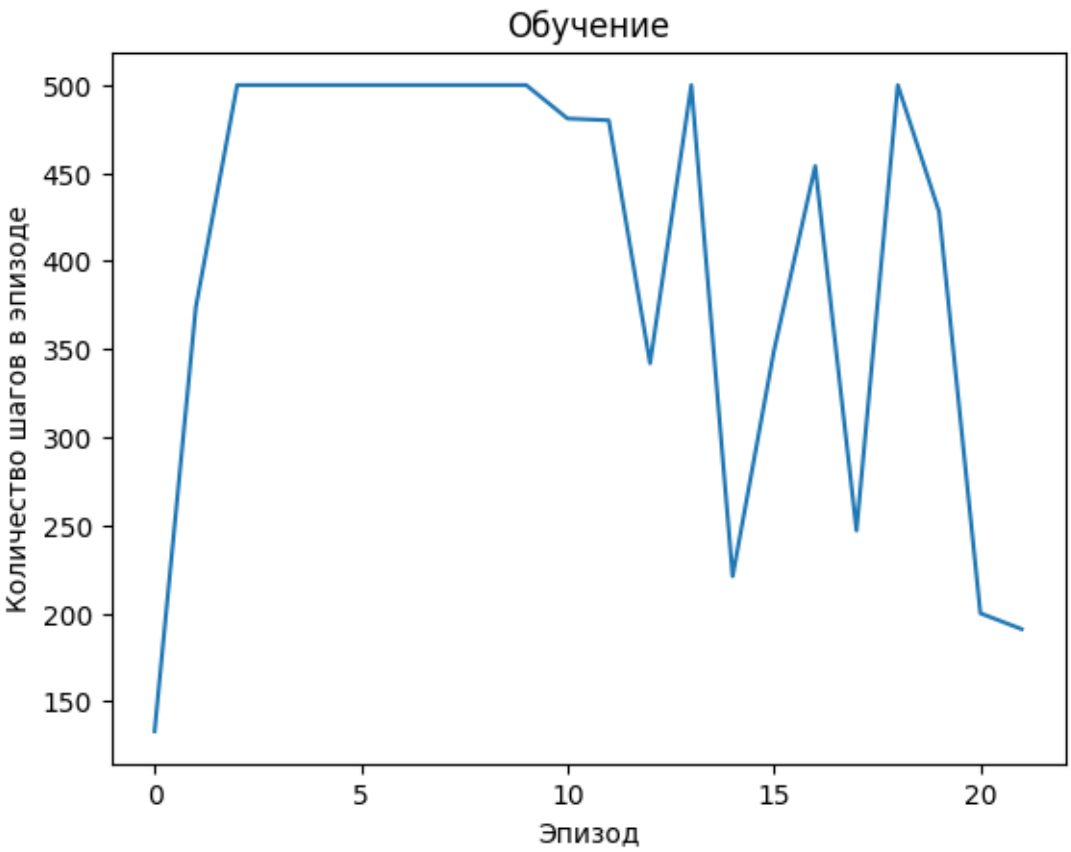
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0
5
10
15
20
Эпизод

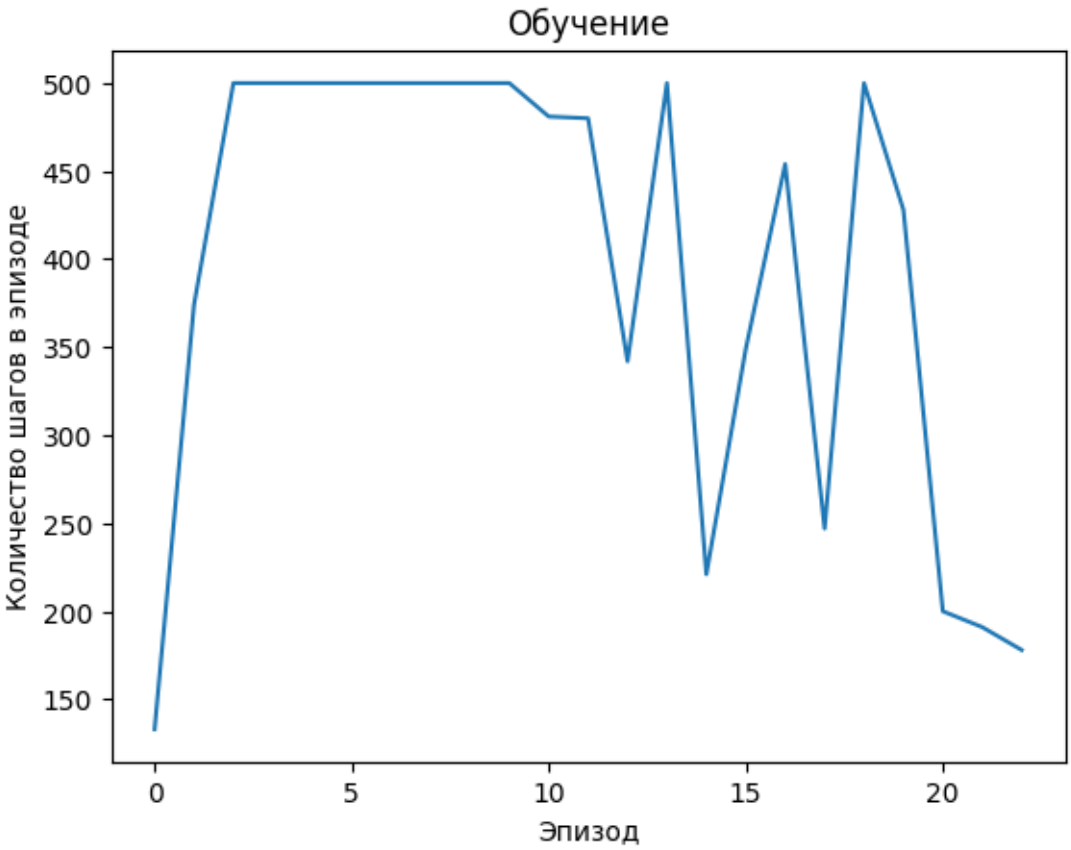
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
0
5
10
15
20

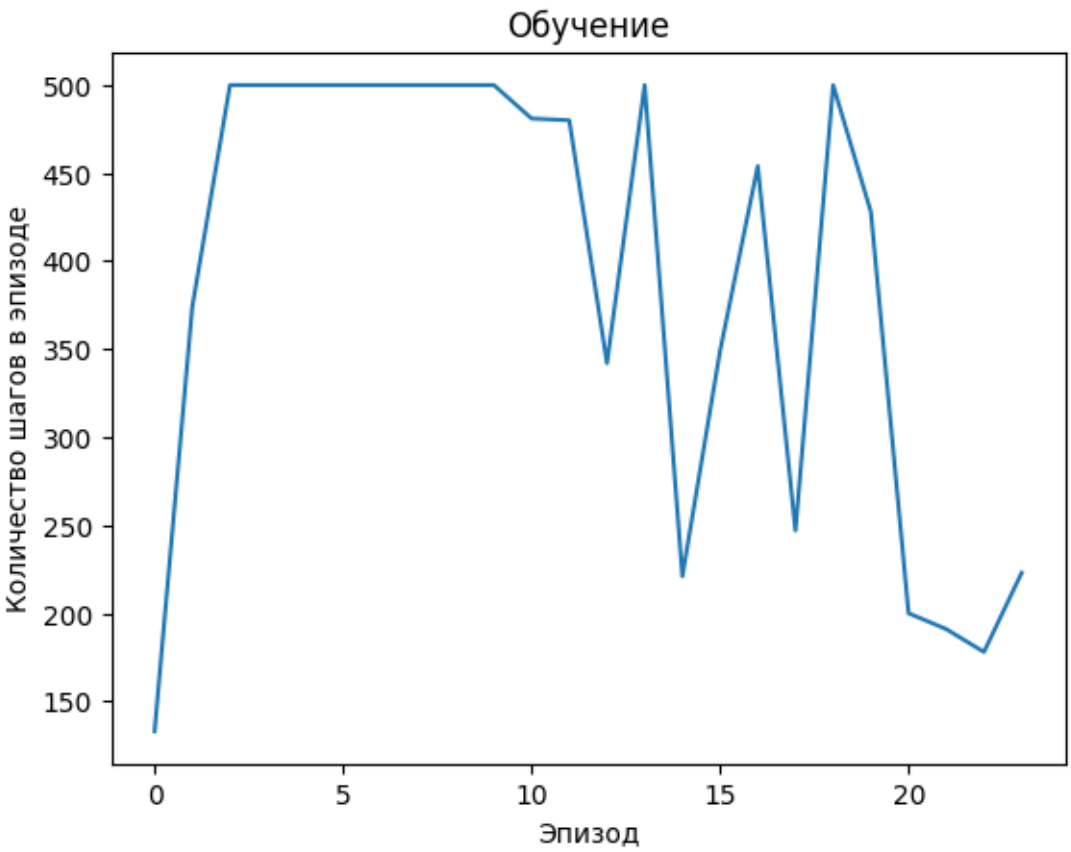
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
0
5
10
15
20

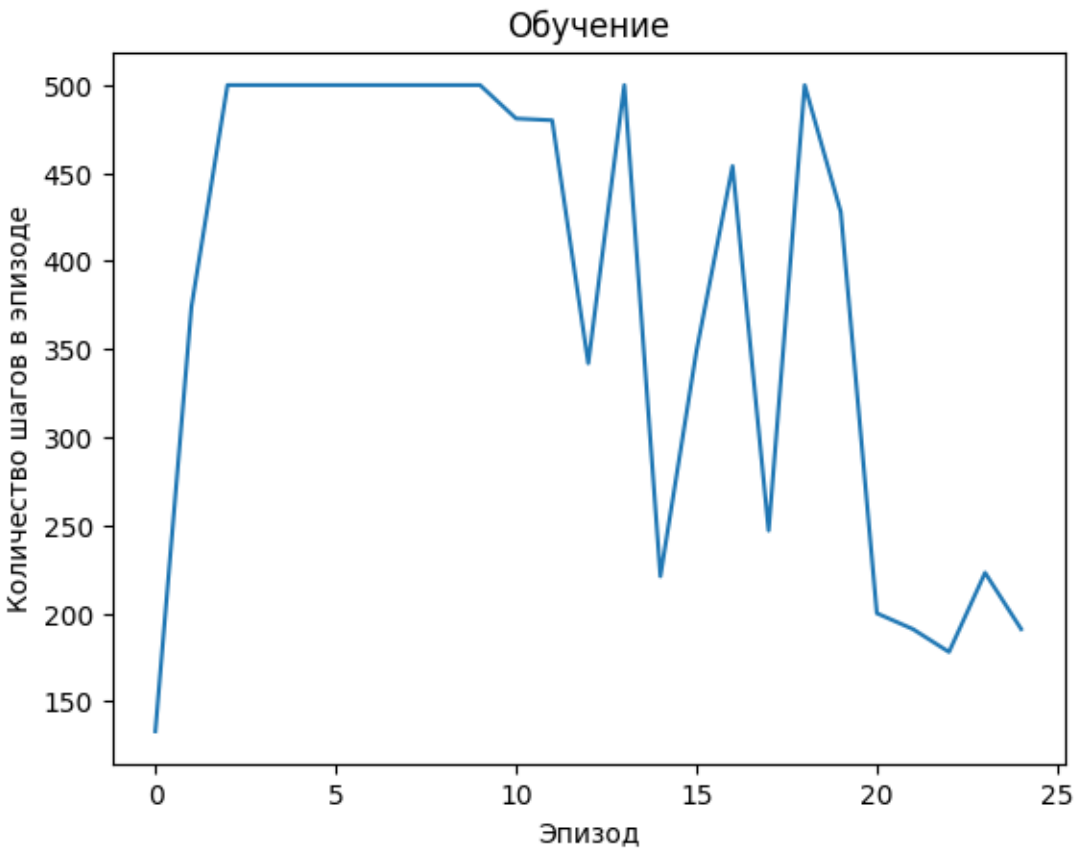
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
0
5
10
15
20
25

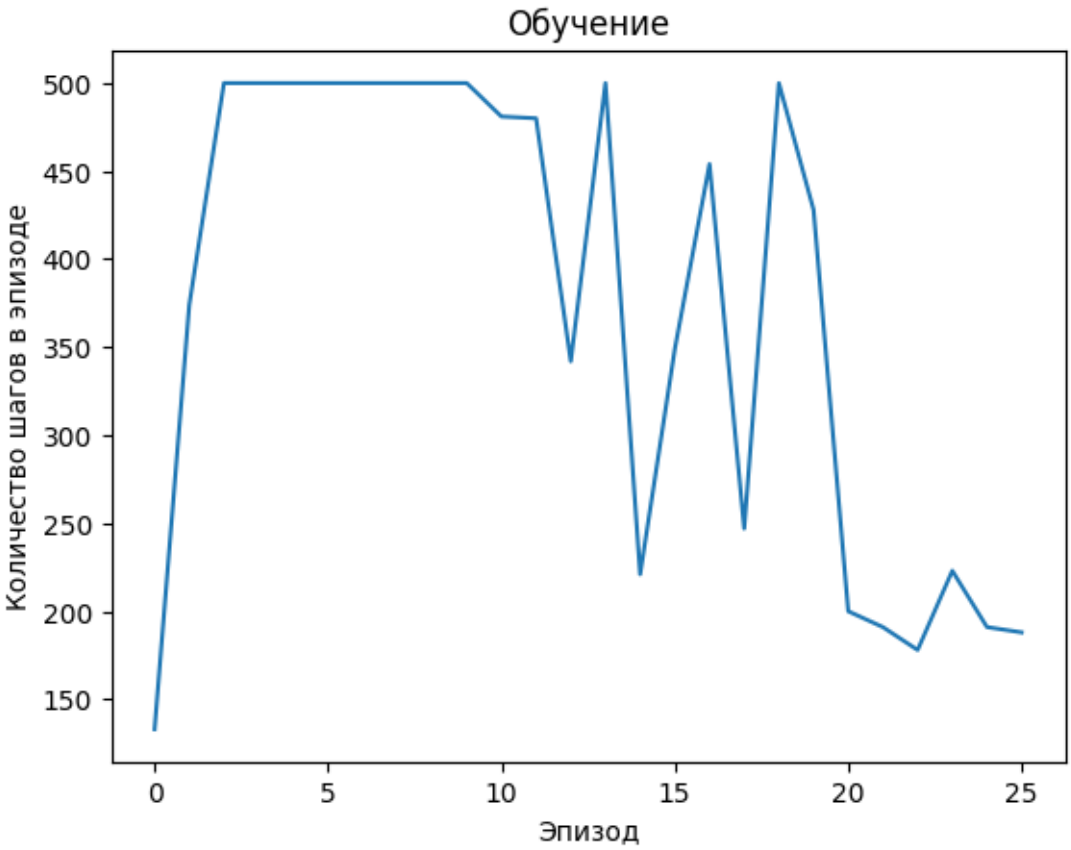
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
0
5
10
15
20
25

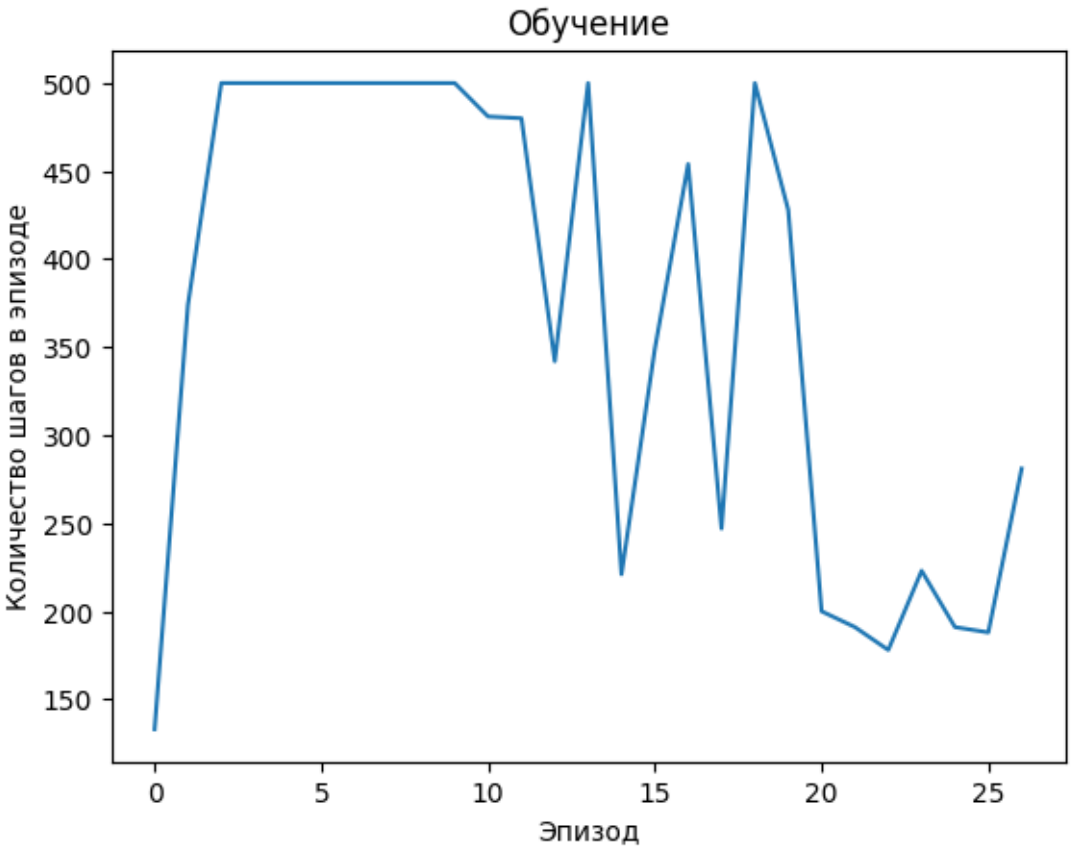
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
0
5
10
15
20
25

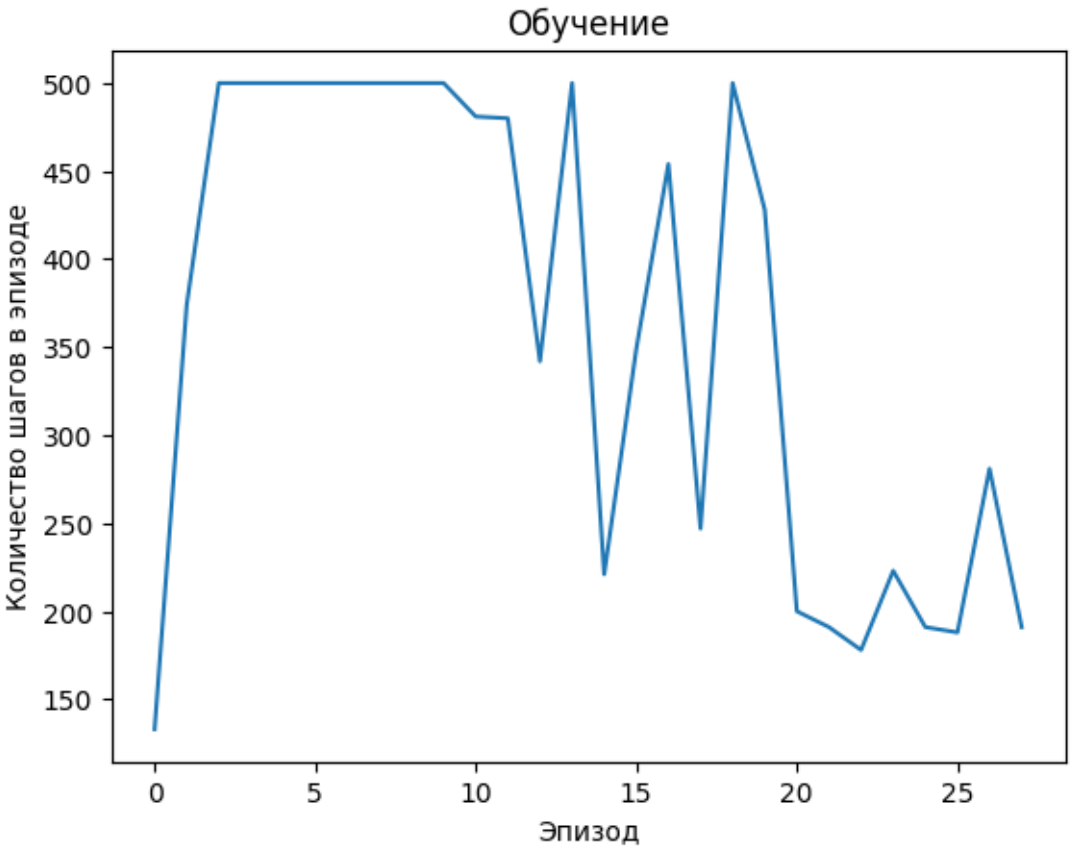
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0
5
10
15
20
25
Эпизод

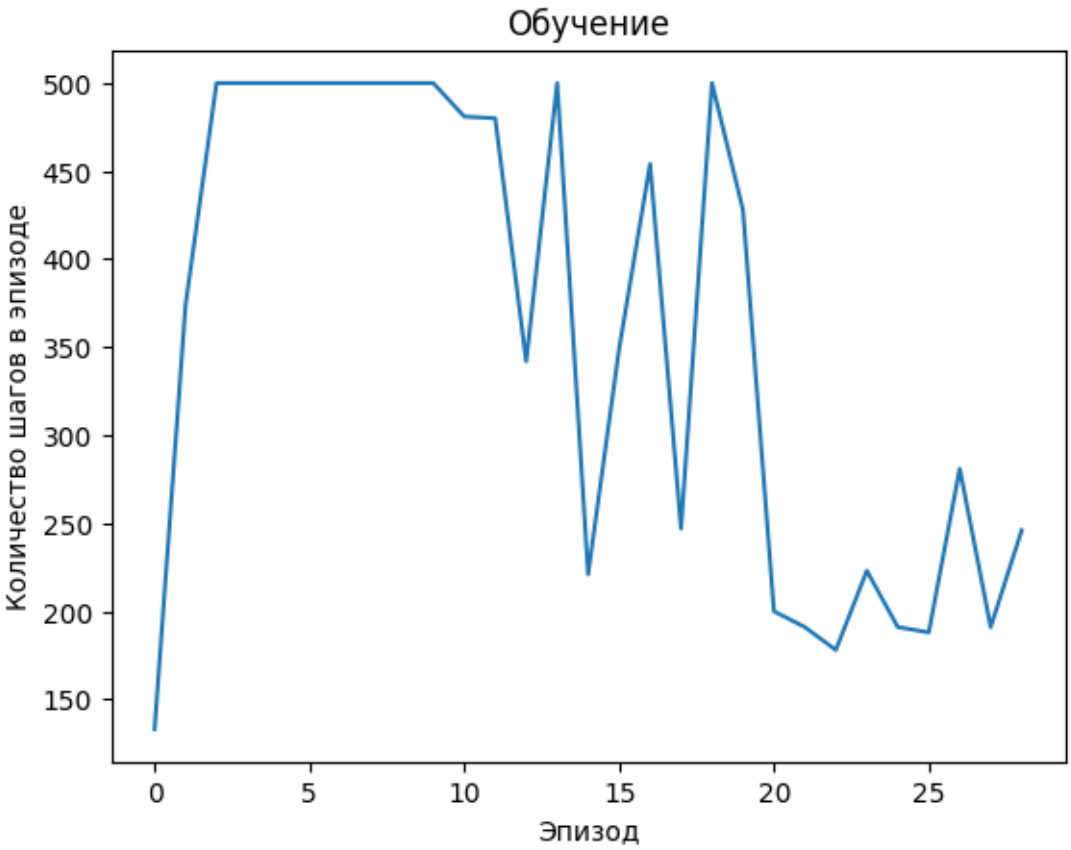
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
0
5
10
15
20
25

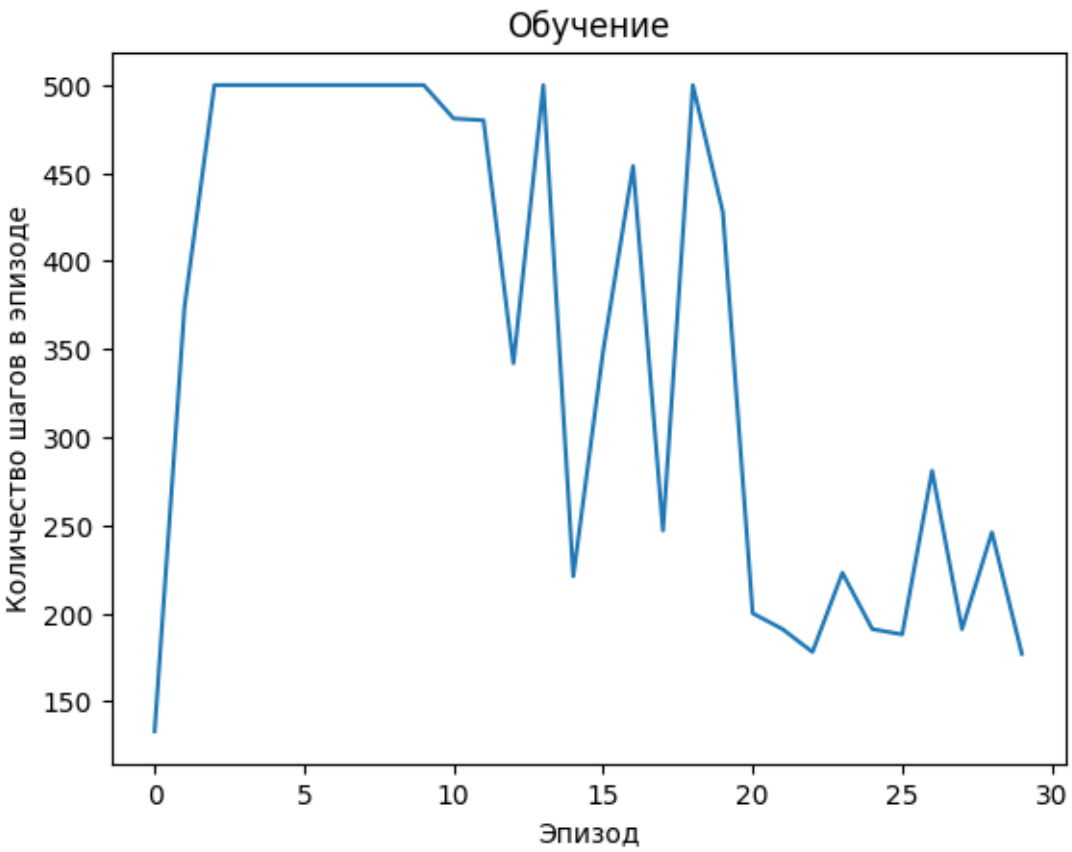
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
0
5
10
15
20
25
30

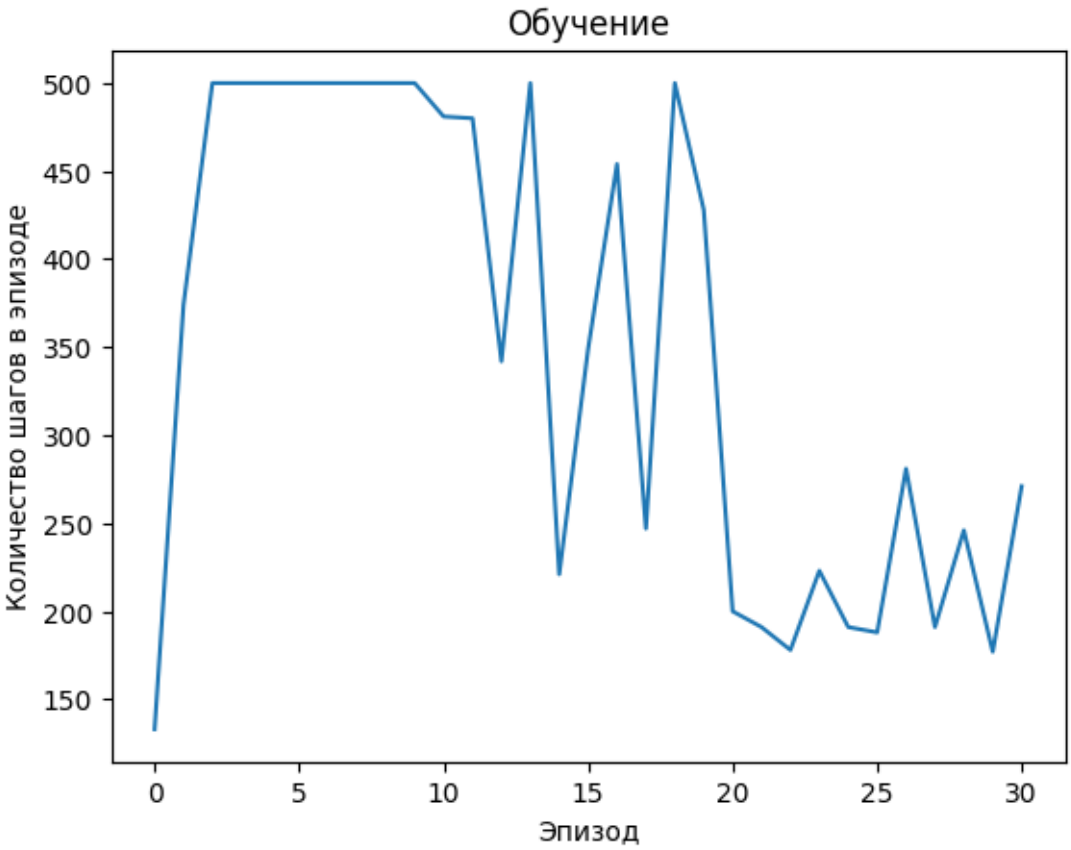
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
0
5
10
15
20
25
30

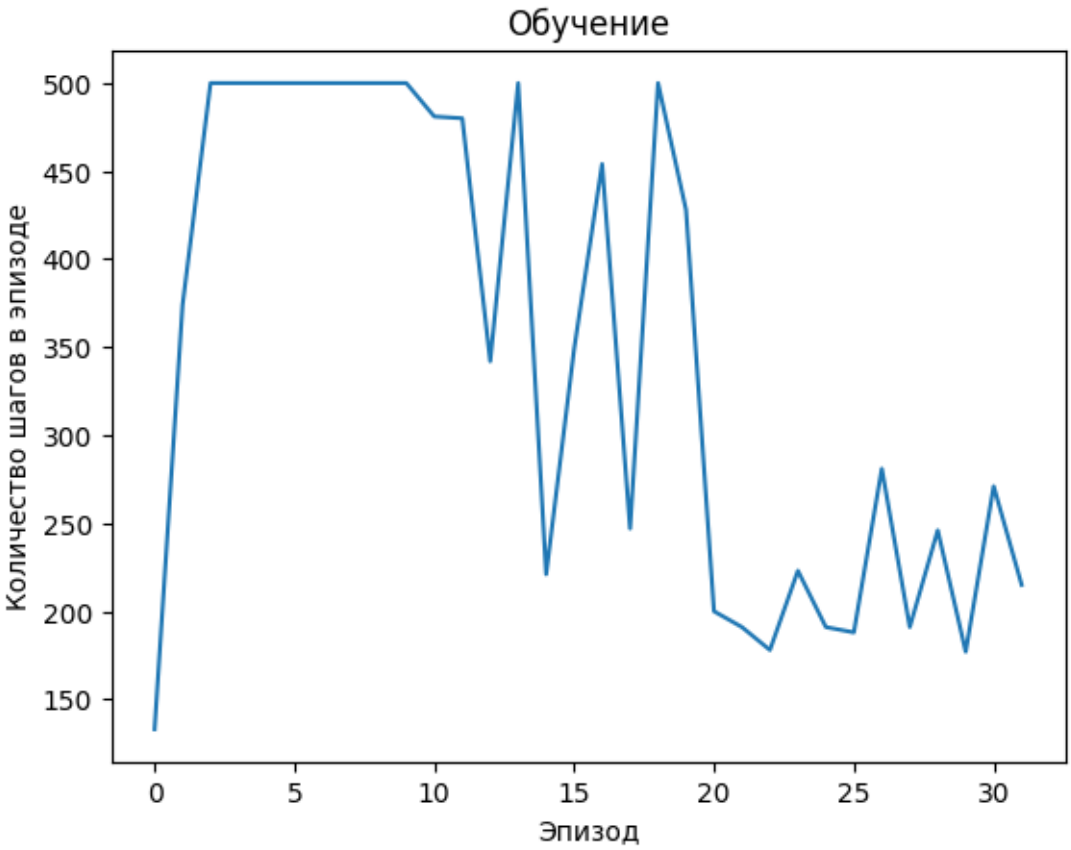
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
0
5
10
15
20
25
30

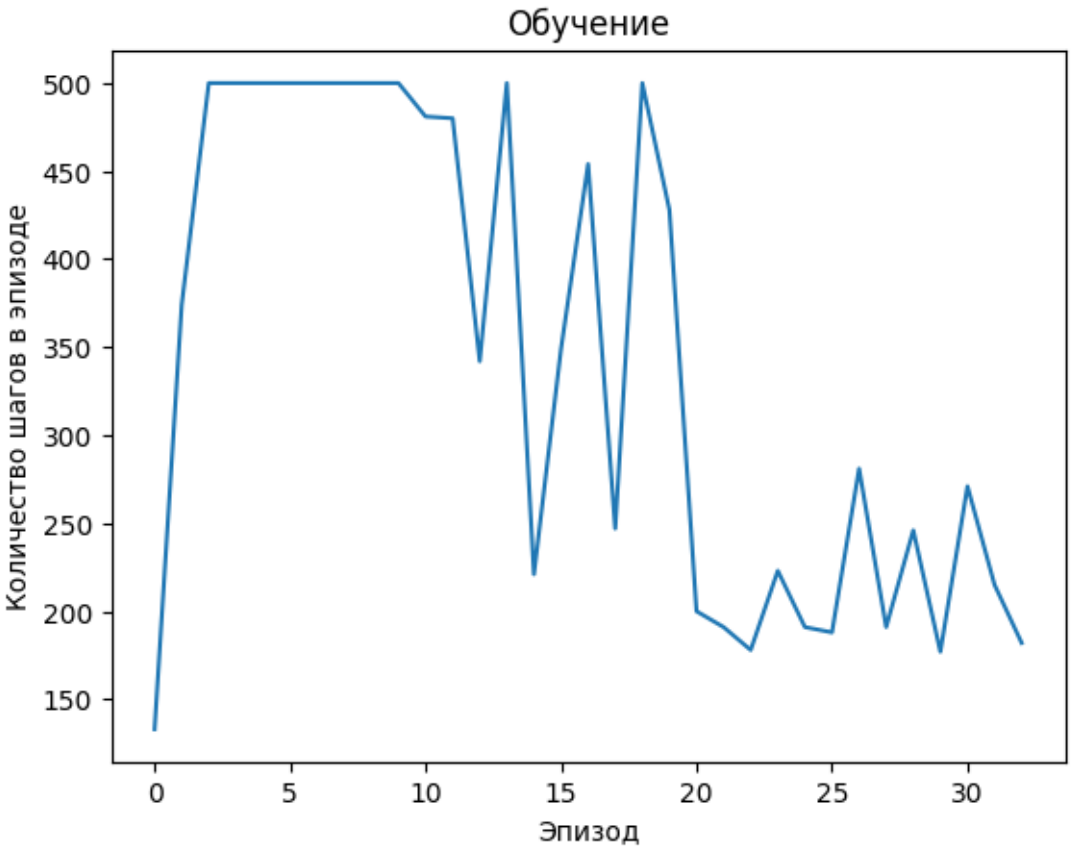
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0
5
10
15
20
25
30
Эпизод

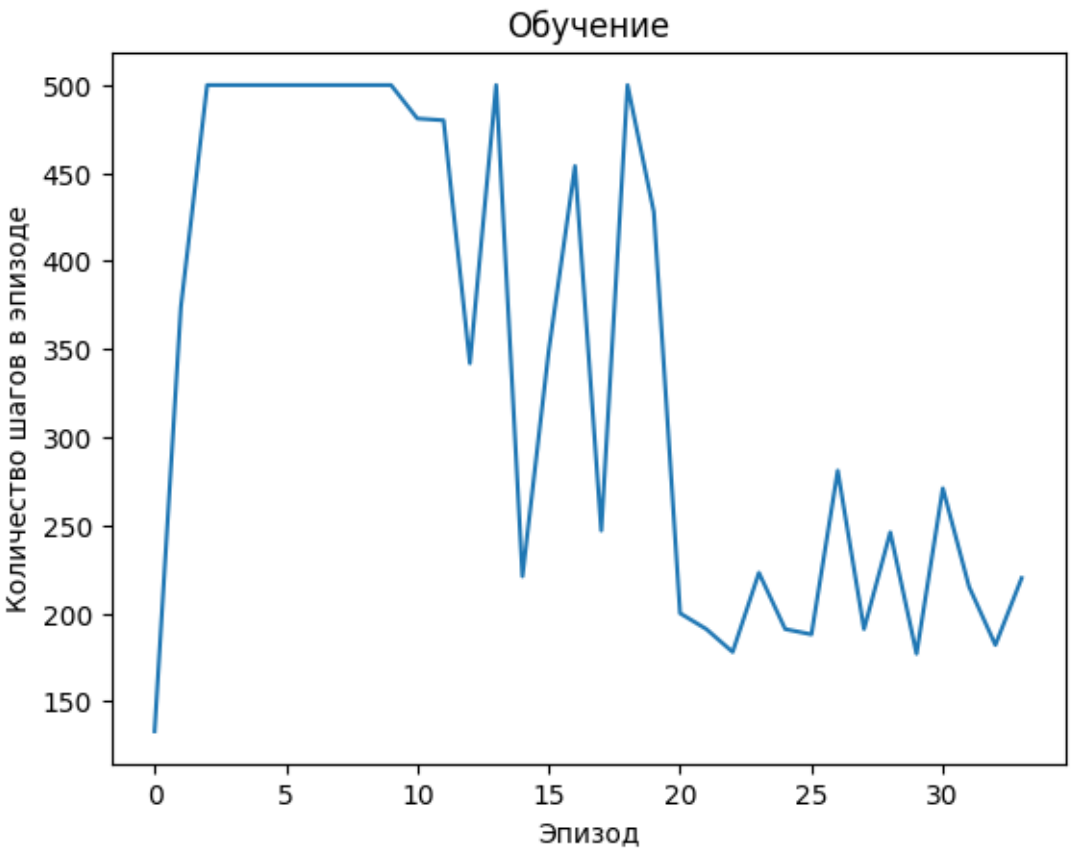
Обучение
Количество шагов в эпизоде
500
450
400
350
300
250
200
150
0
5
10
15
20
25
30
Эпизод

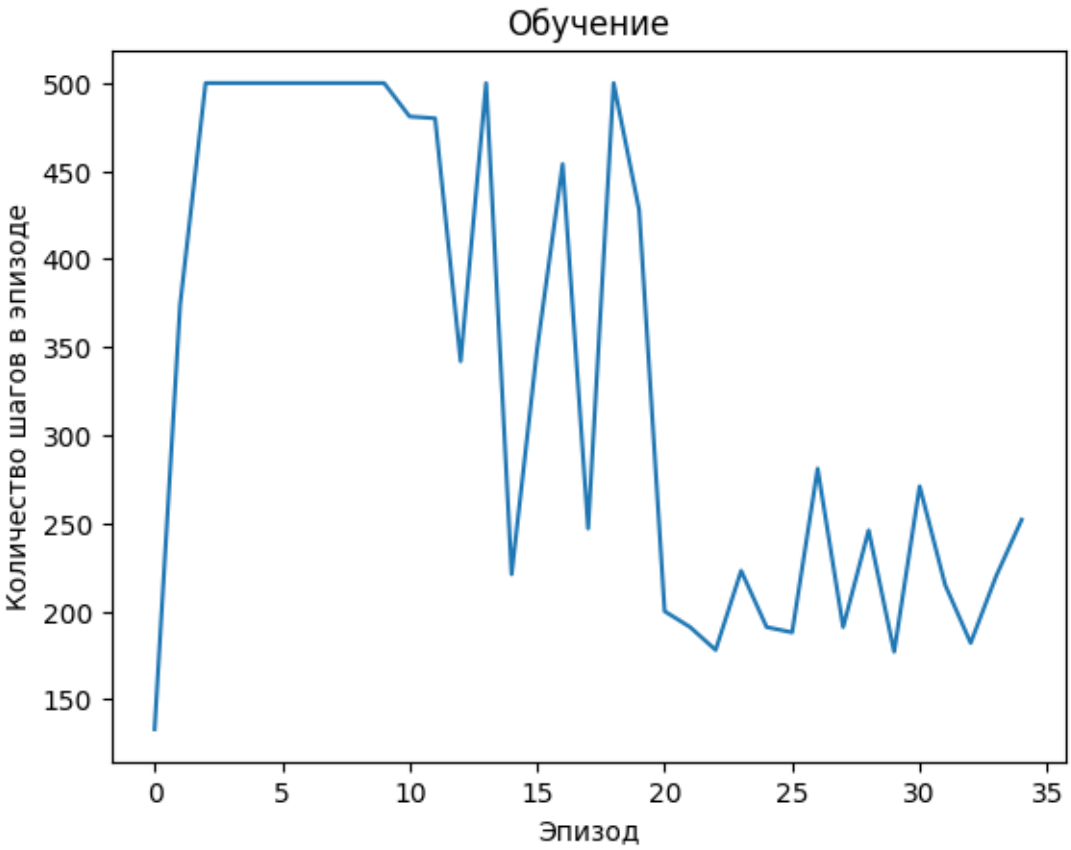
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
0
5
10
15
20
25
30
35

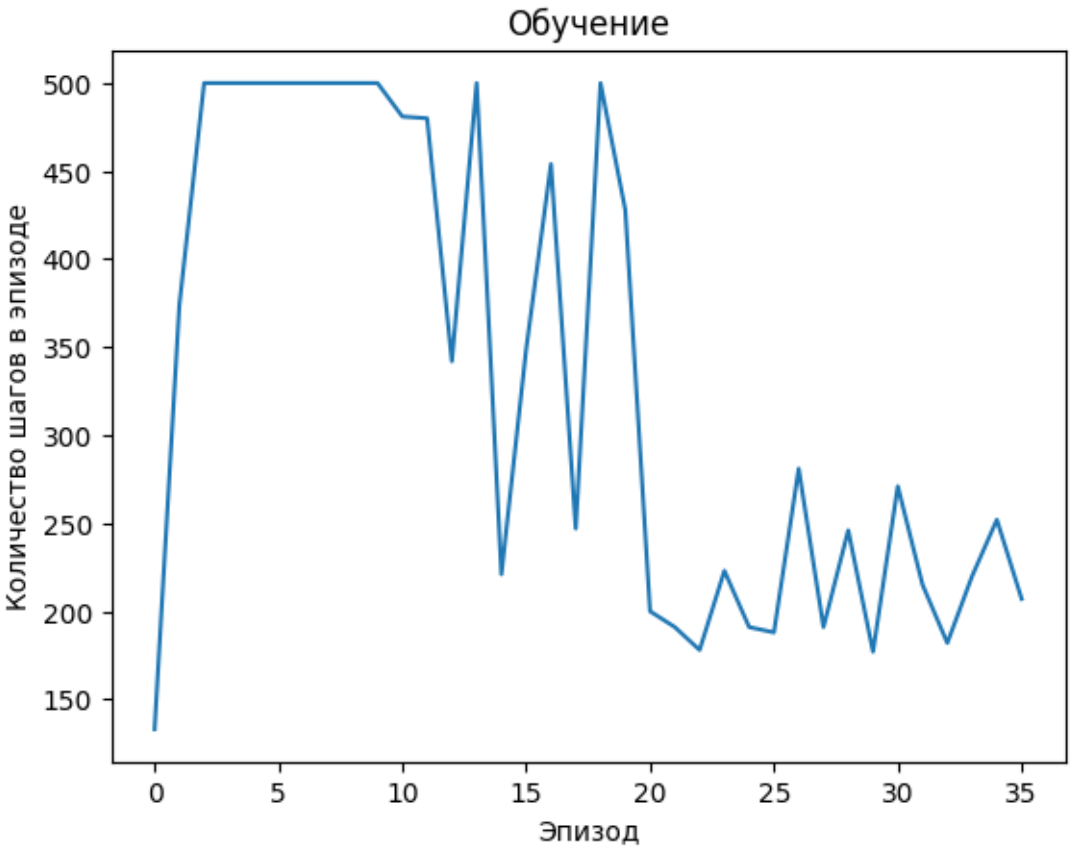
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
0
5
10
15
20
25
30
35

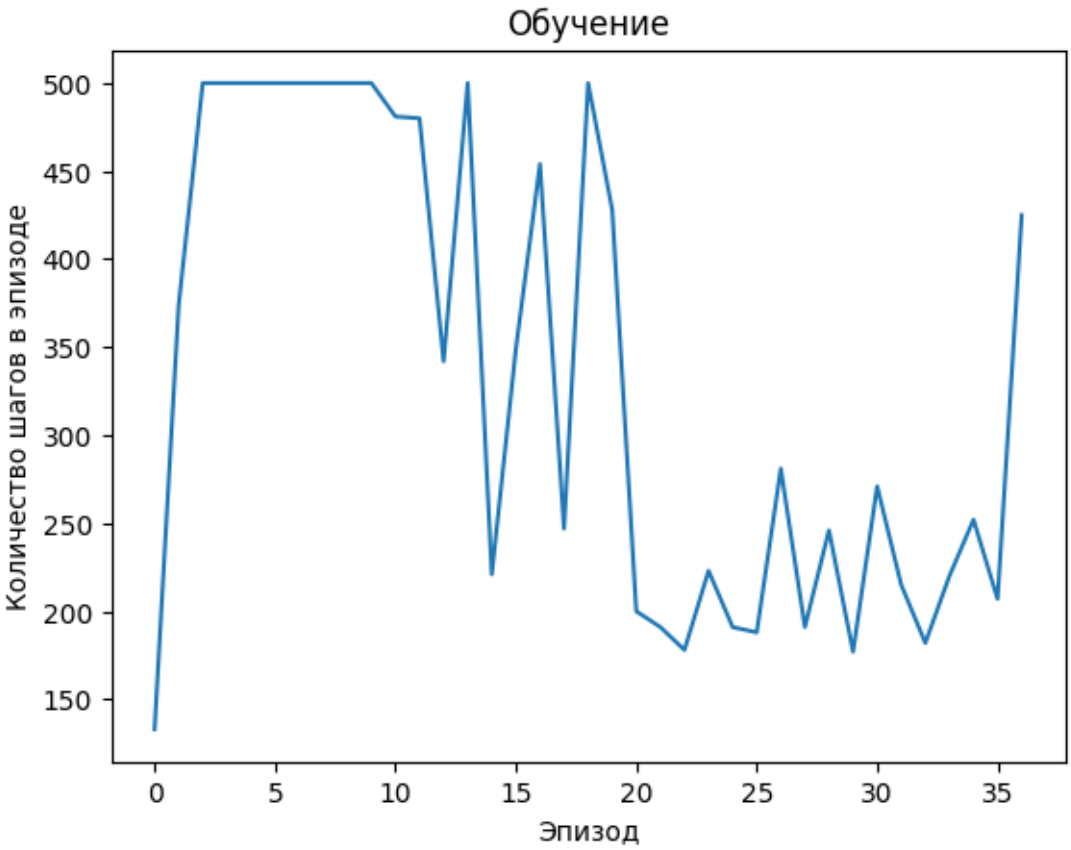
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
0
5
10
15
20
25
30
35

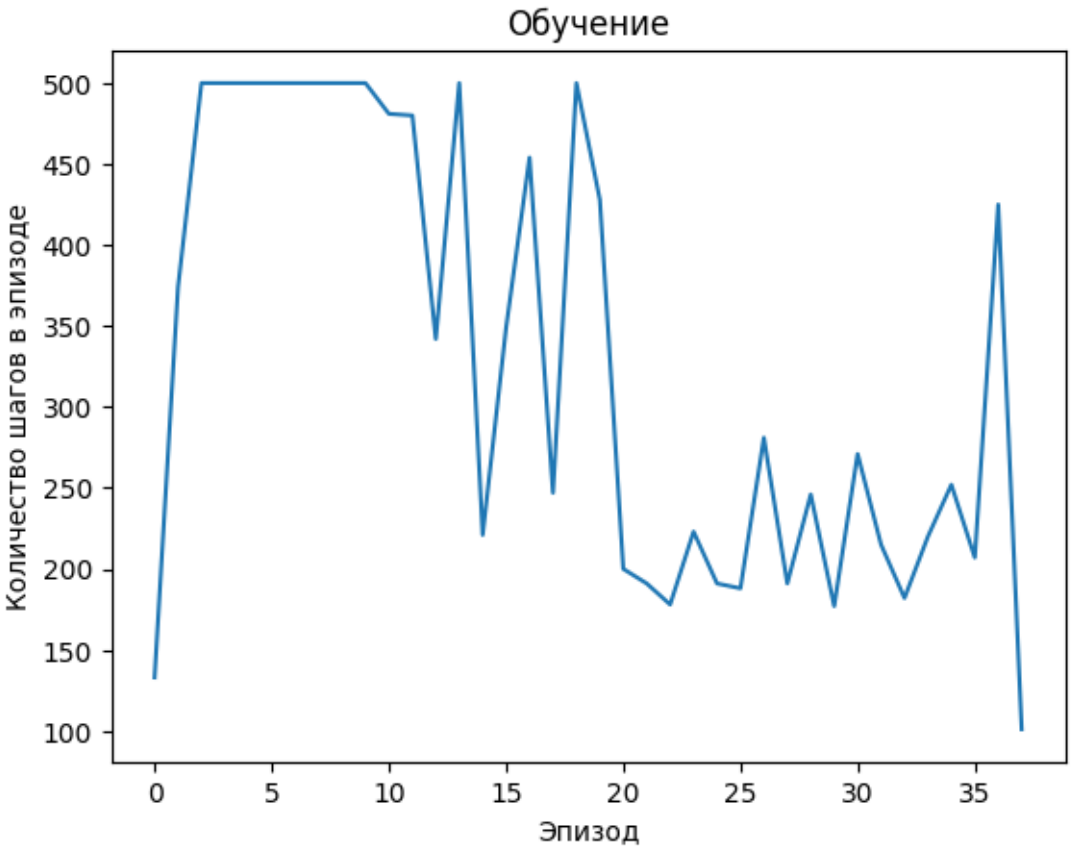
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
100
0
5
10
15
20
25
30
35

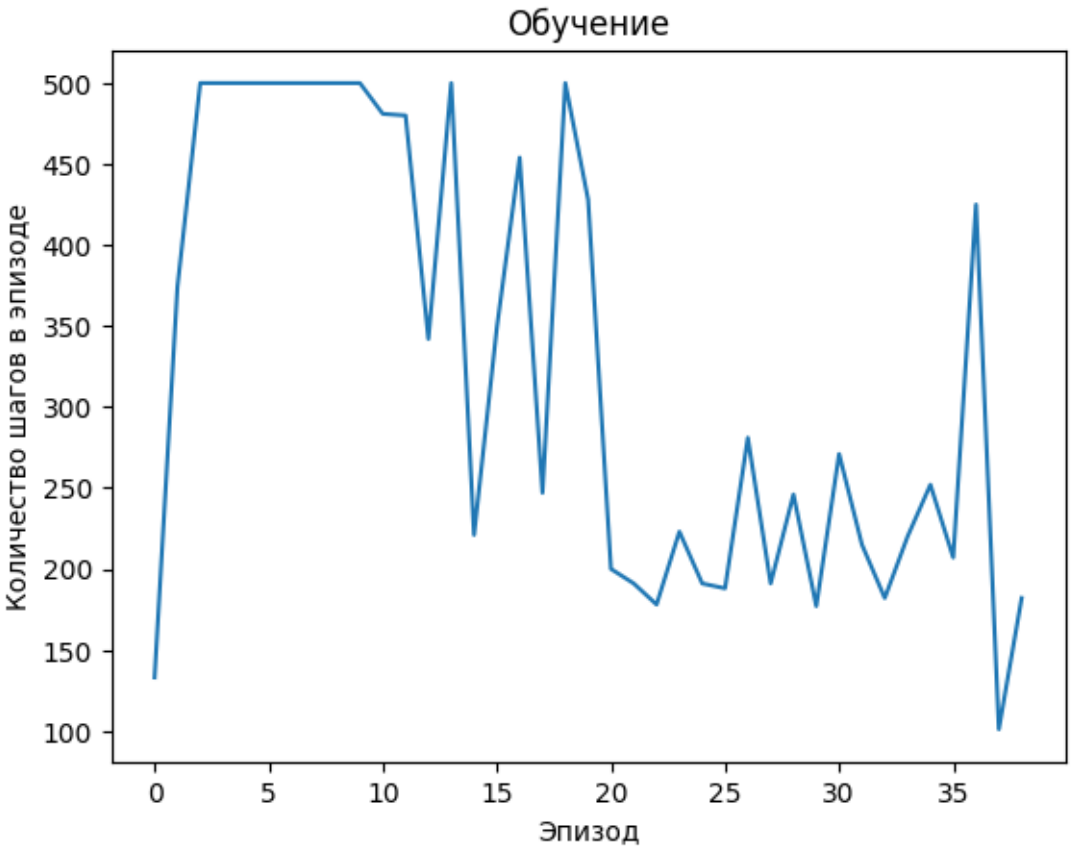
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
100
0
5
10
15
20
25
30
35

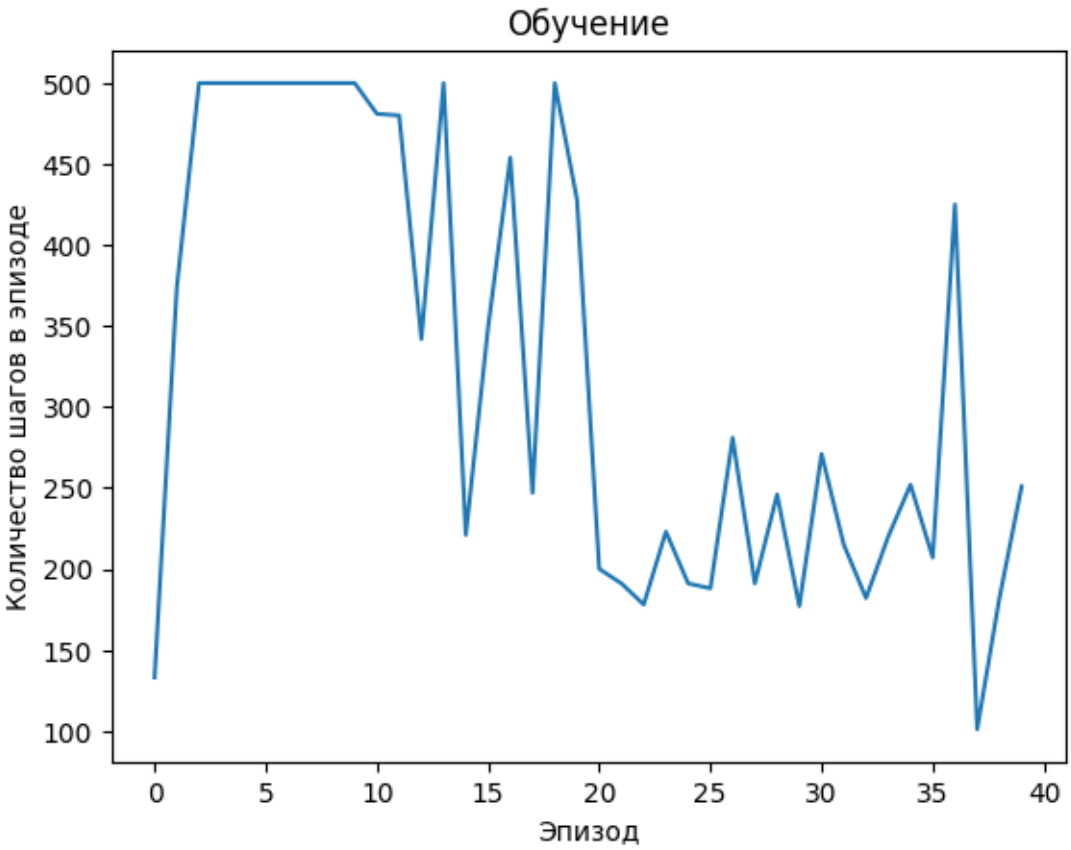
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
100
0
5
10
15
20
25
30
35
40

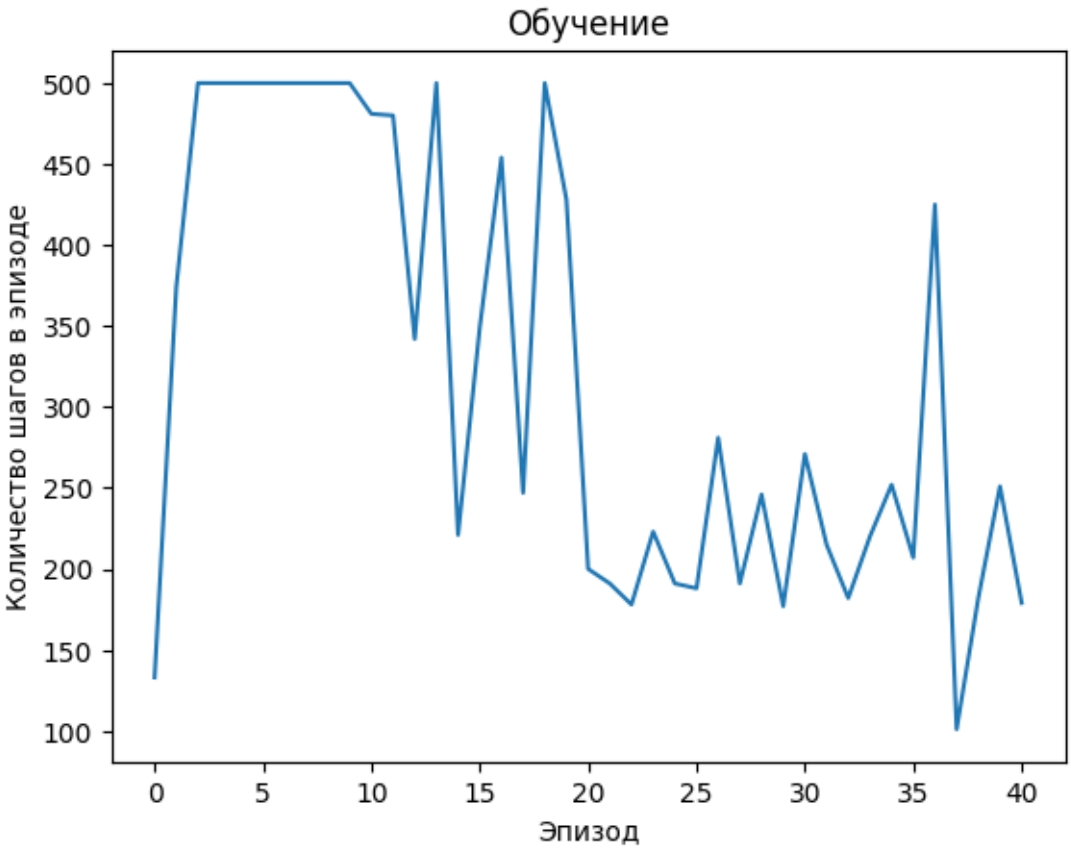
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
100
0
5
10
15
20
25
30
35
40

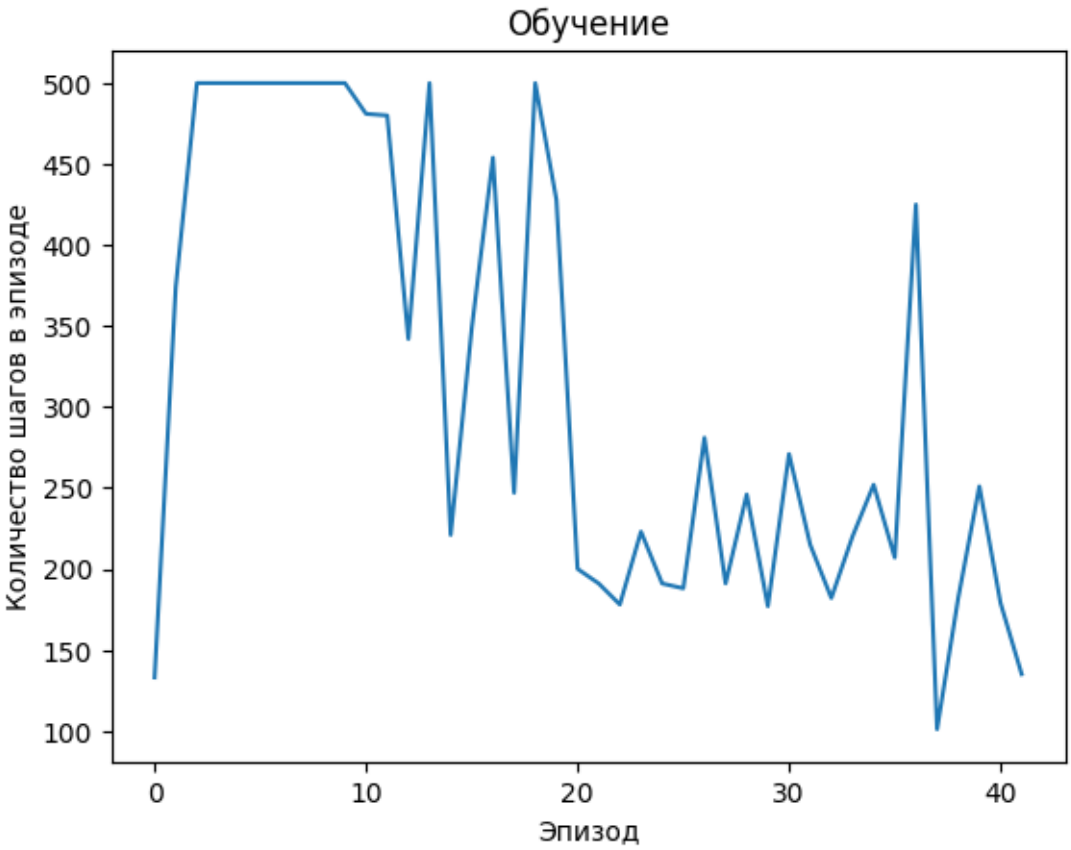
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
100
0
10
20
30
40

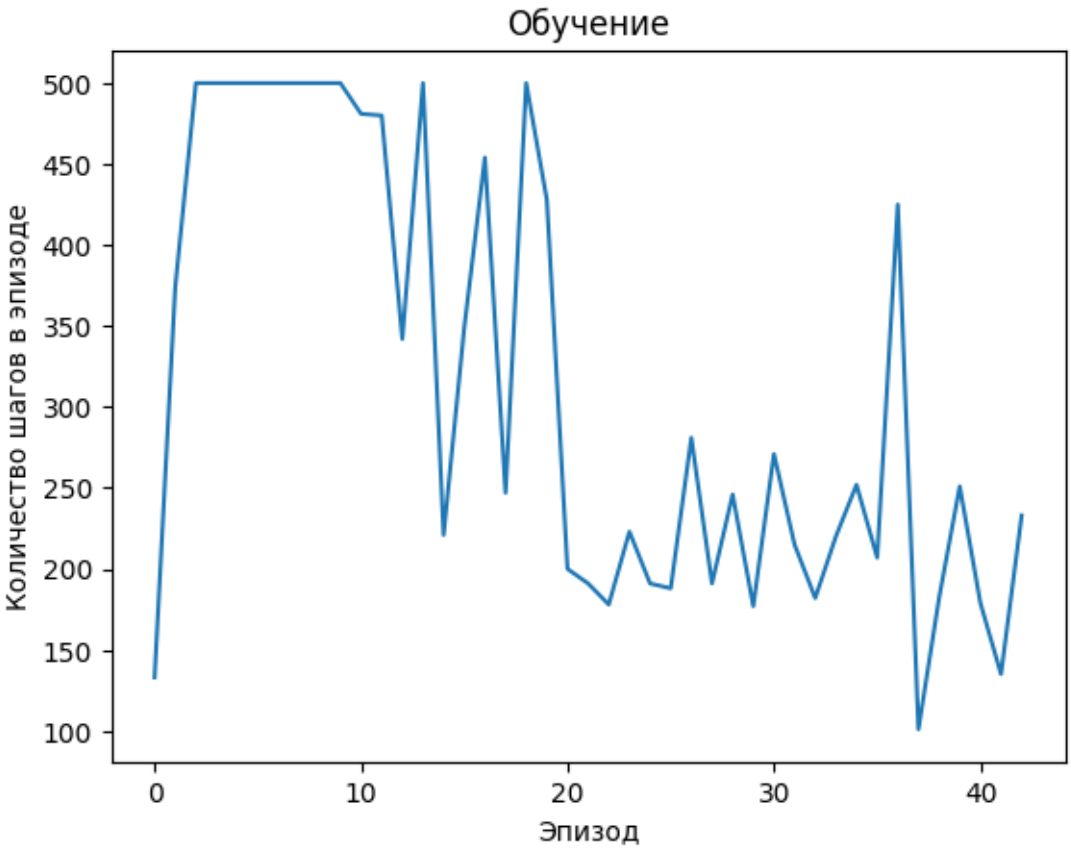
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
100
0
10
20
30
40

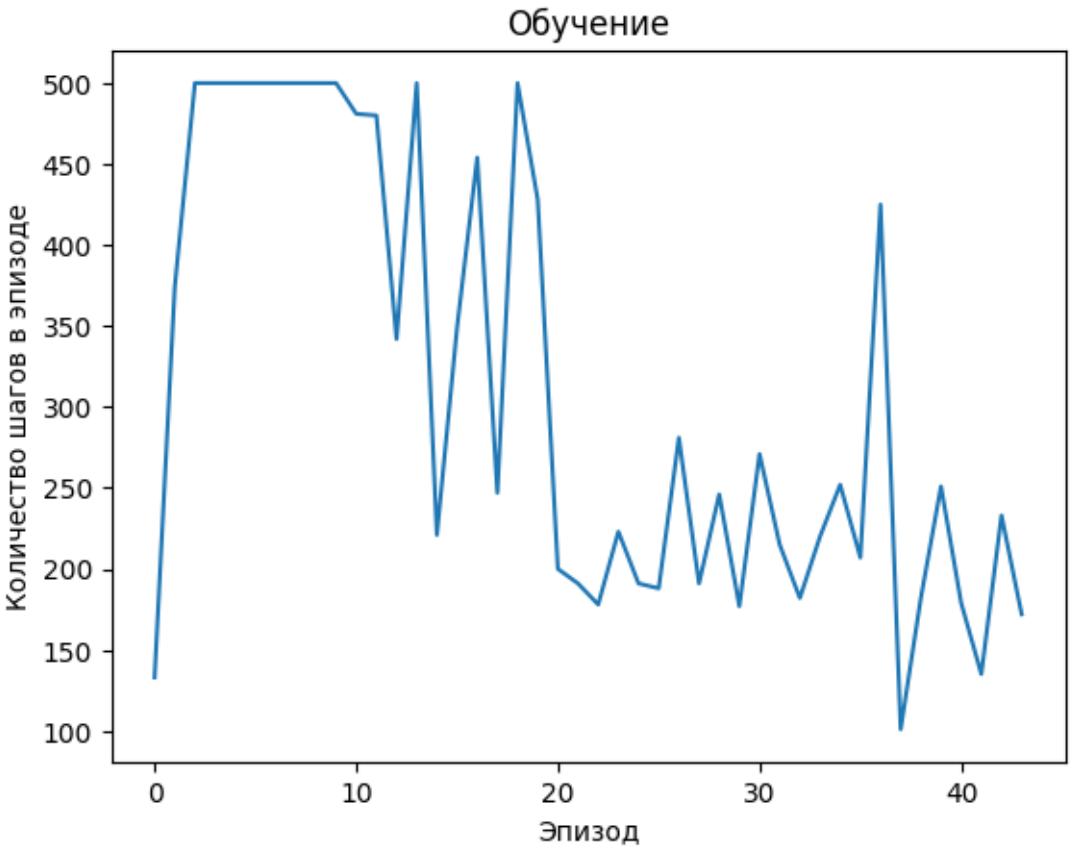
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
100
0
10
20
30
40

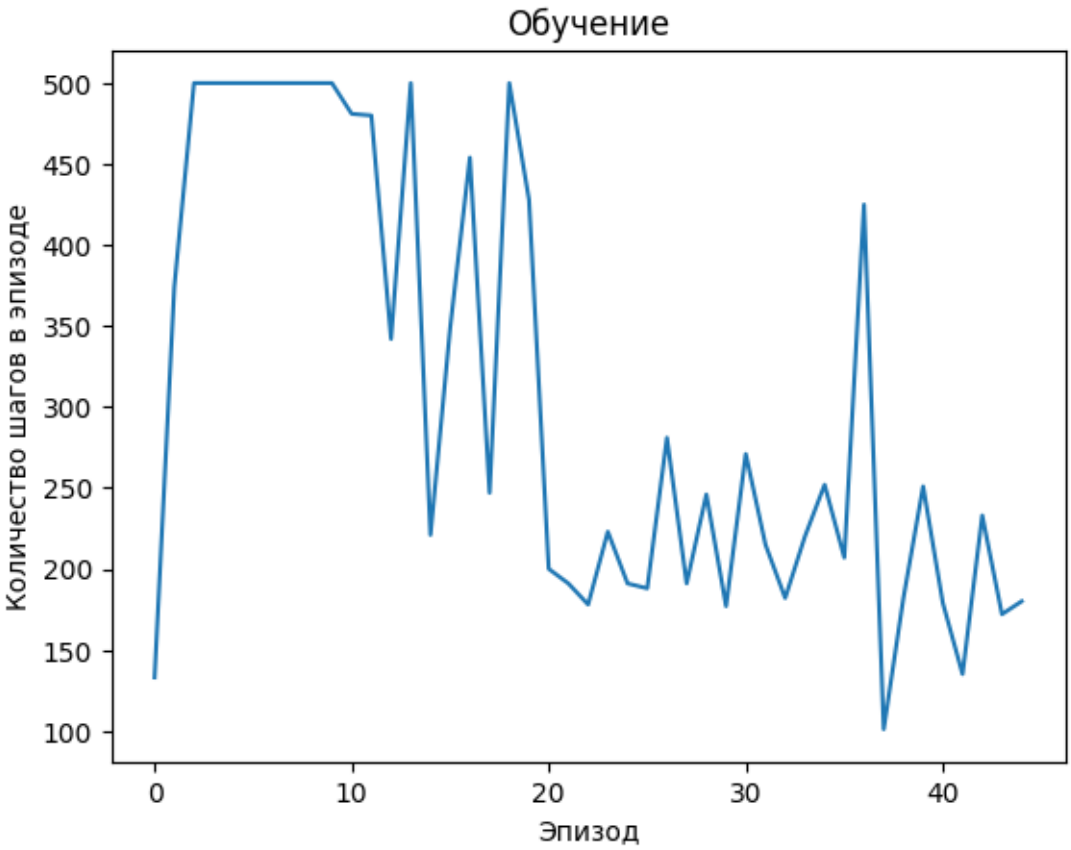
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
100
0
10
20
30
40

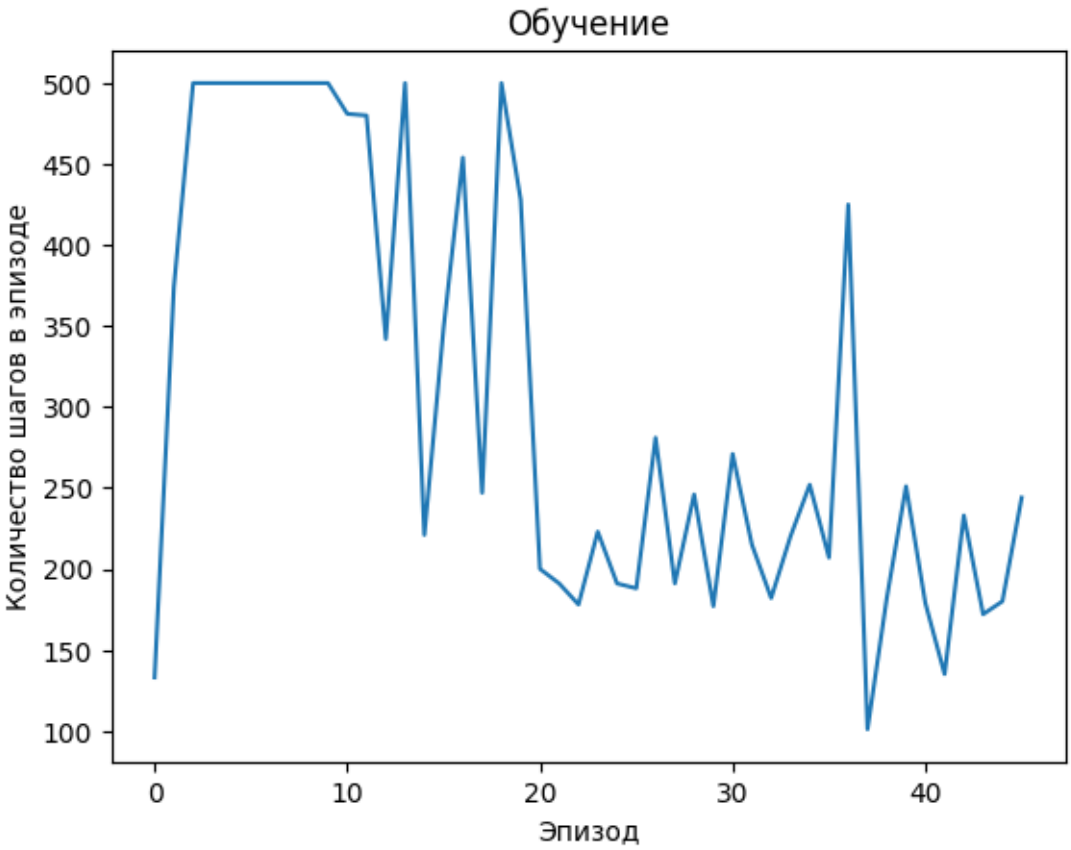
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
100
0
10
20
30
40

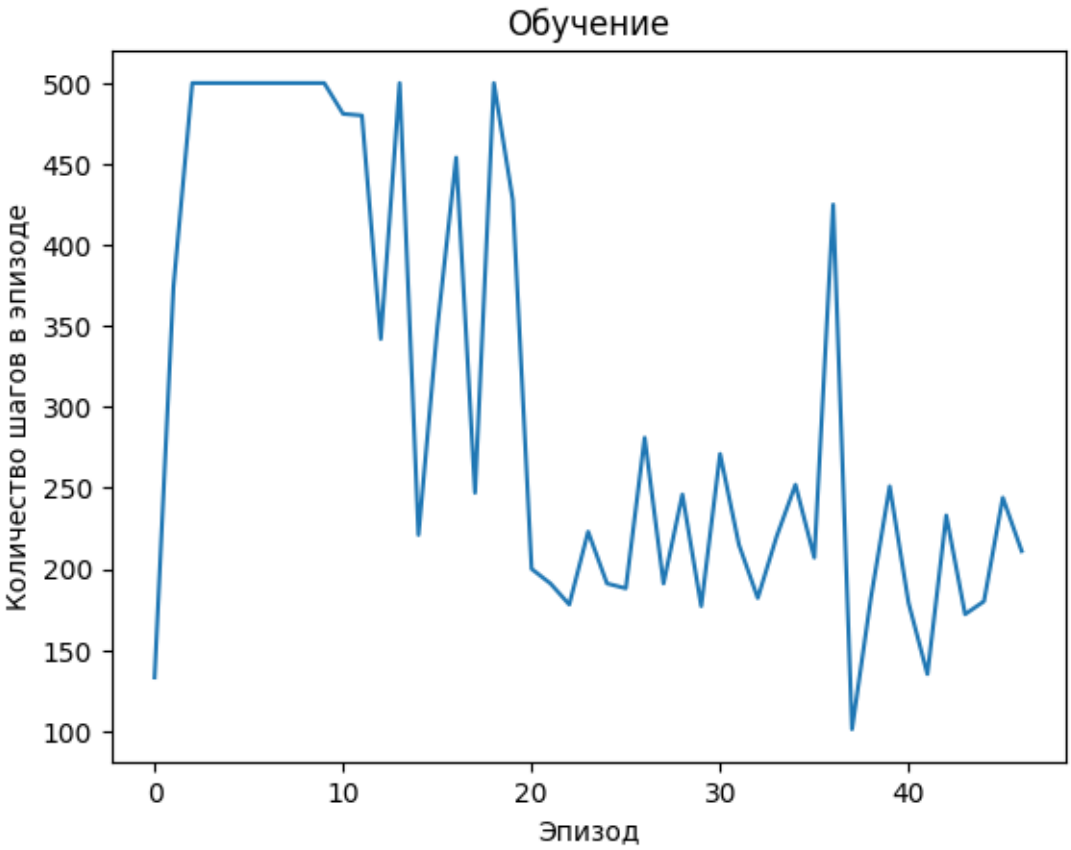
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
100
0
10
20
30
40

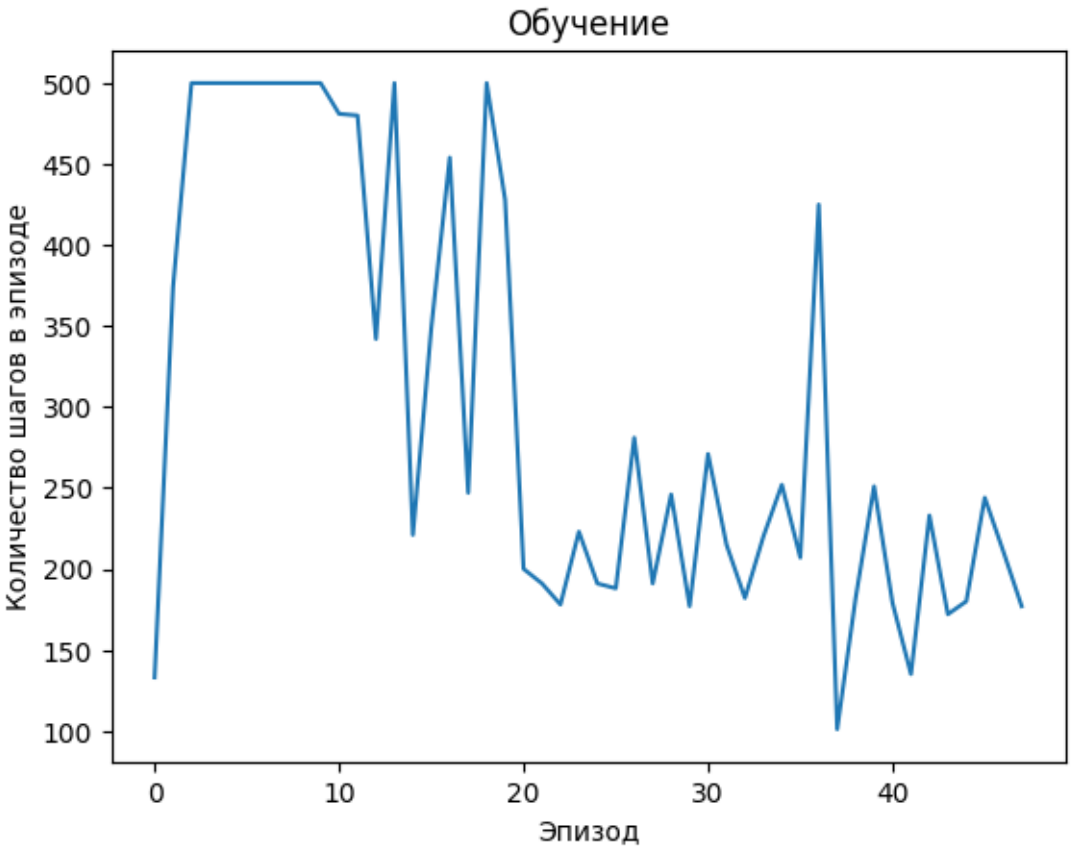
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
100
0
10
20
30
40

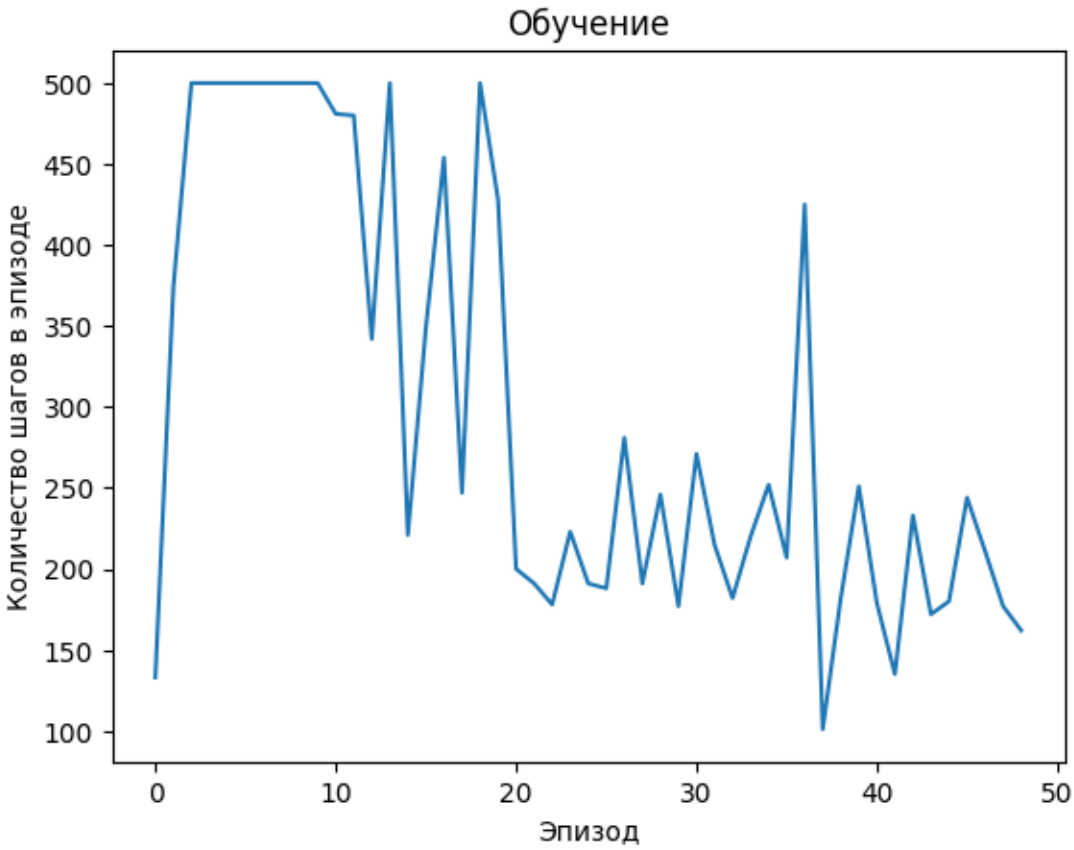
Обучение
Количество шагов в эпизоде
Эпизод
500
450
400
350
300
250
200
150
100
0
10
20
30
40
50

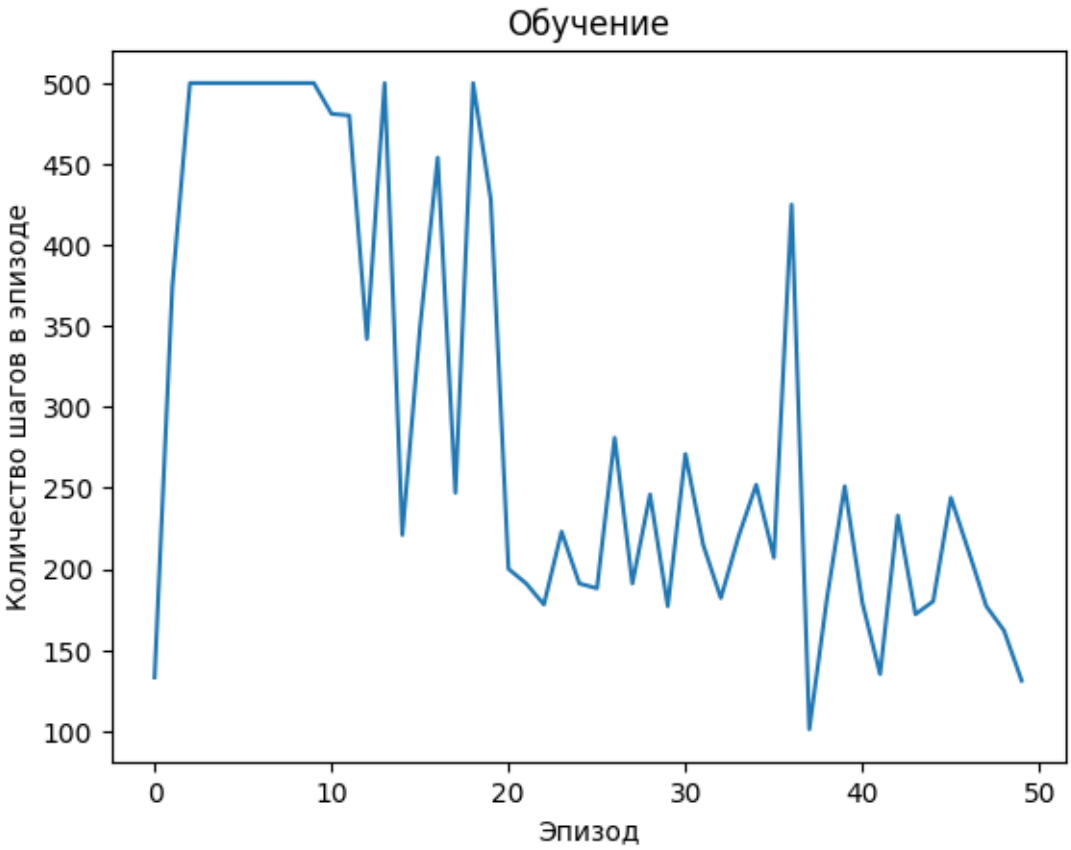


```
done!
          :  [(0, -1.0), (1, -1.0), (1, -1.0), (2, -1.0), (2, -1.0), (2,
-1.0), (2, -1.0), (2, -1.0), (0, -1.0), (0, -1.0), (0, -1.0), (0, -1.0), (2,
-1.0), (0, -1.0), (0, -1.0), (0, -1.0), (2, -1.0), (2, -1.0), (2, -1.0), (2,
-1.0), (0, -1.0), (0, -1.0), (1, -1.0), (0, -1.0), (2, -1.0), (1, -1.0), (2,
-1.0), (2, -1.0), (2, -1.0), (1, -1.0), (0, -1.0), (1, -1.0), (0, -1.0), (0,
-1.0), (0, -1.0), (0, -1.0), (0, -1.0), (1, -1.0), (2, -1.0), (2, -1.0), (1,
-1.0), (1, -1.0), (2, -1.0), (2, -1.0), (2, -1.0), (0, -1.0), (0, -1.0), (0,
-1.0), (1, -1.0), (1, -1.0), (1, -1.0), (2, -1.0), (0, -1.0), (0, -1.0), (2,
-1.0), (2, -1.0), (1, -1.0), (1, -1.0), (0, -1.0), (0, -1.0), (2, -1.0), (0,
-1.0), (2, -1.0), (2, -1.0), (2, -1.0), (2, -1.0), (2, -1.0), (0, -1.0), (2,
-1.0), (1, -1.0), (0, -1.0), (2, -1.0), (0, -1.0), (2, -1.0), (1, -1.0), (1,
-1.0), (2, -1.0), (2, -1.0), (2, -1.0), (2, -1.0), (2, -1.0), (2, -1.0), (0,
-1.0), (2, -1.0), (0, -1.0), (0, -1.0), (0, -1.0), (2, -1.0), (0, -1.0), (0,
-1.0), (1, -1.0), (2, -1.0), (2, -1.0), (2, -1.0), (2, -1.0), (0, -1.0), (1,
-1.0), (1, -1.0), (1, -1.0), (0, -1.0), (2, -1.0), (0, -1.0), (0, -1.0), (1,
-1.0), (2, -1.0), (2, -1.0), (1, -1.0), (2, -1.0), (2, -1.0), (2, -1.0), (1,
-1.0), (2, -1.0), (0, -1.0), (1, -1.0), (0, -1.0), (1, -1.0), (0, -1.0), (0,
-1.0), (1, -1.0), (0, -1.0), (2, -1.0), (2, -1.0), (2, -1.0), (2, -1.0), (0,
-1.0), (1, -1.0), (1, -1.0), (0, -1.0), (0, -1.0), (0, -1.0), (0, -1.0), (0,
```

-1.0), (2, -1.0), (0, -1.0), (1, -1.0), (2, -1.0), (0, -1.0), (2, -1.0), (2,
-1.0), (0, -1.0), (1, -1.0), (1, -1.0), (1, -1.0), (0, -1.0), (1, -1.0), (2,
-1.0), (0, -1.0), (0, -1.0), (1, -1.0), (1, -1.0), (2, -1.0), (0, -1.0), (2,
-1.0), (1, -1.0), (0, -1.0), (1, -1.0), (0, -1.0), (0, -1.0), (0, -1.0), (0,
-1.0), (1, -1.0), (0, -1.0), (0, -1.0), (2, -1.0), (1, -1.0), (0, -1.0), (2,
-1.0), (2, -1.0), (1, -1.0), (0, -1.0), (0, -1.0), (0, -1.0), (2, -1.0), (0,
-1.0), (1, -1.0), (2, -1.0), (2, -1.0), (2, -1.0), (2, -1.0), (2, -1.0), (1,
-1.0), (2, -1.0), (1, -1.0), (1, -1.0), (1, -1.0), (0, -1.0), (0, -1.0), (0,
-1.0), (0, -1.0), (0, -1.0), (2, -1.0), (1, -1.0), (2, -1.0), (1, -1.0), (2,
-1.0), (2, -1.0), (1, -1.0), (2, -1.0), (1, -1.0), (0, -1.0), (2, -1.0), (1,
-1.0), (2, -1.0), (2, -1.0), (0, -1.0), (2, -1.0), (0, -1.0), (0, -1.0), (2,
-1.0), (1, -1.0), (0, -1.0), (0, -1.0), (0, -1.0), (1, -1.0), (0, -1.0), (1,
-1.0), (1, -1.0), (0, -1.0), (1, -1.0), (2, -1.0), (2, -1.0), (2, -1.0), (2,
-1.0), (2, -1.0), (2, -1.0), (2, -1.0), (2, -1.0), (2, 0.0)]

Lab6

June 22, 2023

[ ]:
```
import gymnasium as gym
import math
import random
import matplotlib.pyplot as plt
from collections import namedtuple, deque
import torch
import torch.nn as nn
import torch.optim as optim
import torch.nn.functional as F
```

[ ]:
```
#
CONST_ENV_NAME = 'CartPole-v1'

#         GPU
CONST_DEVICE = torch.device('cuda' if torch.cuda.is_available() else 'cpu')

#      ReplayMemory
Transition = namedtuple('Transition', ('state', 'action', 'next_state',␣
 ↪'reward'))
```

0.0.1 Relay Memory

[ ]:
```
#            Replay Memory
class ReplayMemory(object):
  def __init__(self, capacity):
    self.memory = deque([], maxlen=capacity)

  def push(self, *args):
    '''
                ReplayMemory
    '''

    self.memory.append(Transition(*args))

  def sample(self, batch_size):
    '''
                          batch_size
    '''
```

```
    return random.sample(self.memory, batch_size)

  def __len__(self):
    return len(self.memory)
```

0.0.2 DQN Model

[ ]:
```
class DQN_Model(nn.Module):
  def __init__(self, n_observations, n_actions):
    '''

    '''

    super(DQN_Model, self).__init__()
    self.layer1 = nn.Linear(n_observations, 128)
    self.layer2 = nn.Linear(128, 64)
    self.layer3 = nn.Linear(64, n_actions)

  def forward(self, x):
    '''


                    ,
        batch
    '''

    x = F.relu(self.layer1(x))
    x = F.relu(self.layer2(x))
    return self.layer3(x)
```

0.0.3 DQN Agent

[ ]:
```
class DQN_Agent:
  def __init__(
    self,
    env,
    BATCH_SIZE = 128,
    GAMMA = 0.99,
    EPS_START = 0.1,
    EPS_END = 0.5,
    EPS_DECAY = 1000,
    TAU = 0.005,
    LR = 0.0001,
  ):
    #
    self.env = env
    #        Q-
```

```
    self.n_actions = env.action_space.n
    state, _ = self.env.reset()
    self.n_observations = len(state)
    #
    self.BATCH_SIZE = BATCH_SIZE
    self.GAMMA = GAMMA
    self.EPS_START = EPS_START
    self.EPS_END = EPS_END
    self.EPS_DECAY = EPS_DECAY
    self.TAU = TAU
    self.LR = LR

    #
    #
    self.policy_net = DQN_Model(self.n_observations, self.n_actions).
↪to(CONST_DEVICE)

    #              ,
    #                          TAU
    #             Double DQN
    self.target_net = DQN_Model(self.n_observations, self.n_actions).
↪to(CONST_DEVICE)
    self.target_net.load_state_dict(self.policy_net.state_dict())

    #
    self.optimizer = optim.AdamW(self.policy_net.parameters(), lr=self.LR,␣
↪amsgrad=True)

    # Replay Memory
    self.memory = ReplayMemory(10000)

    #
    self.steps_done = 0

    #
    self.episode_durations = []

 def select_action(self, state):
    '''

    '''

    sample = random.random()
    eps = self.EPS_END + (self.EPS_START - self.EPS_END) * math.exp(-1. * self.
↪steps_done / self.EPS_DECAY)
    self.steps_done += 1
    if sample > eps:
```

```
      with torch.no_grad():
        #                eps
        #               ,                  Q-
        # t.max(1)
        # [1]
        return self.policy_net(state).max(1)[1].view(1, 1)
    else:
      #               eps
      #
      return torch.tensor([[self.env.action_space.sample()]],␣
↪device=CONST_DEVICE, dtype=torch.long)

  def plot_durations(self, show_result=False):
    plt.figure(1)
    durations_t = torch.tensor(self.episode_durations, dtype=torch.float)
    if show_result:
      plt.title('     ')
    else:
      plt.clf()
      plt.title('     ')
      plt.xlabel('    ')
      plt.ylabel('                ')
      plt.plot(durations_t.numpy())
      plt.pause(0.001) #

  def optimize_model(self):
    '''

    '''

    if len(self.memory) < self.BATCH_SIZE:
      return

    transitions = self.memory.sample(self.BATCH_SIZE)
    #           batch'
    #        batch-       Transition
    #   Transition batch-     .
    batch = Transition(*zip(*transitions))

    #                                        batch'
    non_final_mask = torch.tensor(tuple(map(lambda s: s is not None, batch.
↪next_state)), device=CONST_DEVICE, dtype=torch.bool)
    non_final_next_states = torch.cat([s for s in batch.next_state if s is not␣
↪None])
    state_batch = torch.cat(batch.state)
    action_batch = torch.cat(batch.action)
    reward_batch = torch.cat(batch.reward)
```

```
    #       Q(s_t, a)
    state_action_values = self.policy_net(state_batch).gather(1, action_batch)

    #       V(s_{t+1})
    next_state_values = torch.zeros(self.BATCH_SIZE, device=CONST_DEVICE)

    with torch.no_grad():
      next_state_values[non_final_mask] = self.
↪target_net(non_final_next_states).max(1)[0]

    #                   Q
    expected_state_action_values = (next_state_values * self.GAMMA) +␣
↪reward_batch

    #       Huber loss
    criterion = nn.SmoothL1Loss()
    loss = criterion(state_action_values, expected_state_action_values.
↪unsqueeze(1))

    #
    self.optimizer.zero_grad()
    loss.backward()

    # gradient clipping
    torch.nn.utils.clip_grad_value_(self.policy_net.parameters(), 100)
    self.optimizer.step()

  def play_agent(self):
    '''

    '''

    env2 = gym.make(CONST_ENV_NAME, render_mode='human')
    state = env2.reset()[0]
    state = torch.tensor(state, dtype=torch.float32, device=CONST_DEVICE).
↪unsqueeze(0)
    res = []

    terminated = False
    truncated = False

    while not terminated and not truncated:
      action = self.select_action(state)
      action = action.item()
      observation, reward, terminated, truncated, _ = env2.step(action)
      env2.render()
```

```
    res.append((action, reward))

    state = torch.tensor(observation, dtype=torch.float32,␣
↪device=CONST_DEVICE).unsqueeze(0)

  print('done!')
  print('          : ', res)

def train(self):
  '''

  '''

  if torch.cuda.is_available():
    num_episodes = 600
  else:
    num_episodes = 50

  for i_episode in range(num_episodes):
    #
    state, info = self.env.reset()
    state = torch.tensor(state, dtype=torch.float32, device=CONST_DEVICE).
↪unsqueeze(0)

    terminated = False
    truncated = False

    iters = 0
    while not terminated and not truncated:
      action = self.select_action(state)
      observation, reward, terminated, truncated, _ = self.env.step(action.
↪item())
      reward = torch.tensor([reward], device=CONST_DEVICE)

      if terminated:
        next_state = None
      else:
        next_state = torch.tensor(observation, dtype=torch.float32,␣
↪device=CONST_DEVICE).unsqueeze(0)

      #             Replay Memory
      self.memory.push(state, action, next_state, reward)

      #
      state = next_state

      #
```

```
        self.optimize_model()

        #           target-
        #   ←    + (1 -   )
        target_net_state_dict = self.target_net.state_dict()
        policy_net_state_dict = self.policy_net.state_dict()

        for key in policy_net_state_dict:
          target_net_state_dict[key] = policy_net_state_dict[key] * self.TAU +␣
↪target_net_state_dict[key] * (1 - self.TAU)

        self.target_net.load_state_dict(target_net_state_dict)
        iters += 1

      self.episode_durations.append(iters)
      self.plot_durations()
```

[ ]:
```
env = gym.make(CONST_ENV_NAME)
agent = DQN_Agent(env)
agent.train()
agent.play_agent()
```

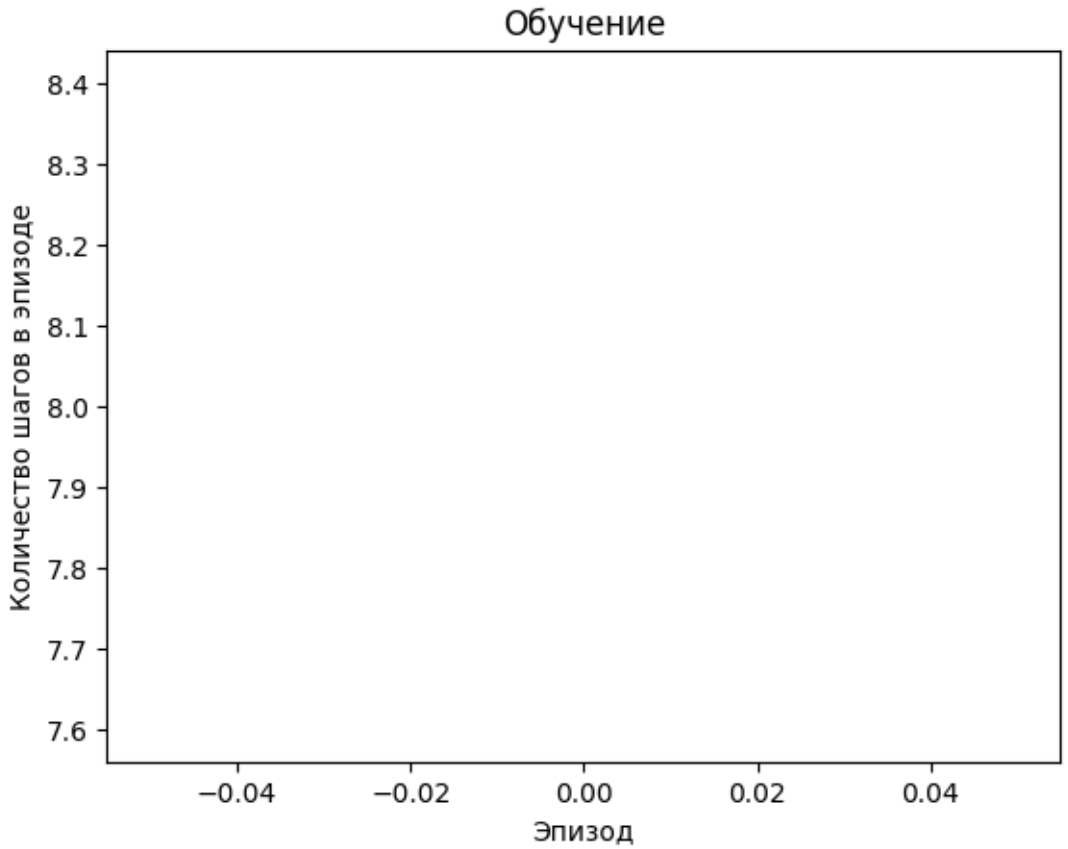

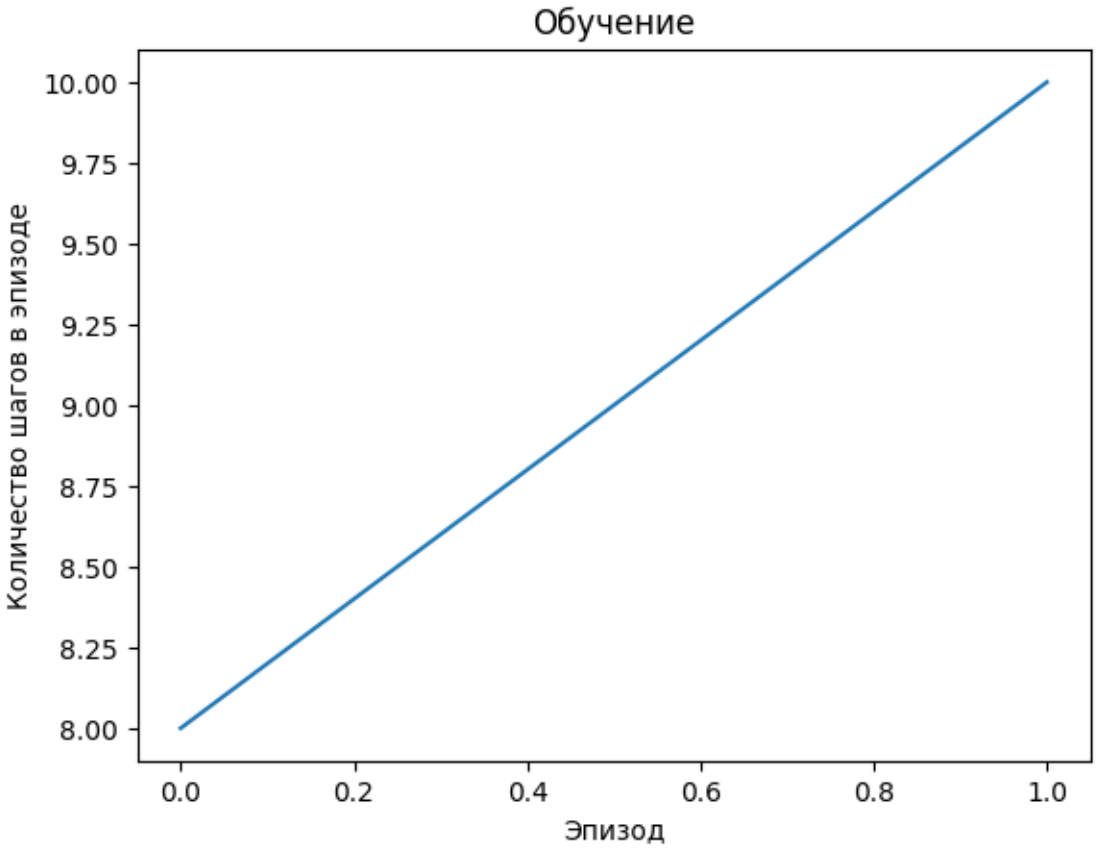
Обучение
Количество шагов в эпизоде
10.00
9.75
9.50
9.25
9.00
8.75
8.50
8.25
8.00
0.0
0.2
0.4
0.6
0.8
1.0
Эпизод

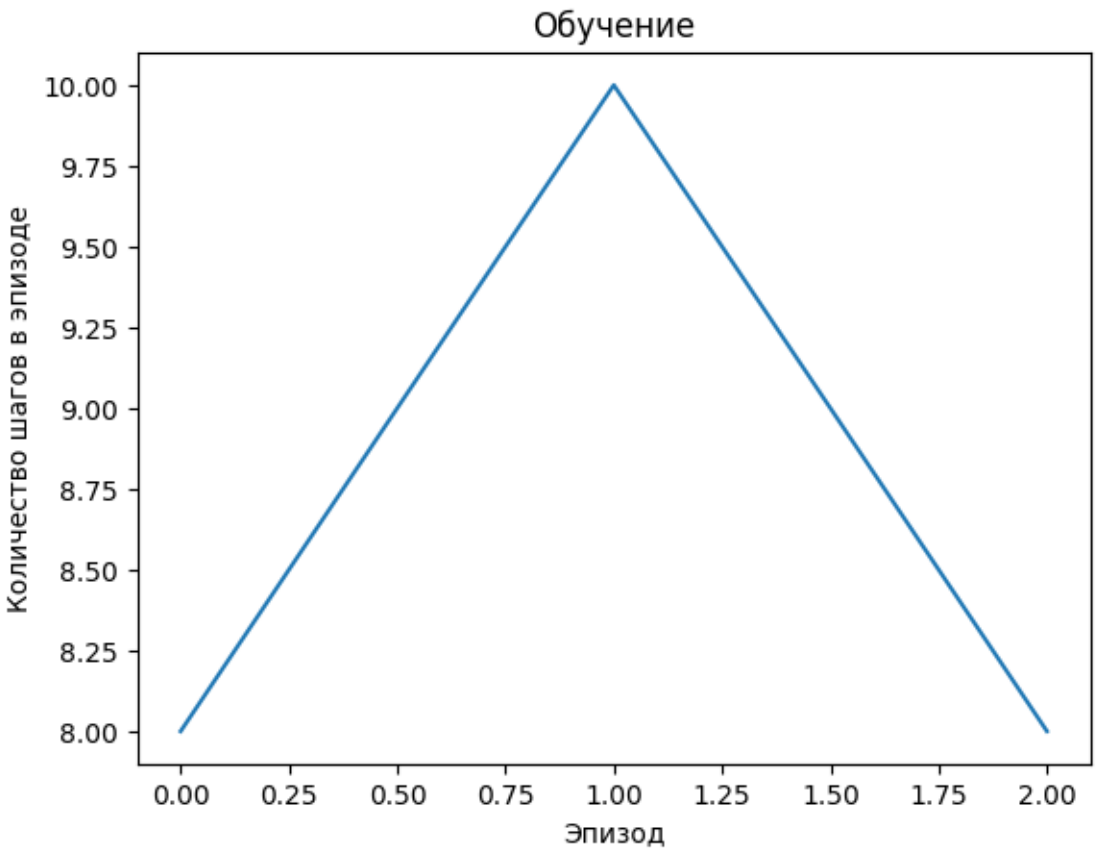
Обучение
Количество шагов в эпизоде
10.00
9.75
9.50
9.25
9.00
8.75
8.50
8.25
8.00
0.00
0.25
0.50
0.75
1.00
1.25
1.50
1.75
2.00
Эпизод

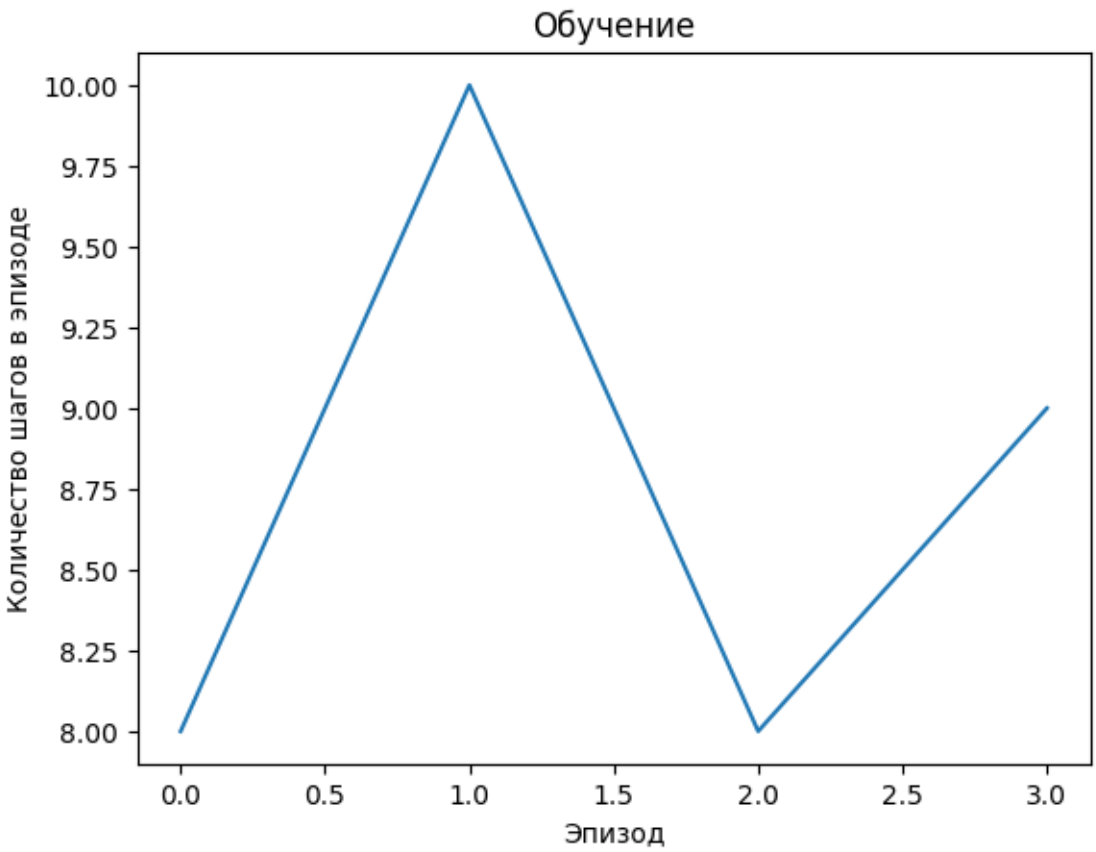
Обучение
Количество шагов в эпизоде
10.00
9.75
9.50
9.25
9.00
8.75
8.50
8.25
8.00
0.0
0.5
1.0
1.5
2.0
2.5
3.0
Эпизод

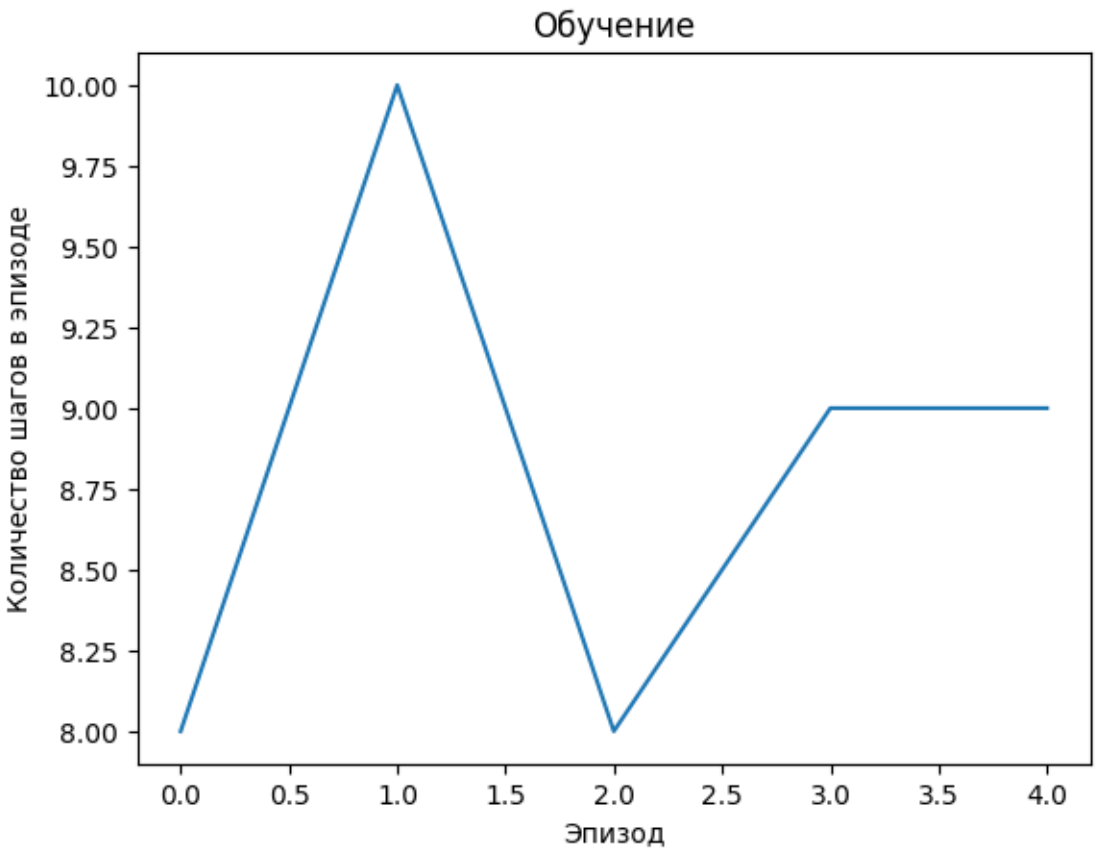
Обучение
Количество шагов в эпизоде
10.00
9.75
9.50
9.25
9.00
8.75
8.50
8.25
8.00
0.0
0.5
1.0
1.5
2.0
2.5
3.0
3.5
4.0
Эпизод

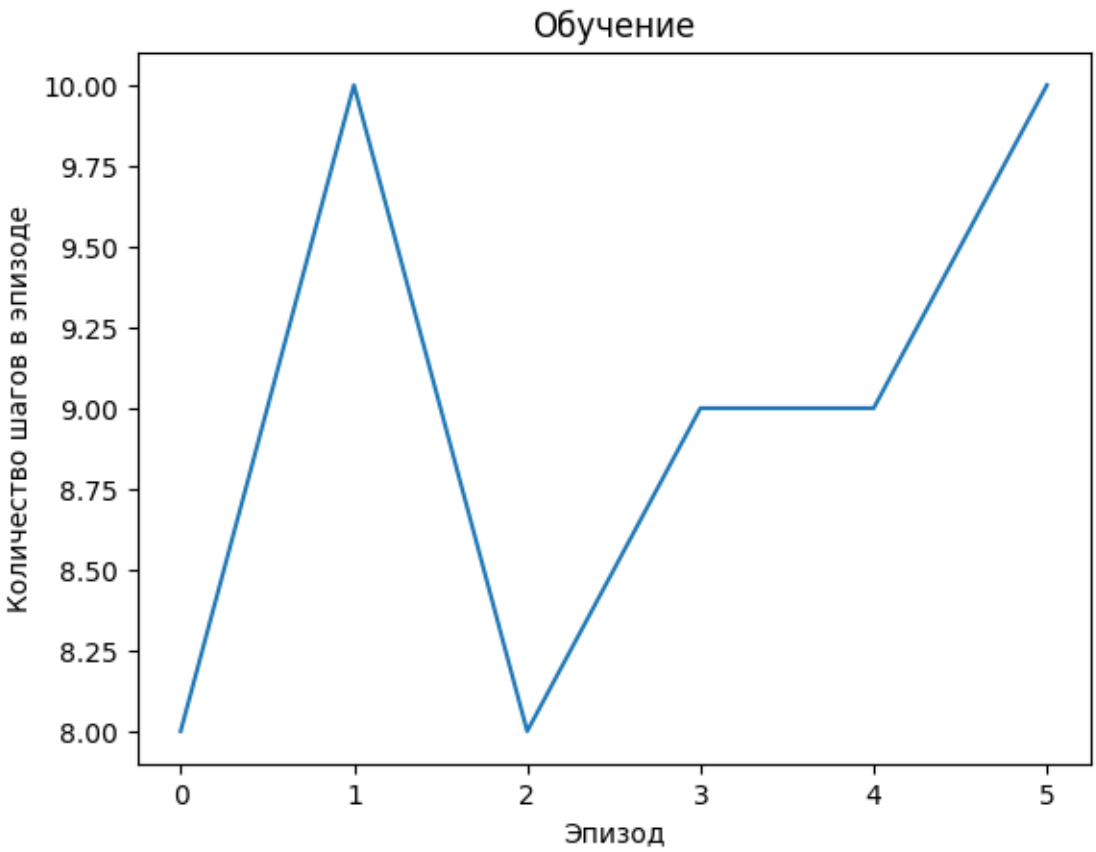
Обучение
Количество шагов в эпизоде
10.00
9.75
9.50
9.25
9.00
8.75
8.50
8.25
8.00
0
1
2
3
4
5
Эпизод

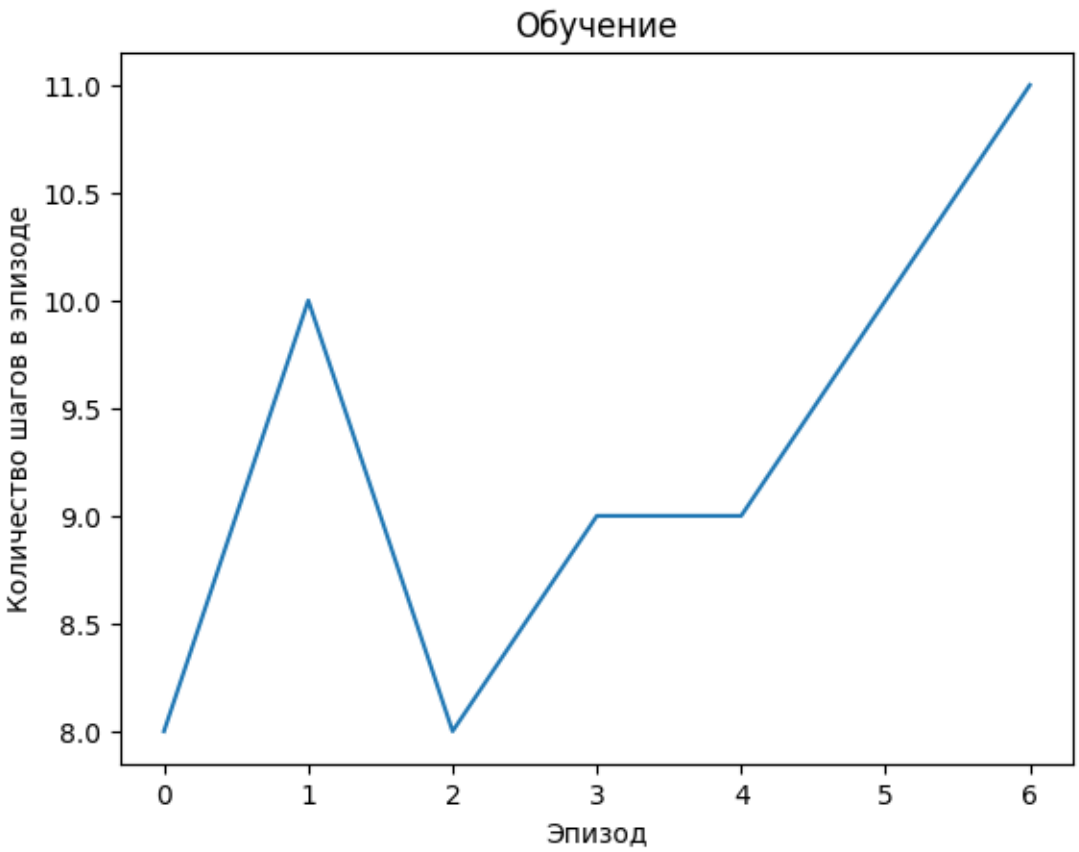
Обучение
Количество шагов в эпизоде
11.0
10.5
10.0
9.5
9.0
8.5
8.0
0
1
2
3
4
5
6
Эпизод

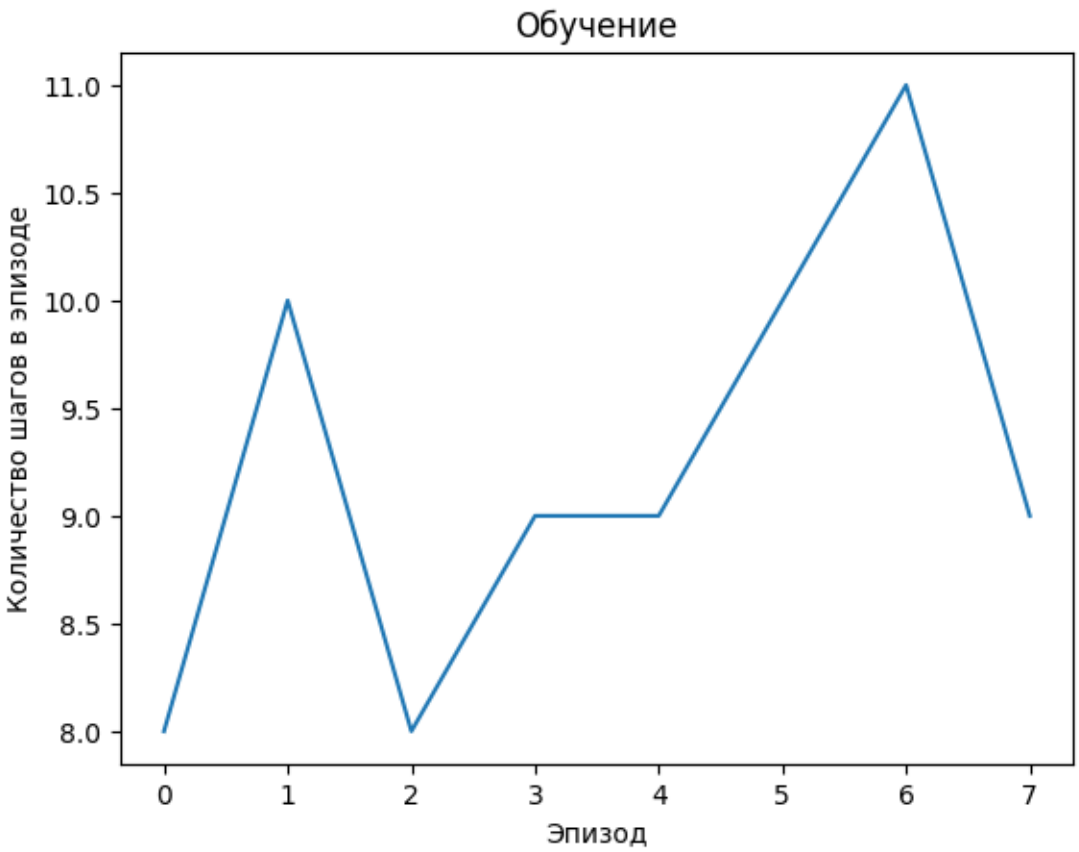
Обучение
Количество шагов в эпизоде
11.0
10.5
10.0
9.5
9.0
8.5
8.0
0
1
2
3
4
5
6
7
Эпизод

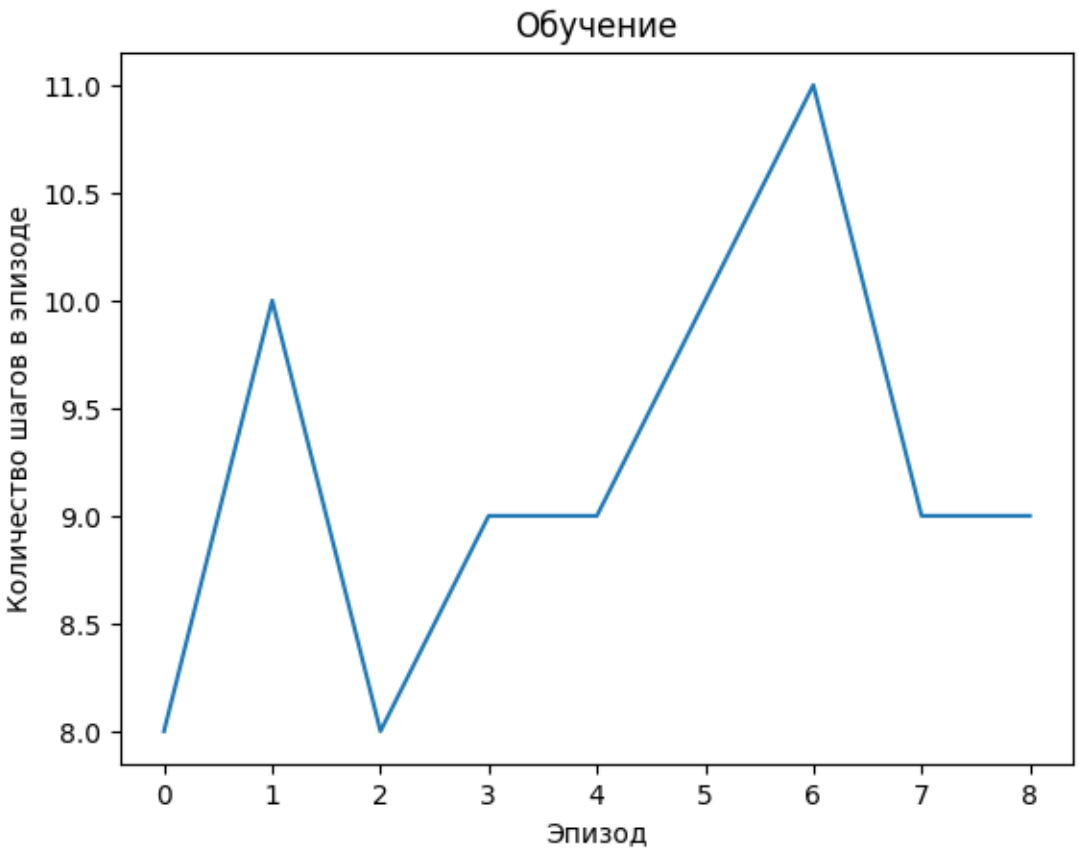
Обучение
Количество шагов в эпизоде
11.0
10.5
10.0
9.5
9.0
8.5
8.0
0
1
2
3
4
5
6
7
8
Эпизод

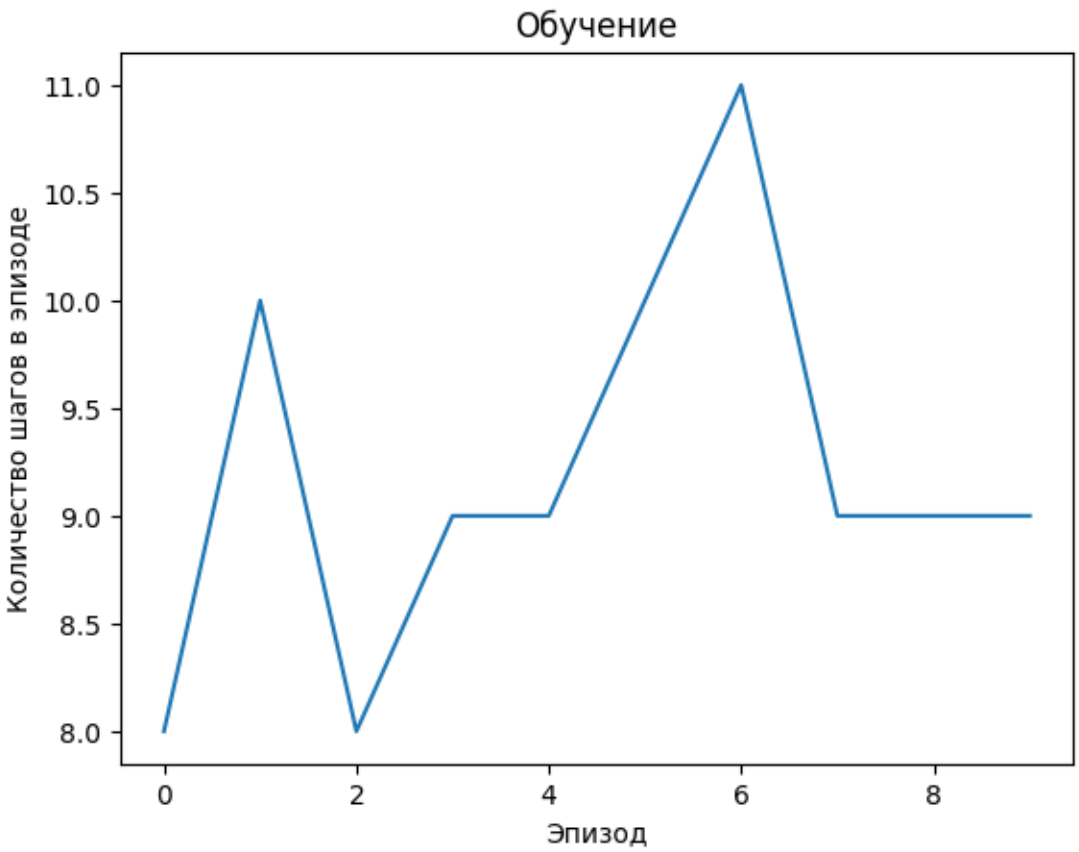
Обучение
Количество шагов в эпизоде
11.0
10.5
10.0
9.5
9.0
8.5
8.0
0
2
4
6
8
Эпизод

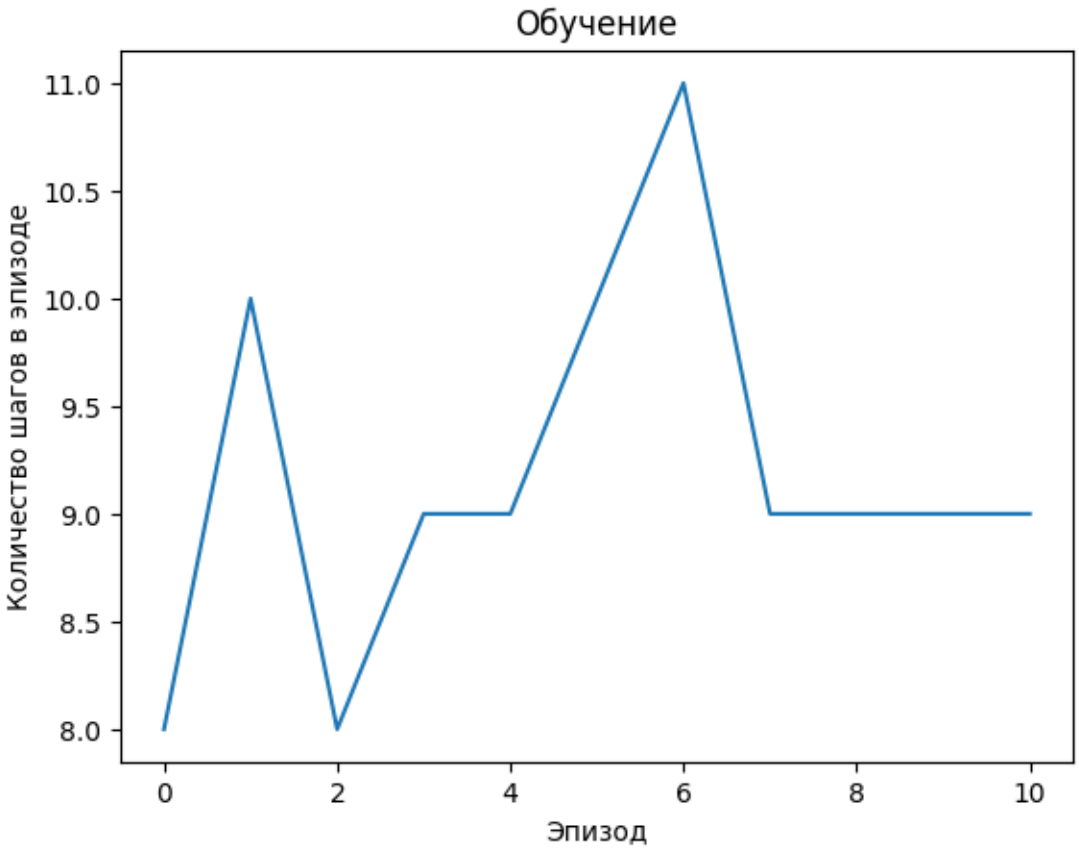
Обучение
Количество шагов в эпизоде
11.0
10.5
10.0
9.5
9.0
8.5
8.0
0
2
4
6
8
10
Эпизод

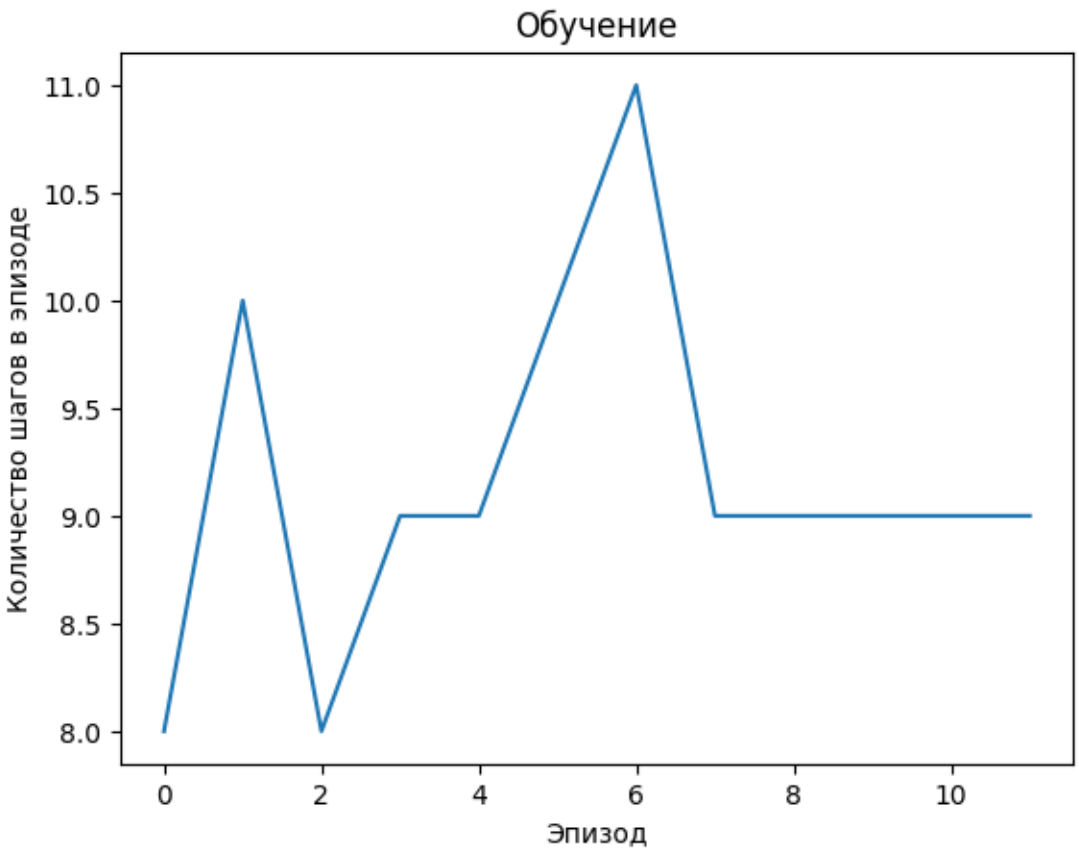
Обучение
Количество шагов в эпизоде
Эпизод
11.0
10.5
10.0
9.5
9.0
8.5
8.0
0
2
4
6
8
10

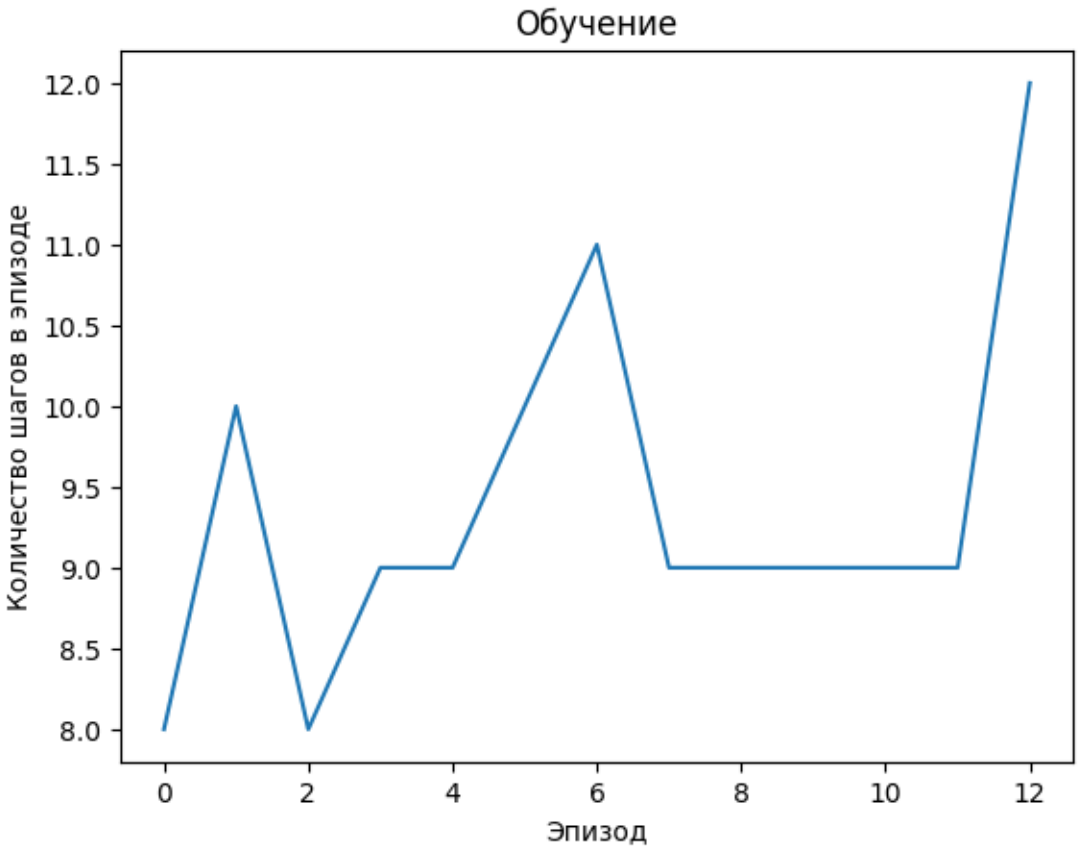
Обучение
Количество шагов в эпизоде
Эпизод
12.0
11.5
11.0
10.5
10.0
9.5
9.0
8.5
8.0
0
2
4
6
8
10
12

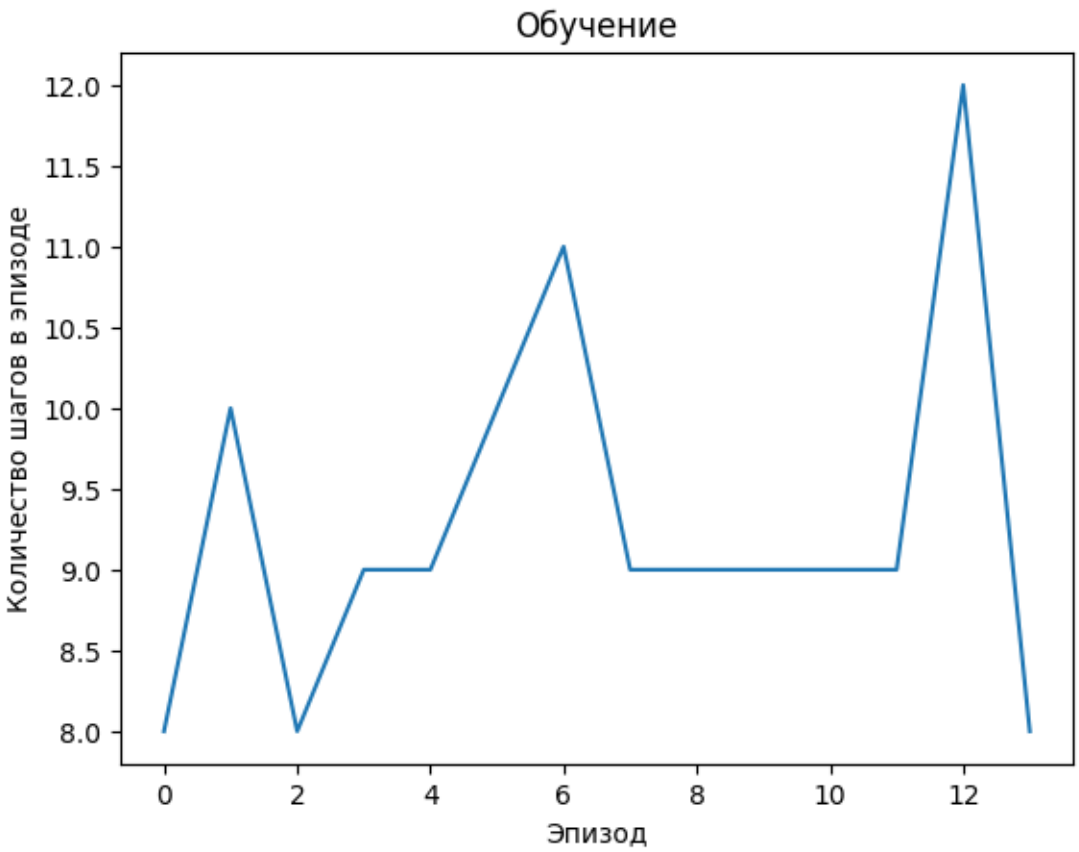
Обучение
Количество шагов в эпизоде
Эпизод
12.0
11.5
11.0
10.5
10.0
9.5
9.0
8.5
8.0
0
2
4
6
8
10
12

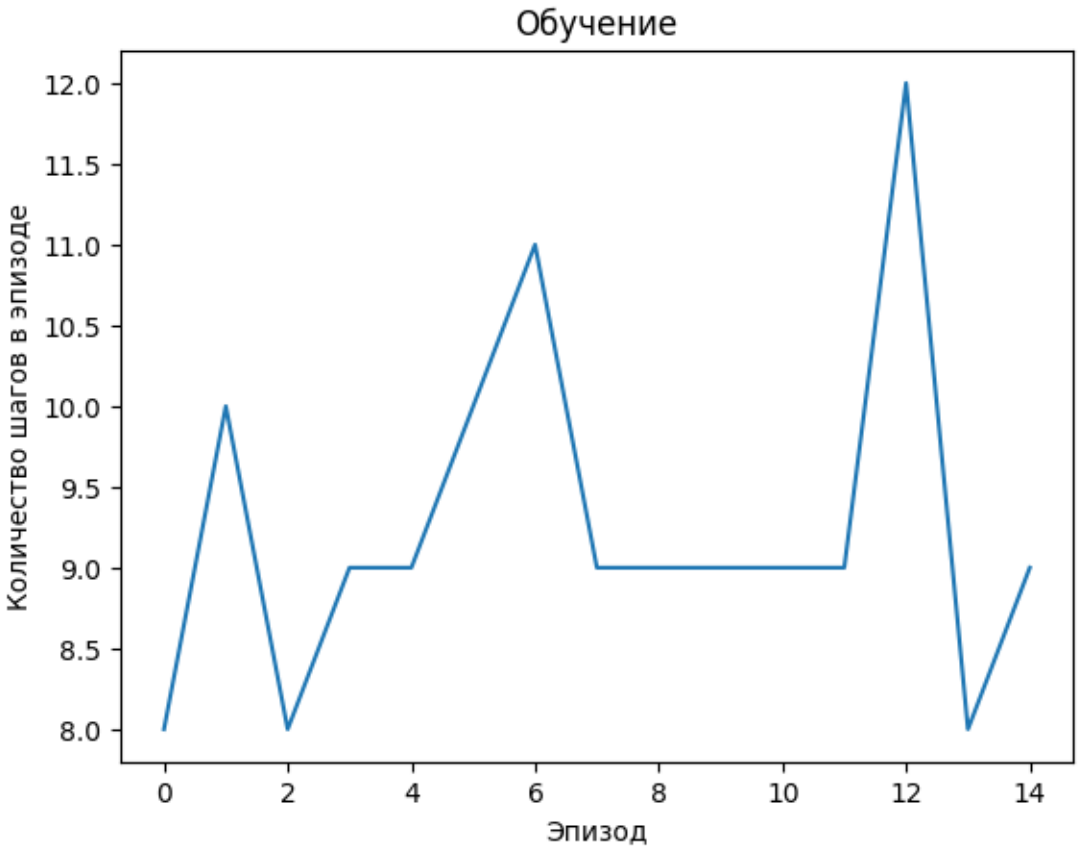
Обучение
Количество шагов в эпизоде
Эпизод
12.0
11.5
11.0
10.5
10.0
9.5
9.0
8.5
8.0
0
2
4
6
8
10
12
14

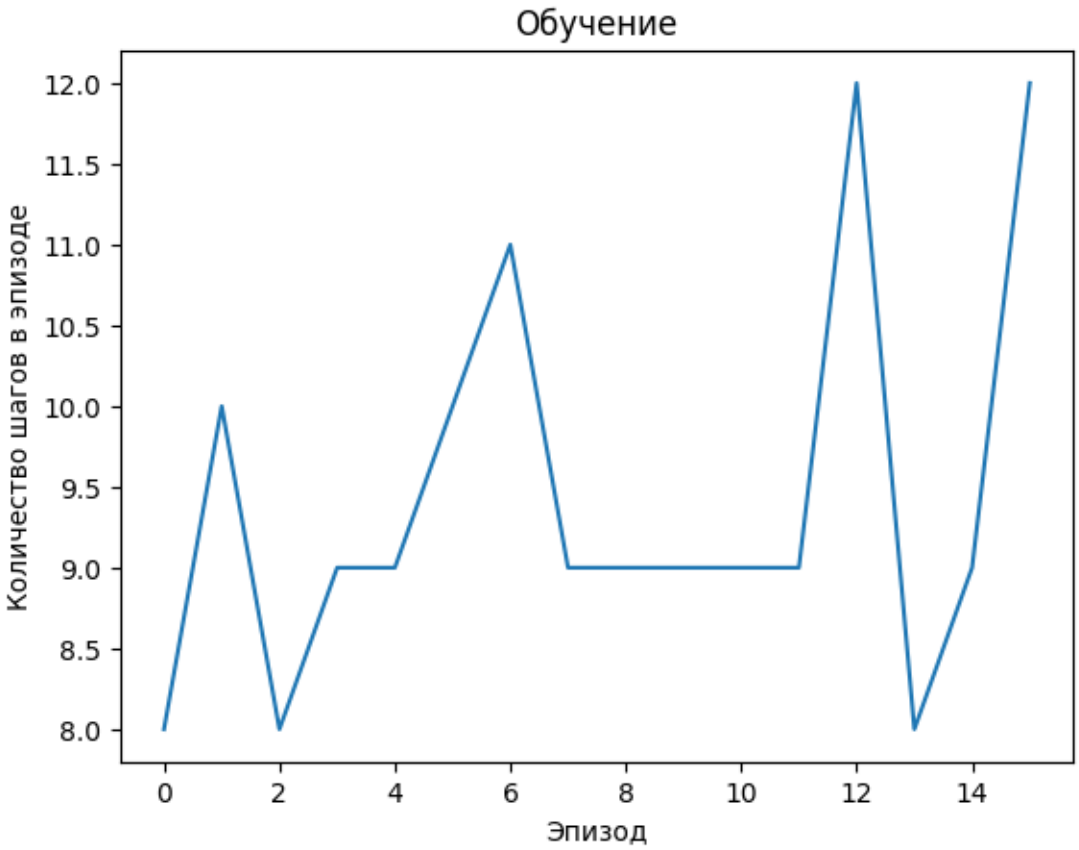
Обучение
Количество шагов в эпизоде
Эпизод
12.0
11.5
11.0
10.5
10.0
9.5
9.0
8.5
8.0
0
2
4
6
8
10
12
14

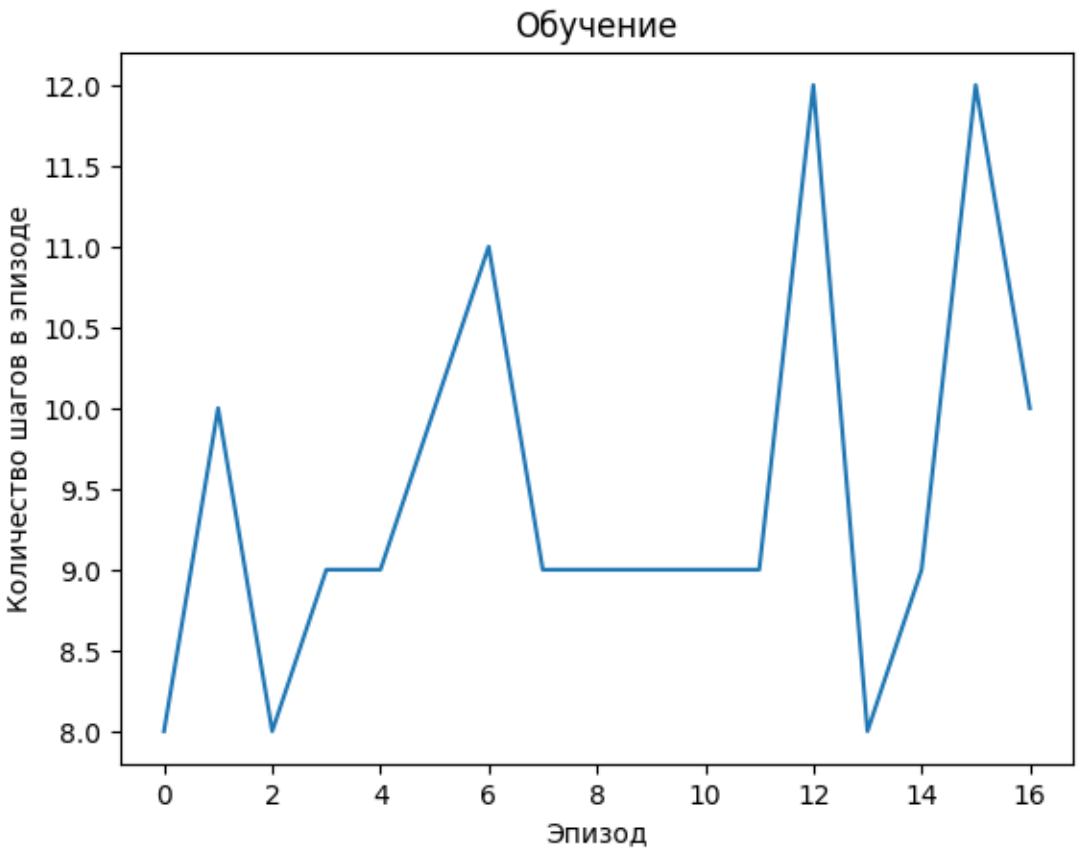
Обучение
Количество шагов в эпизоде
Эпизод
12.0
11.5
11.0
10.5
10.0
9.5
9.0
8.5
8.0
0
2
4
6
8
10
12
14
16

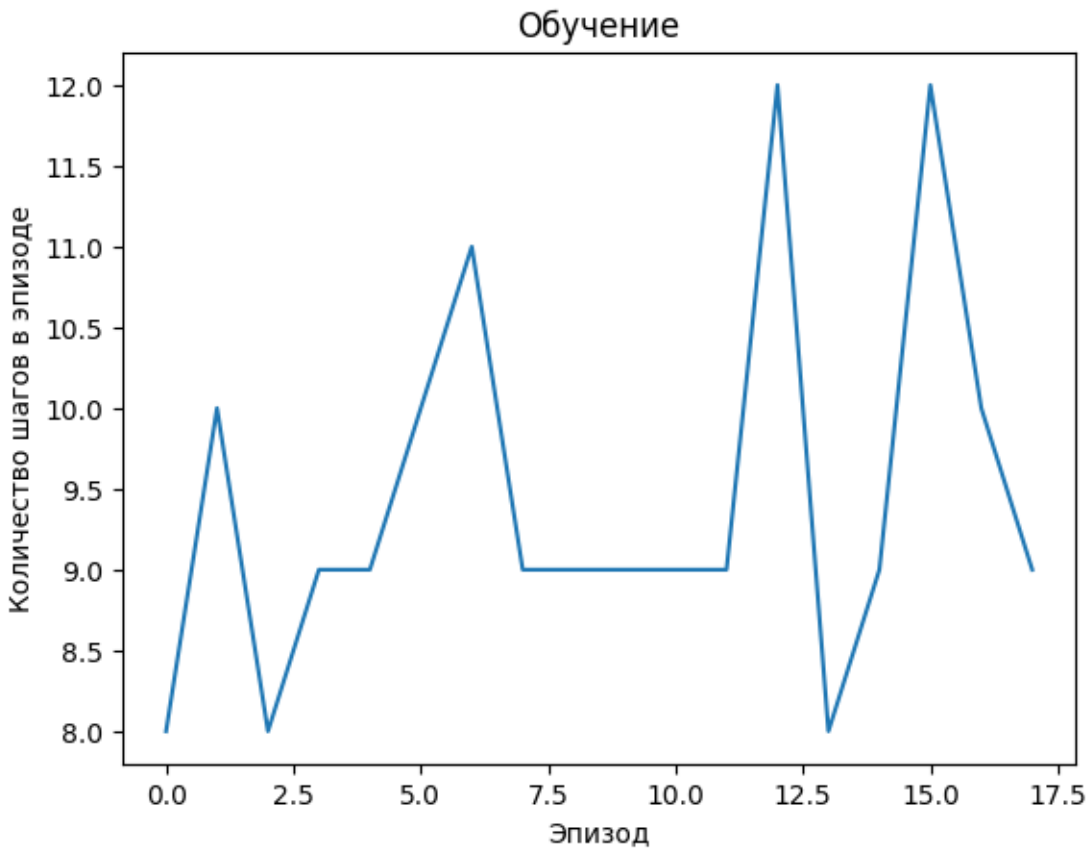
Обучение
Количество шагов в эпизоде
12.0
11.5
11.0
10.5
10.0
9.5
9.0
8.5
8.0
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5
Эпизод

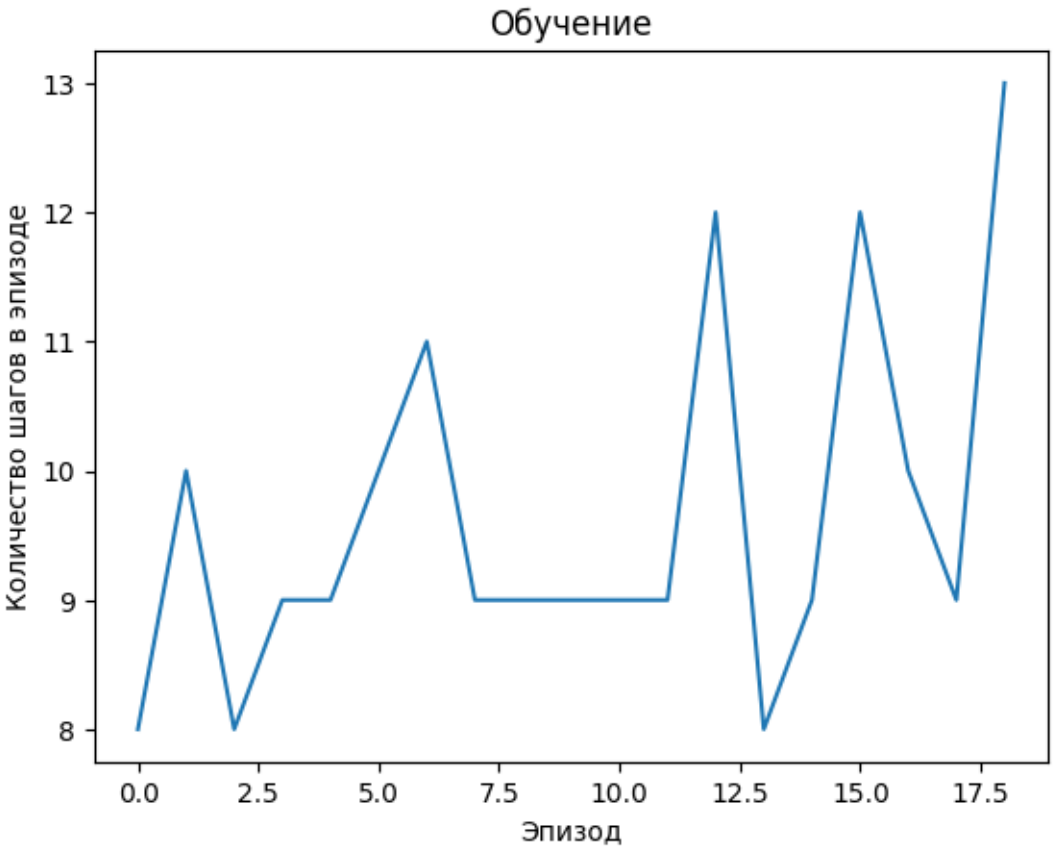
Обучение
Количество шагов в эпизоде
Эпизод
13
12
11
10
9
8
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5

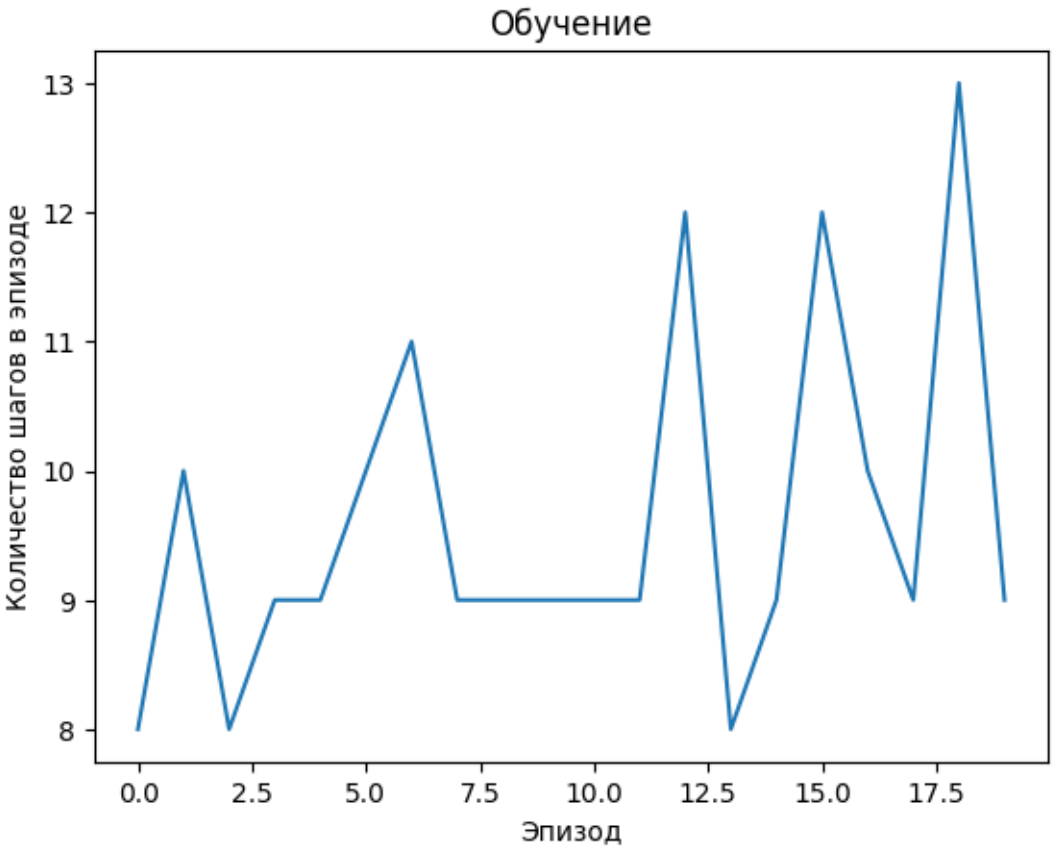
Обучение
Количество шагов в эпизоде
13
12
11
10
9
8
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5
Эпизод

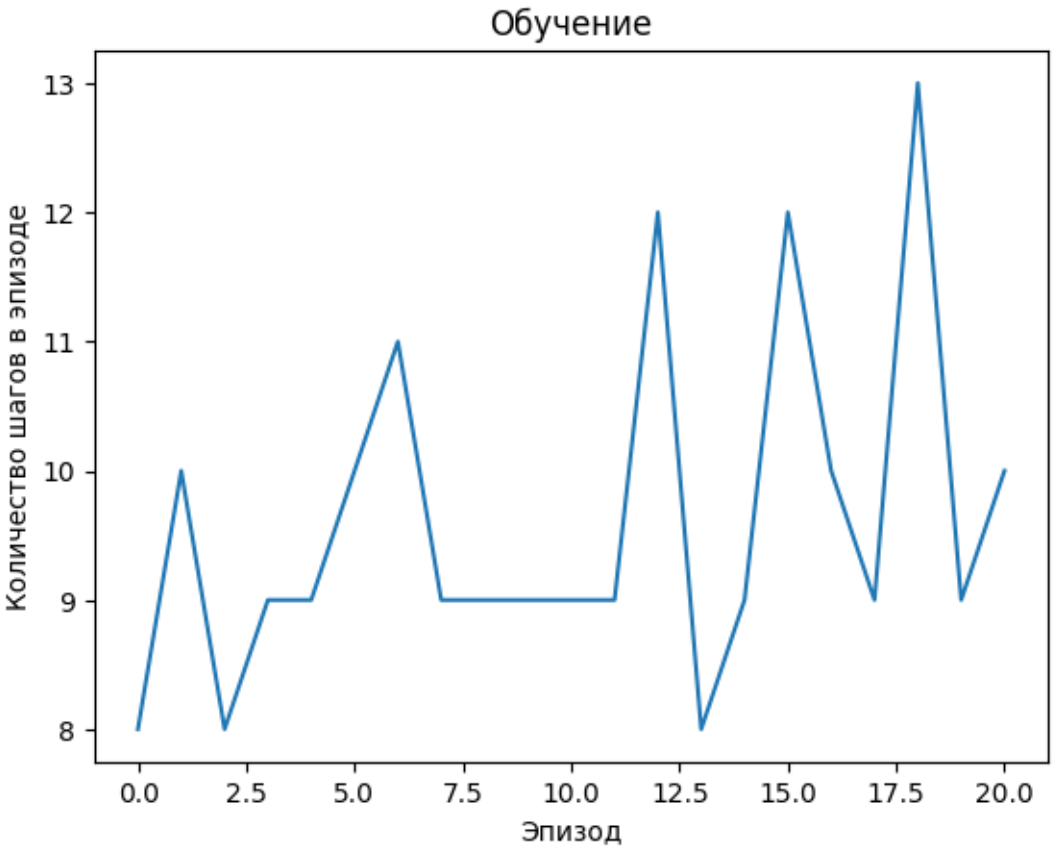
Обучение
Количество шагов в эпизоде
Эпизод
13
12
11
10
9
8
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5
20.0

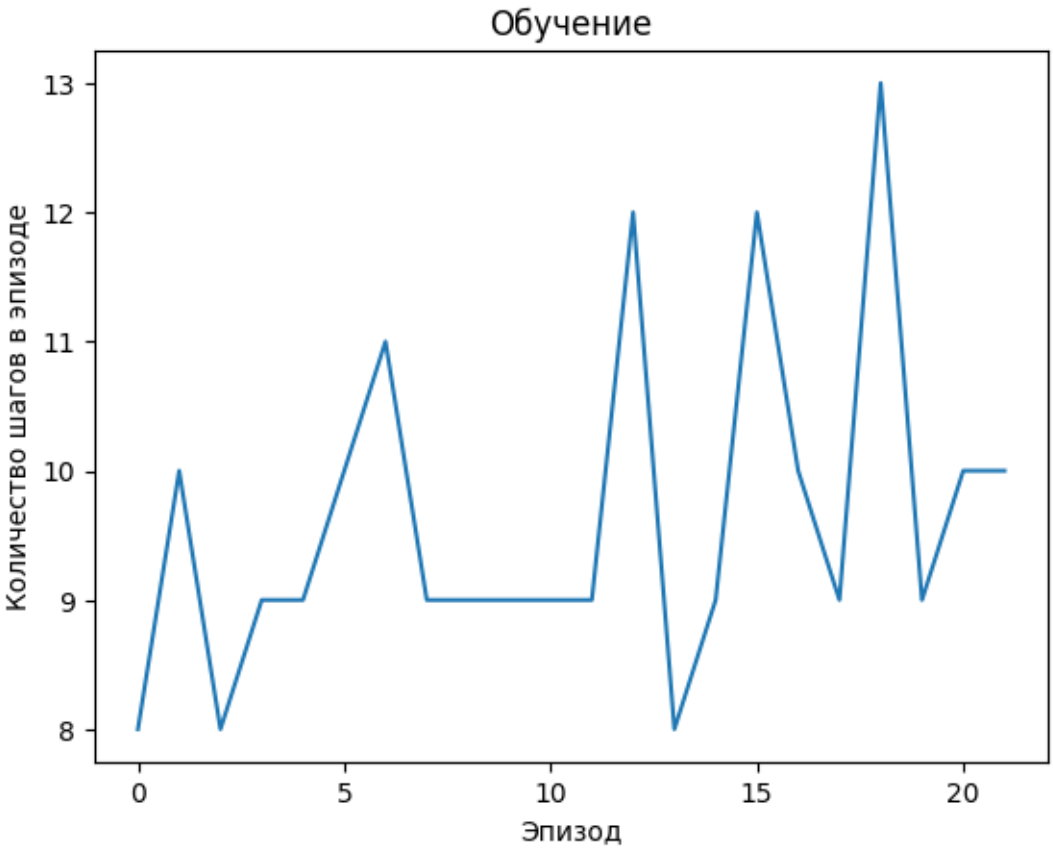
Обучение
Количество шагов в эпизоде
Эпизод
13
12
11
10
9
8
0
5
10
15
20

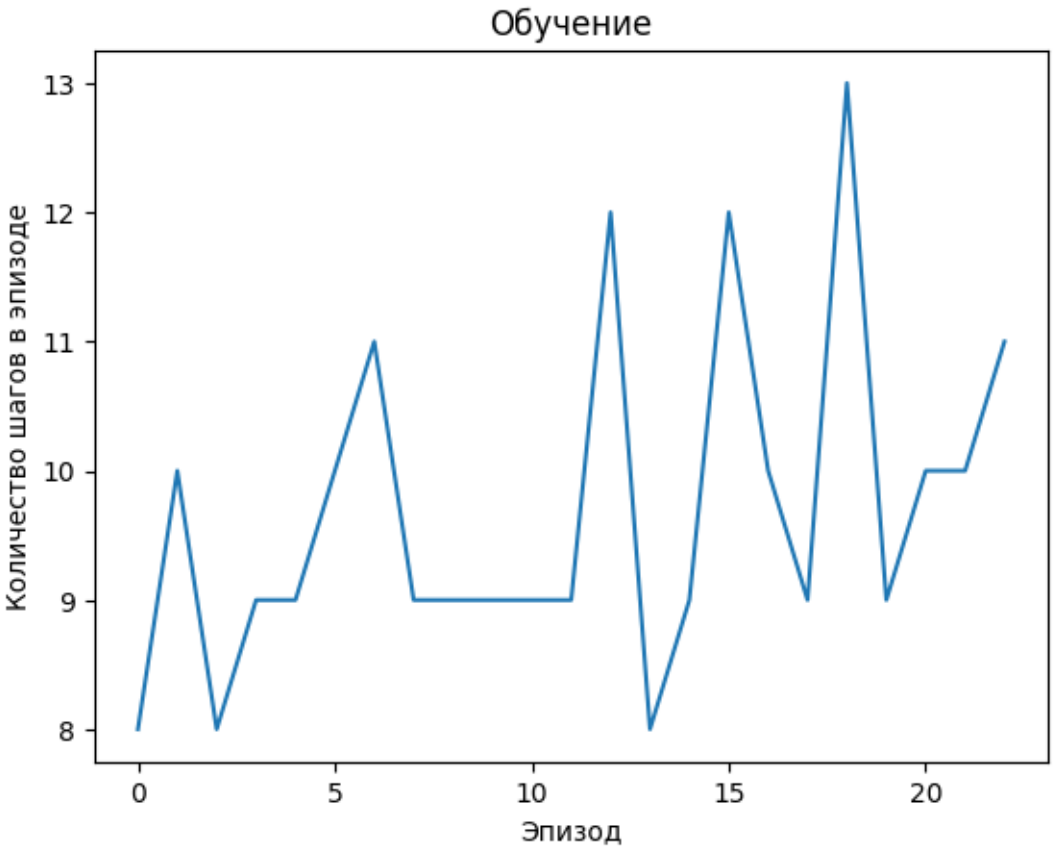
Обучение
Количество шагов в эпизоде
Эпизод
13
12
11
10
9
8
0
5
10
15
20

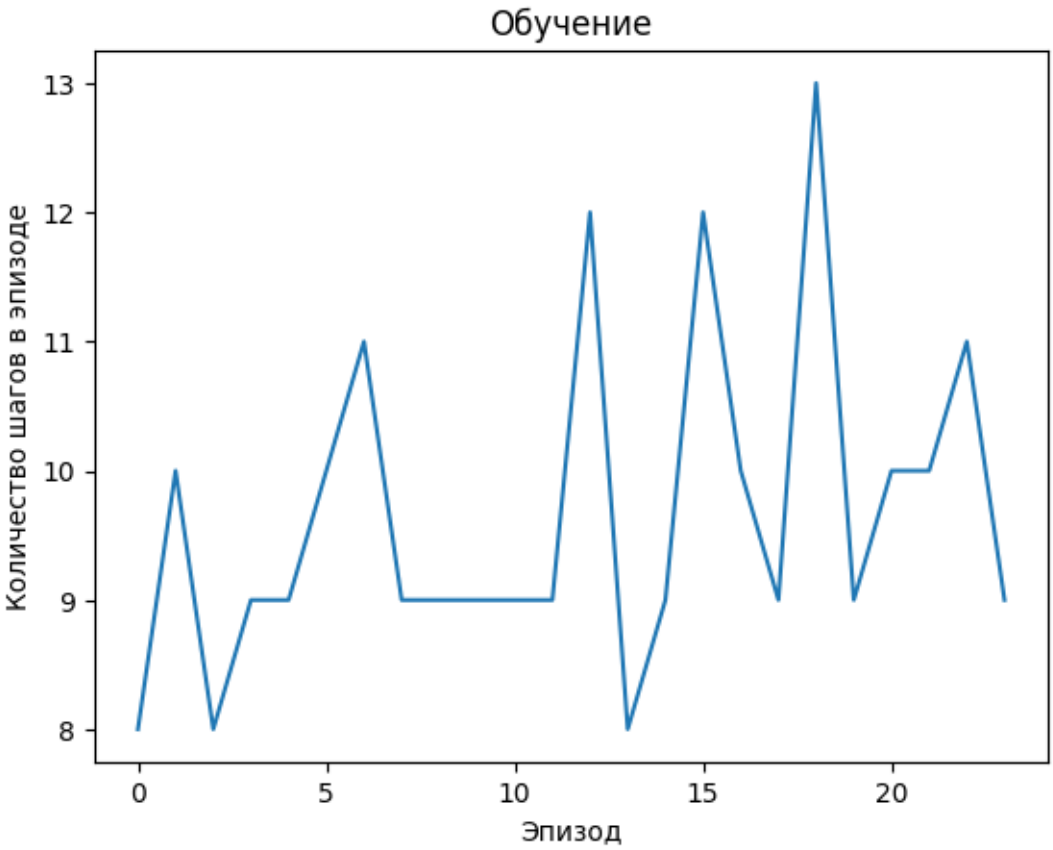
Обучение
Количество шагов в эпизоде
Эпизод
13
12
11
10
9
8
0
5
10
15
20

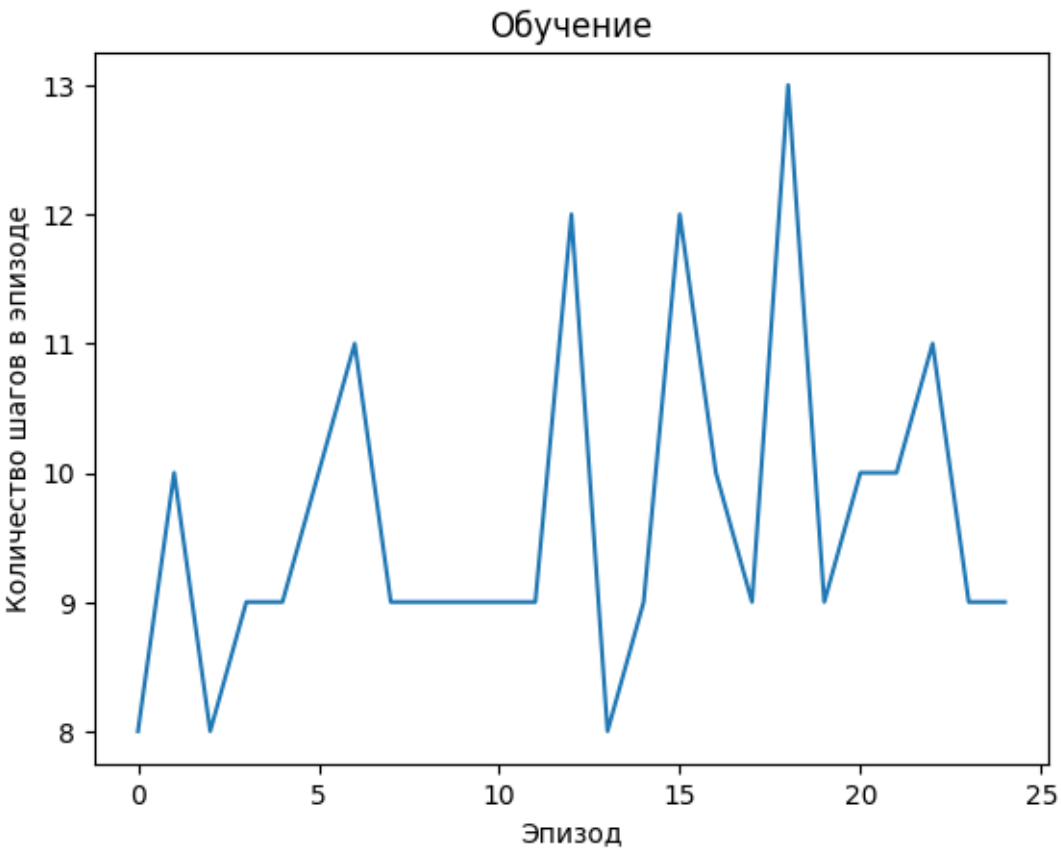
Обучение
Количество шагов в эпизоде
Эпизод
13
12
11
10
9
8
0
5
10
15
20
25

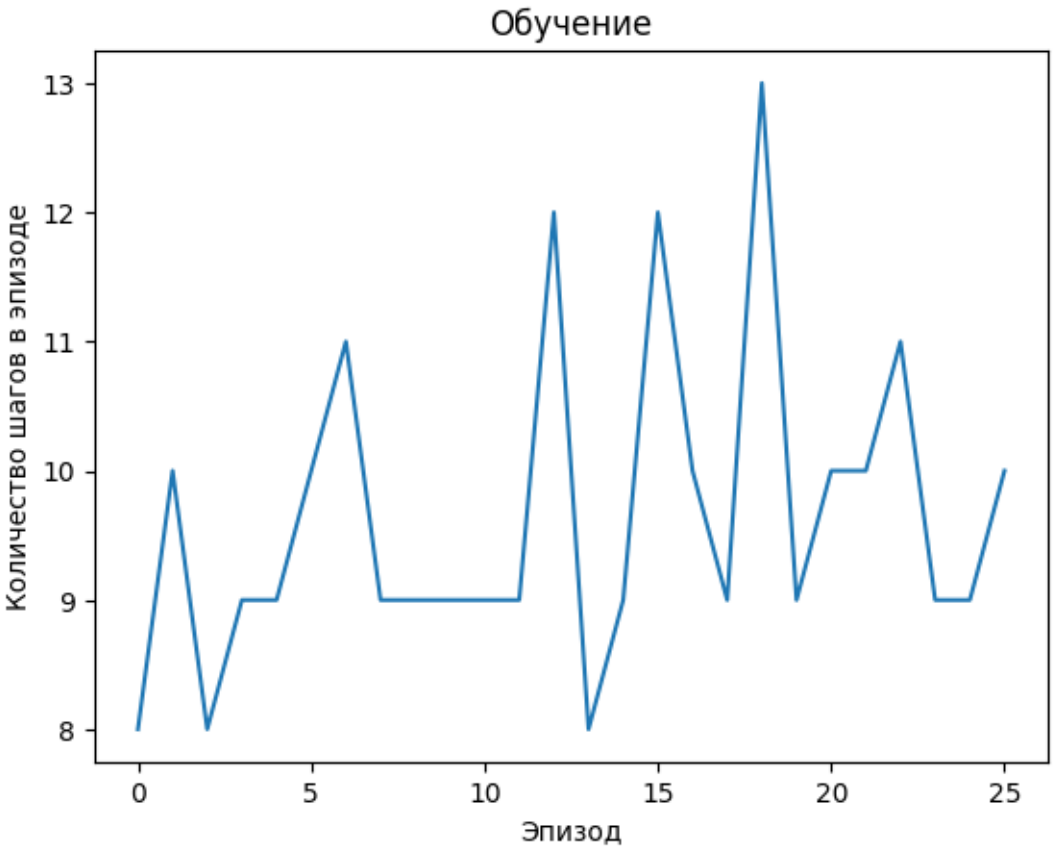
Обучение
Количество шагов в эпизоде
Эпизод
13
12
11
10
9
8
0
5
10
15
20
25

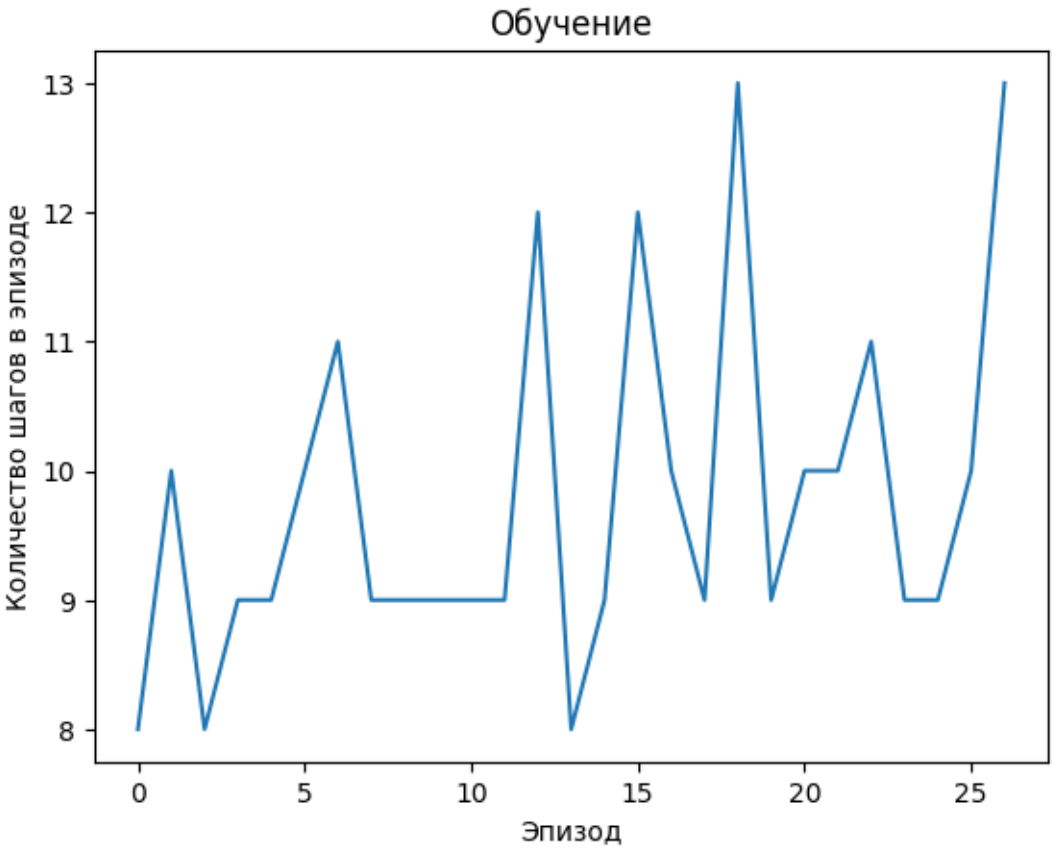
Обучение
Количество шагов в эпизоде
Эпизод
13
12
11
10
9
8
0
5
10
15
20
25

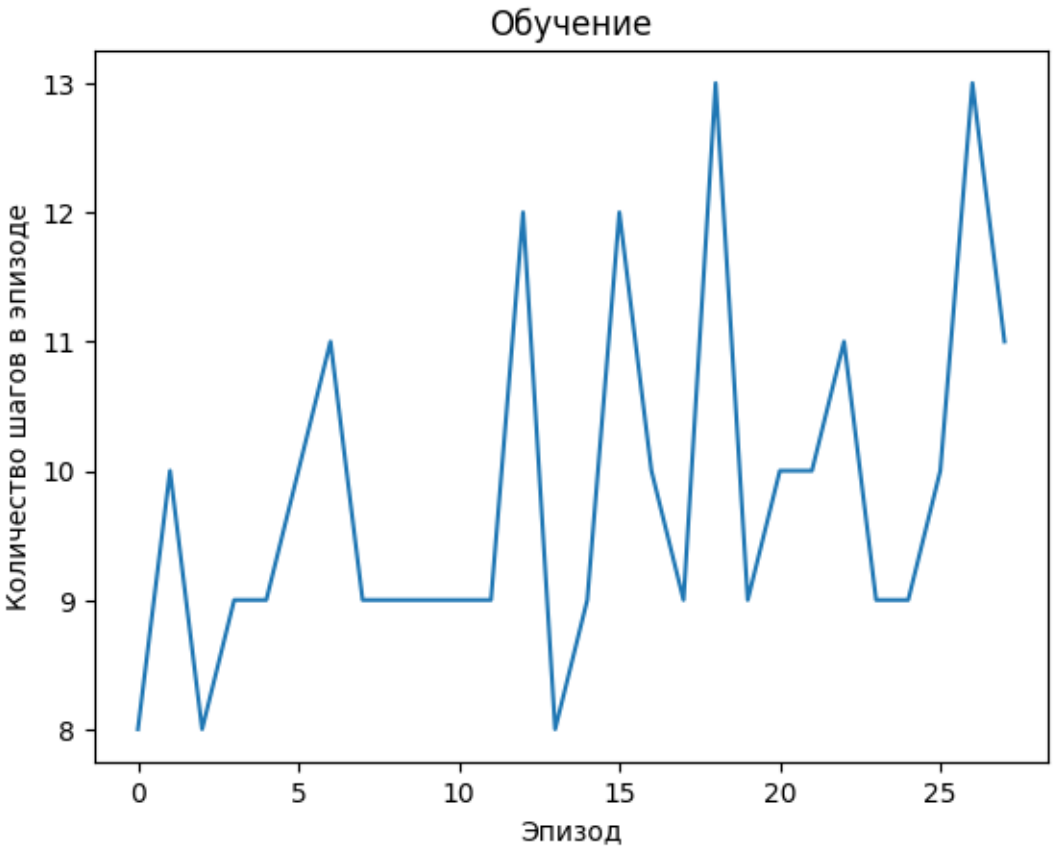
Обучение
Количество шагов в эпизоде
Эпизод
13
12
11
10
9
8
0
5
10
15
20
25

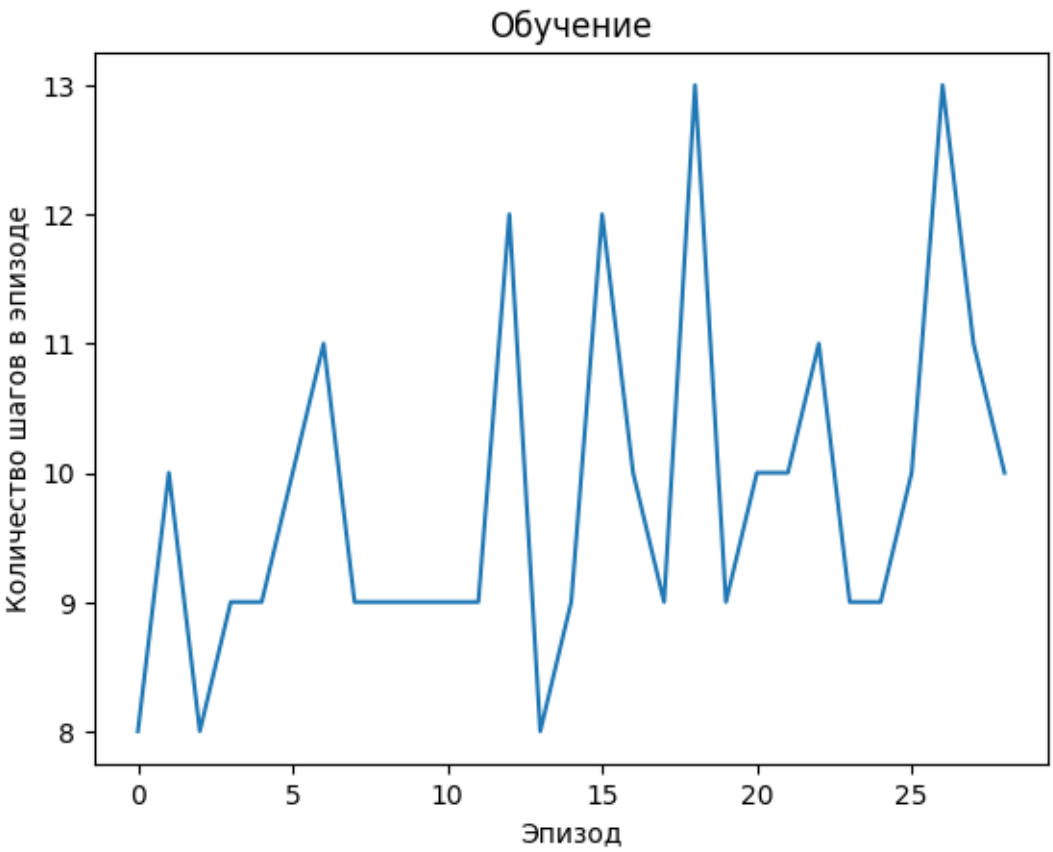
Обучение
Количество шагов в эпизоде
Эпизод
13
12
11
10
9
8
0
5
10
15
20
25

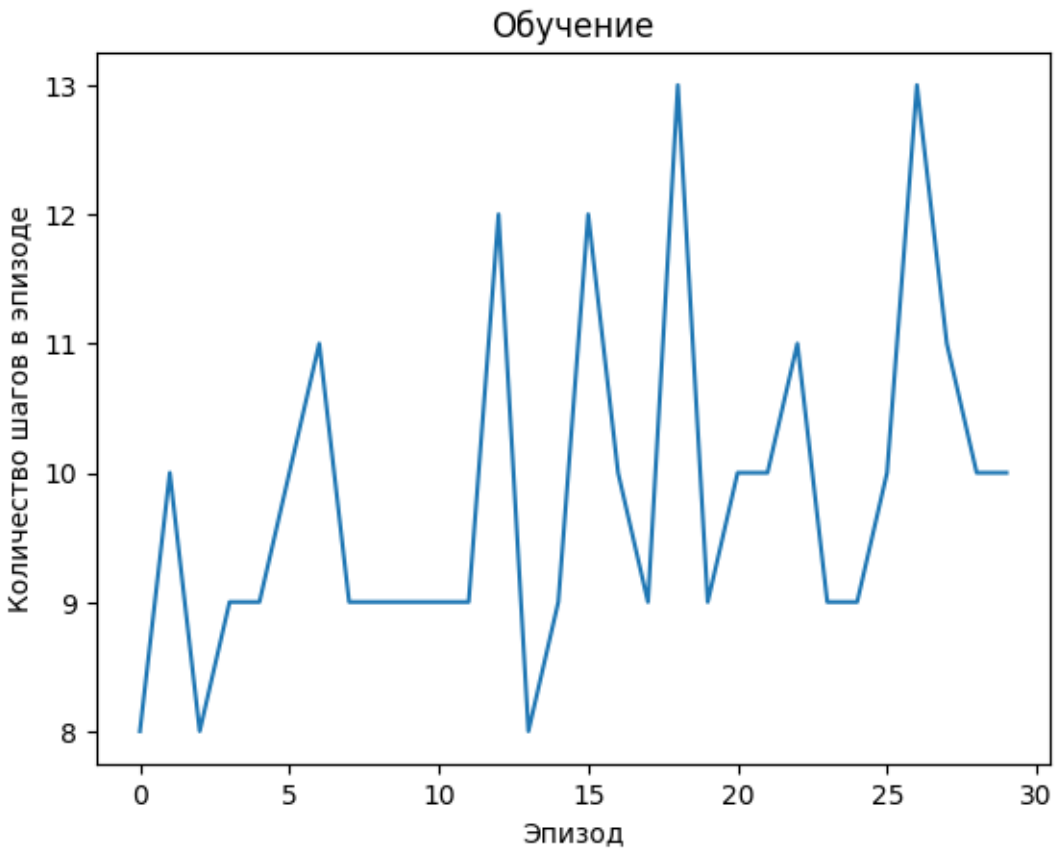
Обучение
Количество шагов в эпизоде
Эпизод
13
12
11
10
9
8
0
5
10
15
20
25
30

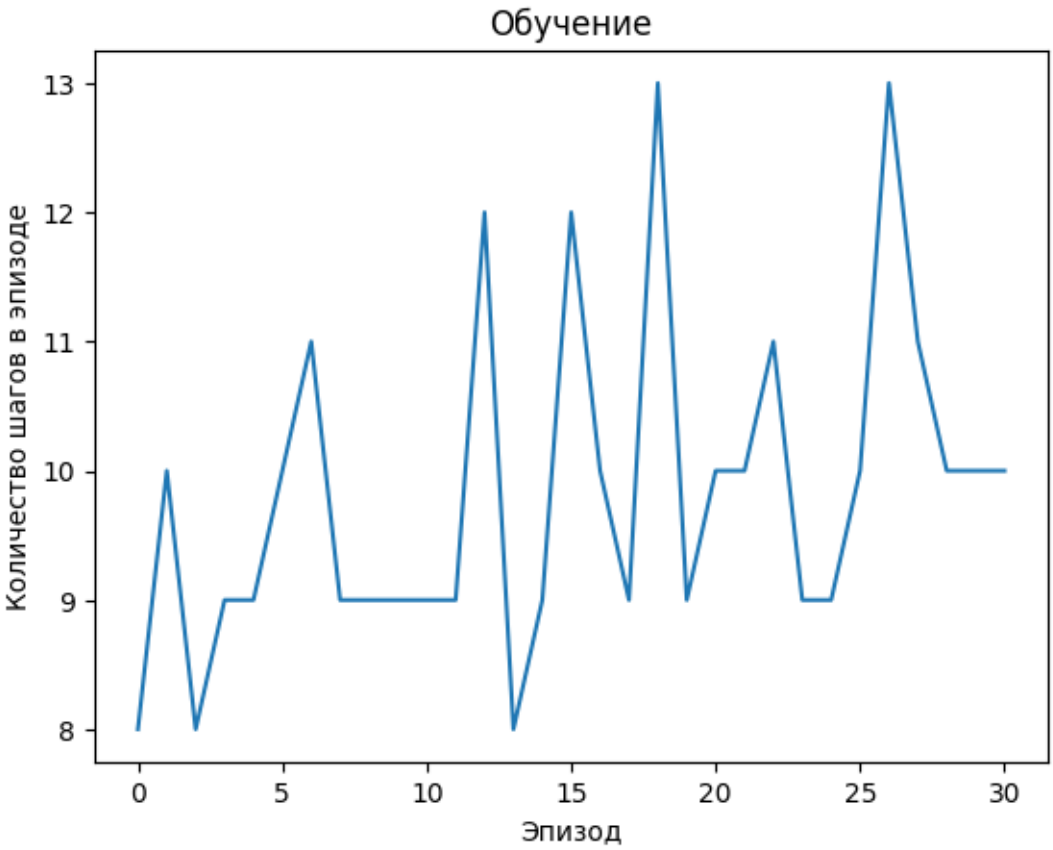
Обучение
Количество шагов в эпизоде
Эпизод
13
12
11
10
9
8
0
5
10
15
20
25
30

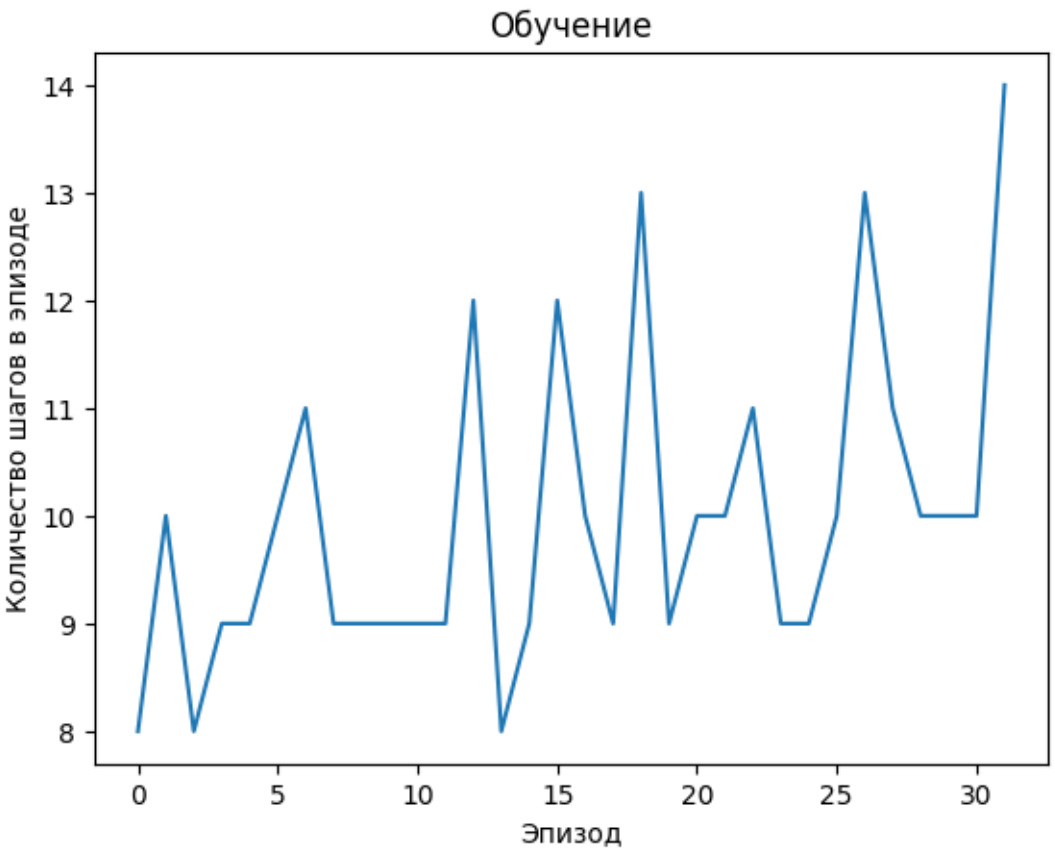
Обучение
Количество шагов в эпизоде
Эпизод
14
13
12
11
10
9
8
0
5
10
15
20
25
30

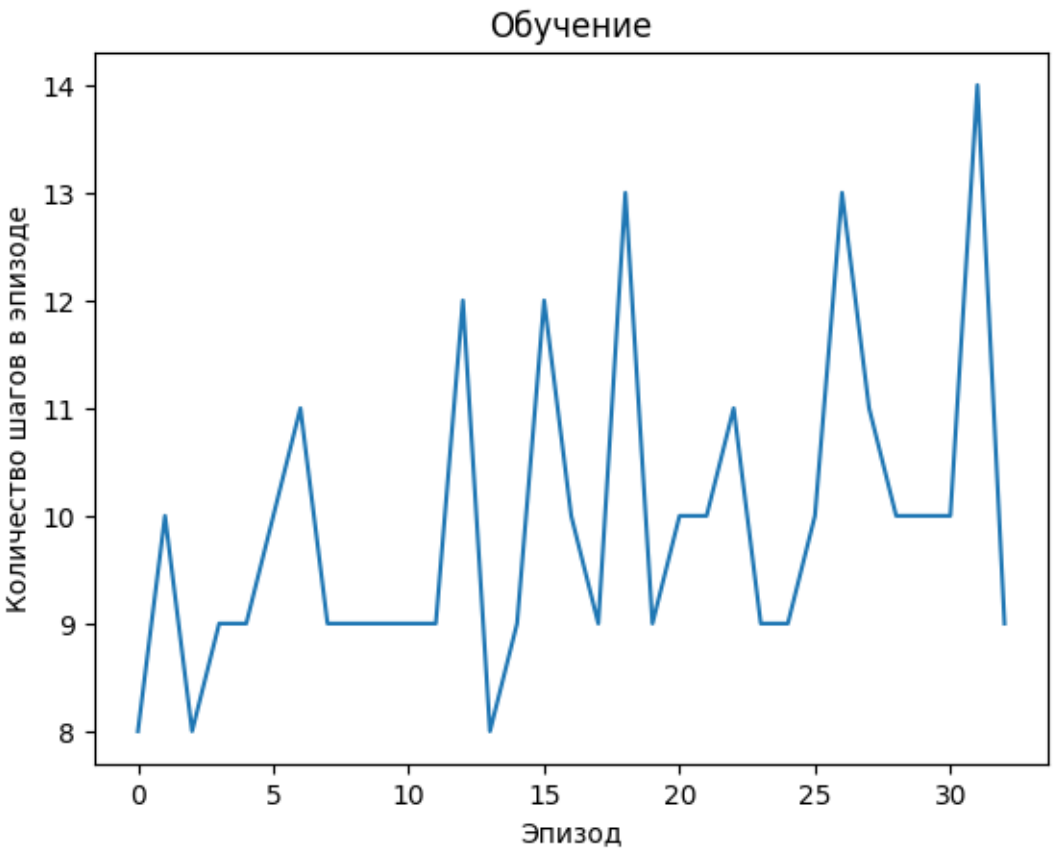
Обучение
Количество шагов в эпизоде
Эпизод
14
13
12
11
10
9
8
0
5
10
15
20
25
30

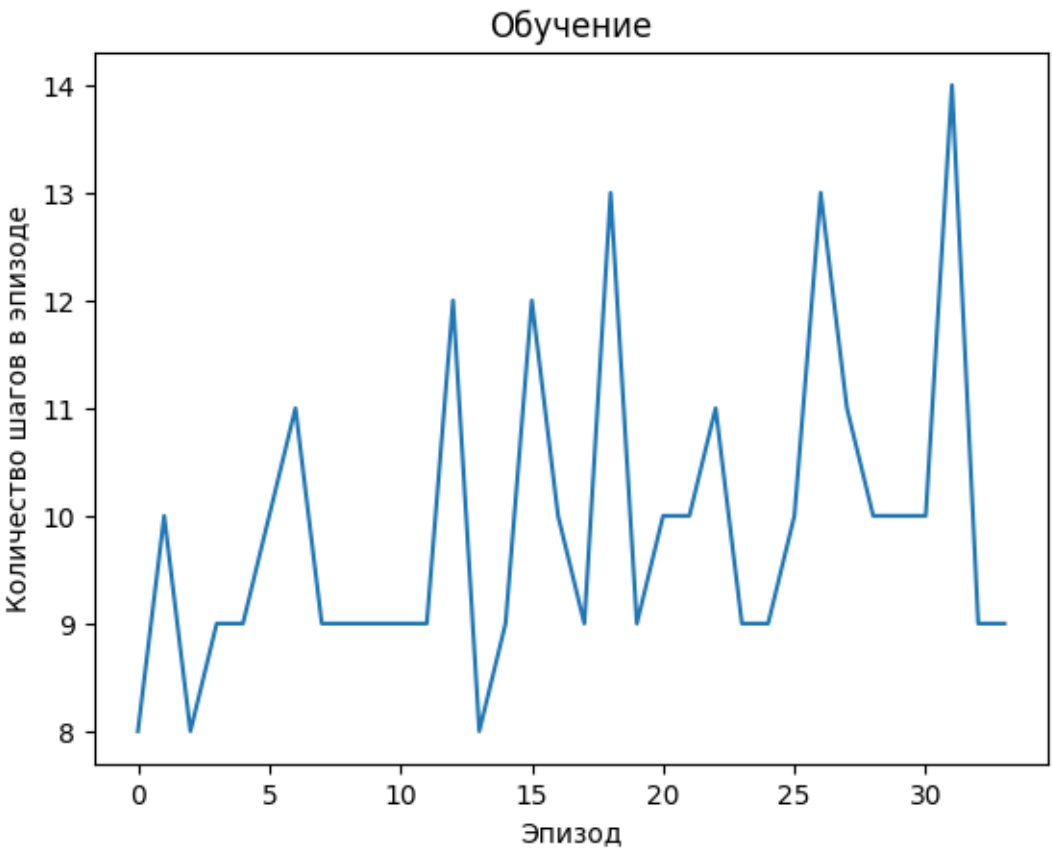
Обучение
Количество шагов в эпизоде
Эпизод
14
13
12
11
10
9
8
0
5
10
15
20
25
30

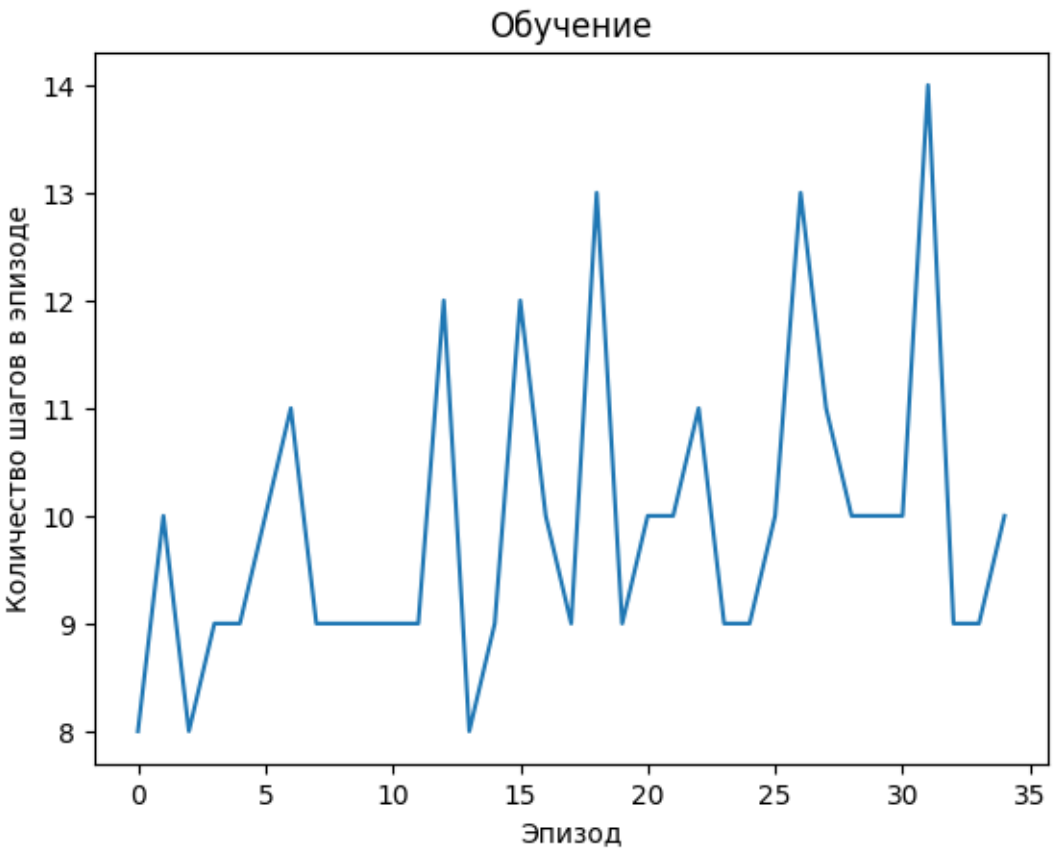
Обучение
Количество шагов в эпизоде
Эпизод
14
13
12
11
10
9
8
0
5
10
15
20
25
30
35

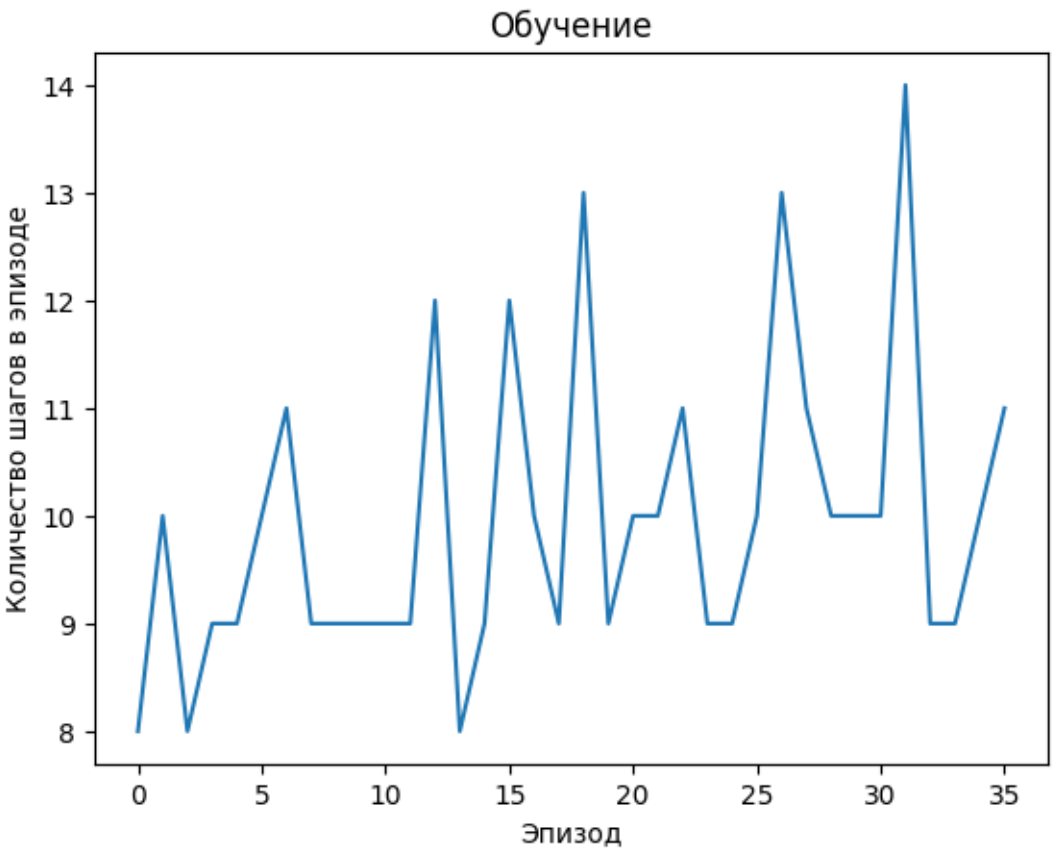
Обучение
Количество шагов в эпизоде
Эпизод
14
13
12
11
10
9
8
0
5
10
15
20
25
30
35

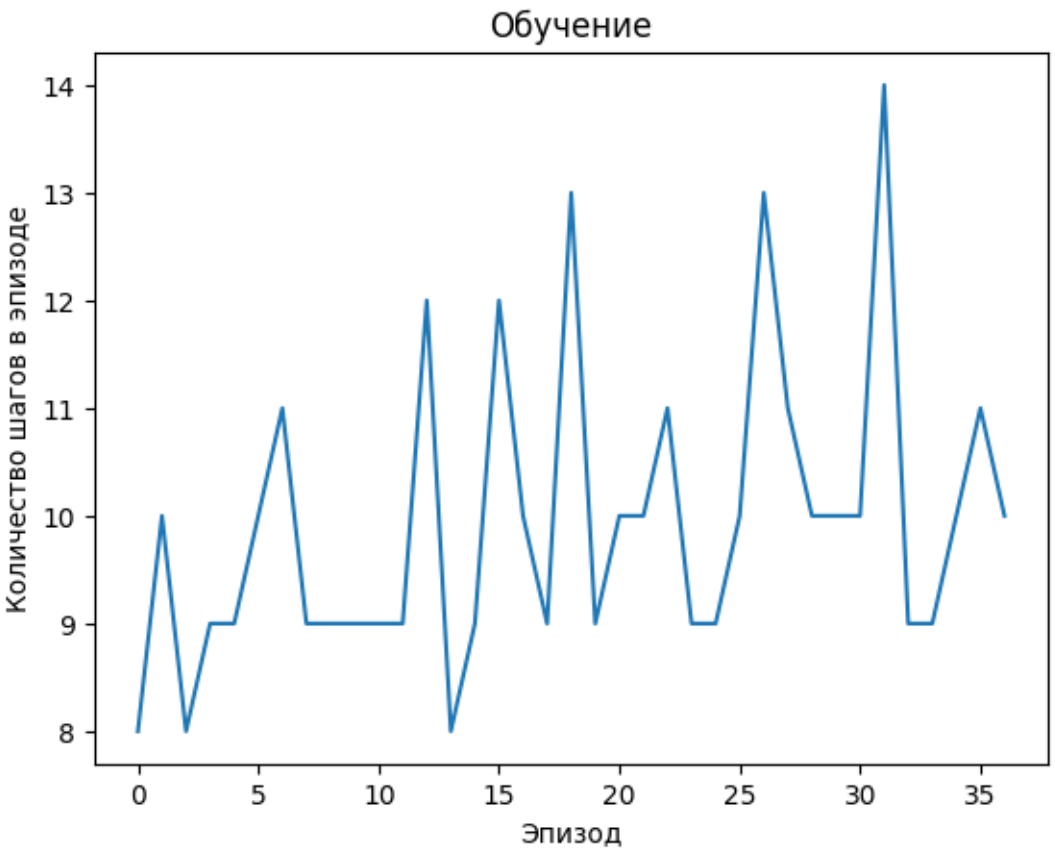
Обучение
Количество шагов в эпизоде
Эпизод
14
13
12
11
10
9
8
0
5
10
15
20
25
30
35

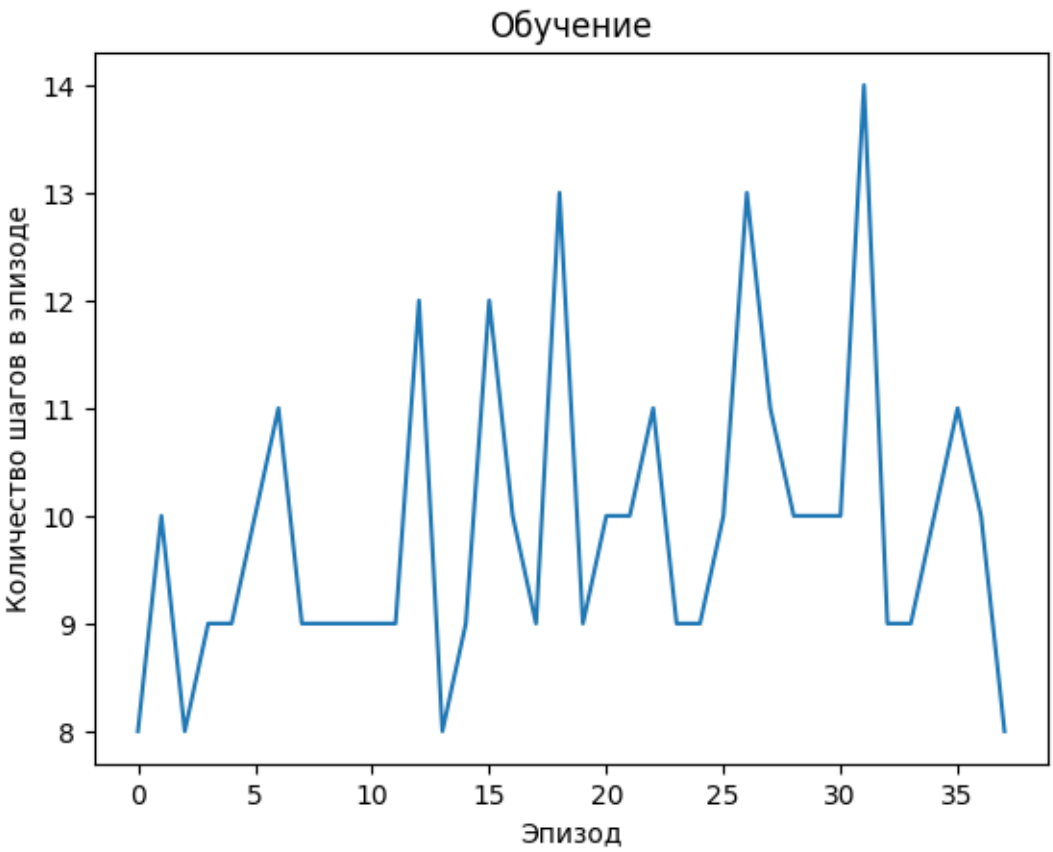
Обучение
Количество шагов в эпизоде
Эпизод
14
13
12
11
10
9
8
0
5
10
15
20
25
30
35

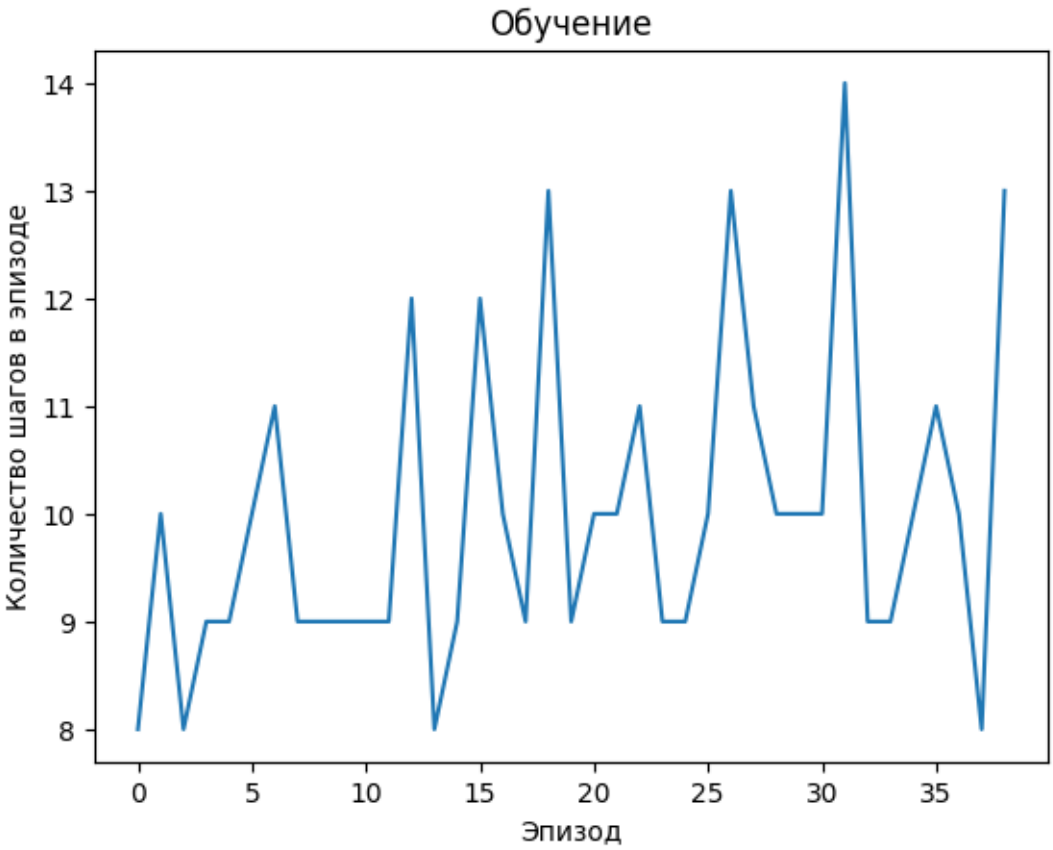
Обучение
Количество шагов в эпизоде
Эпизод
14
13
12
11
10
9
8
0
5
10
15
20
25
30
35

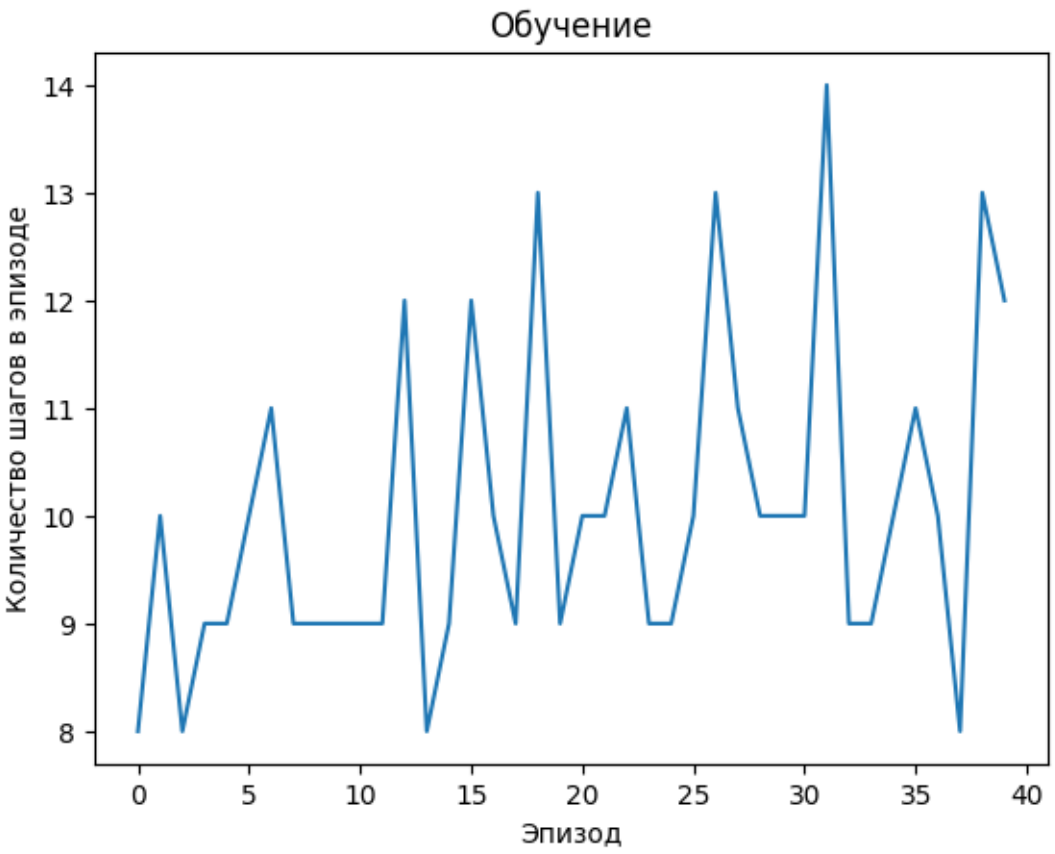
Обучение
Количество шагов в эпизоде
Эпизод
14
13
12
11
10
9
8
0
5
10
15
20
25
30
35
40

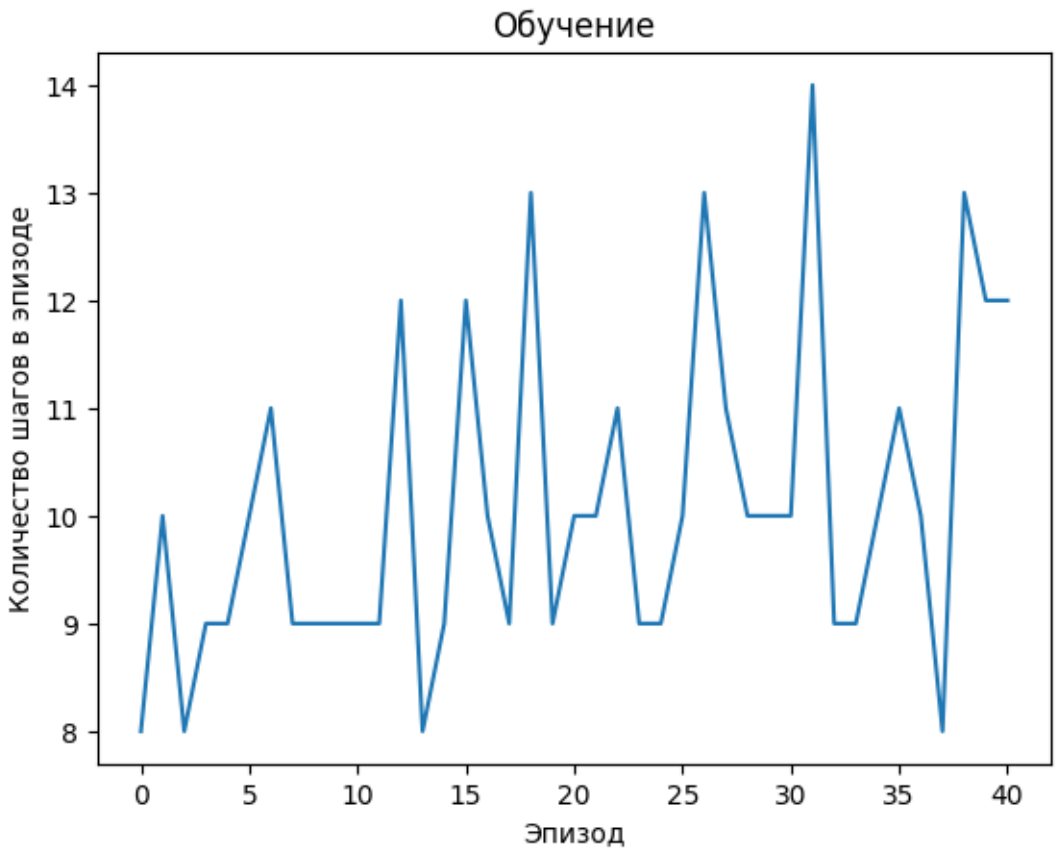
Обучение
Количество шагов в эпизоде
Эпизод
14
13
12
11
10
9
8
0
5
10
15
20
25
30
35
40

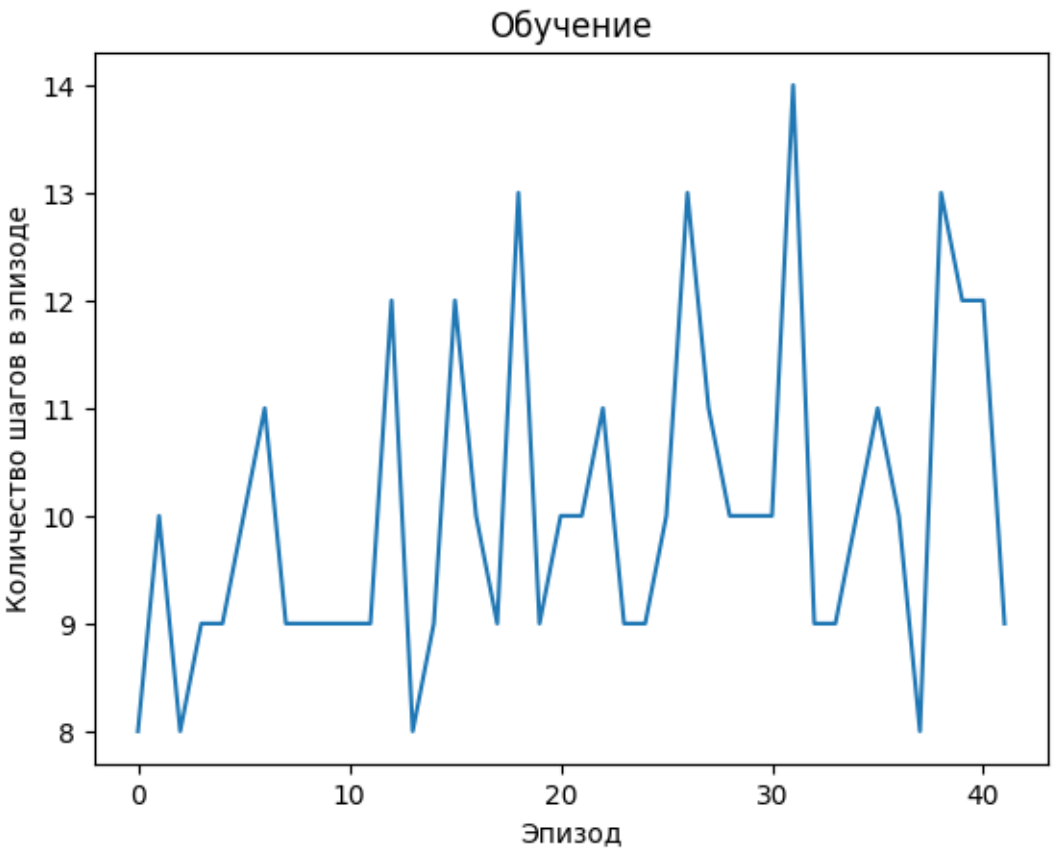
Обучение
Количество шагов в эпизоде
Эпизод
14
13
12
11
10
9
8
0
10
20
30
40

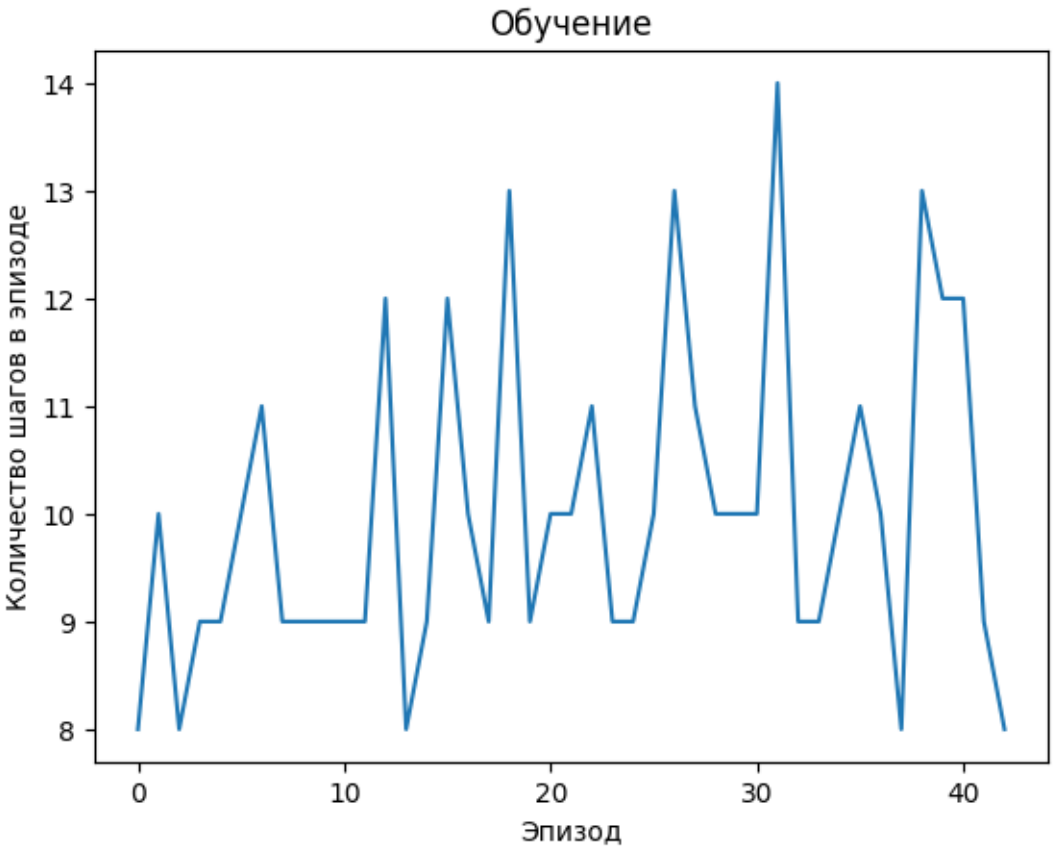
Обучение
Количество шагов в эпизоде
Эпизод
14
13
12
11
10
9
8
0
10
20
30
40

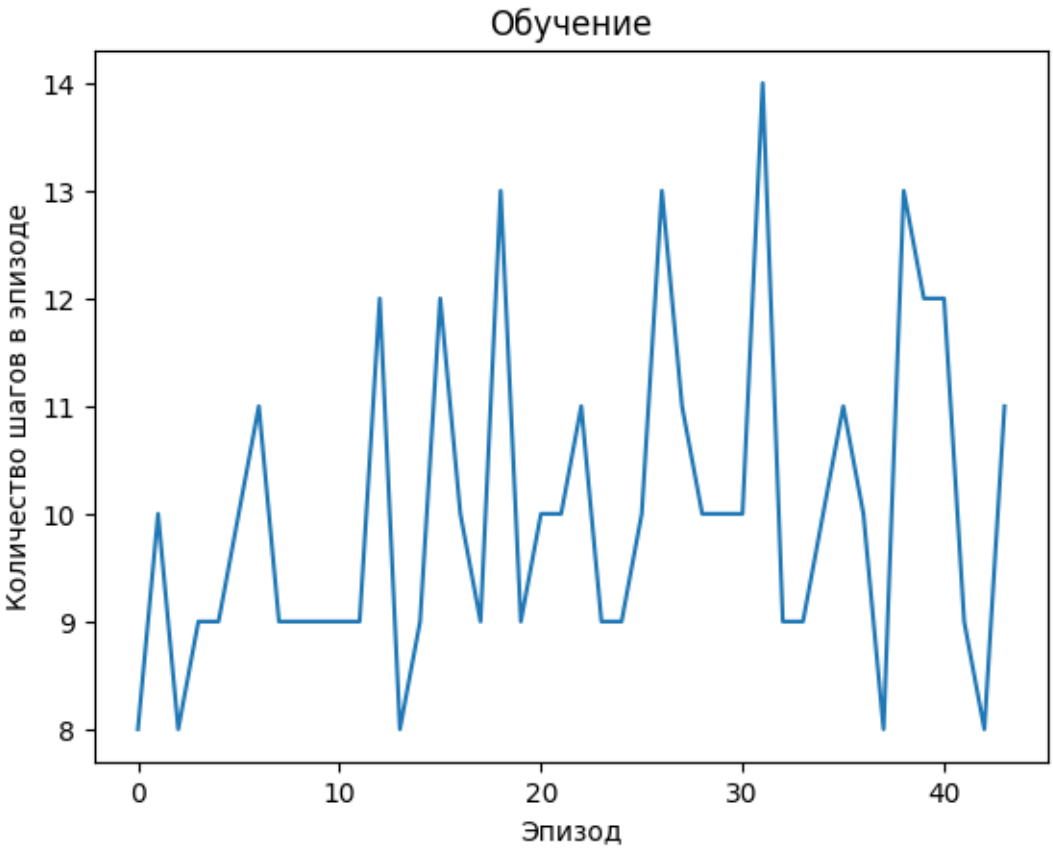
Обучение
Количество шагов в эпизоде
Эпизод
14
13
12
11
10
9
8
0
10
20
30
40

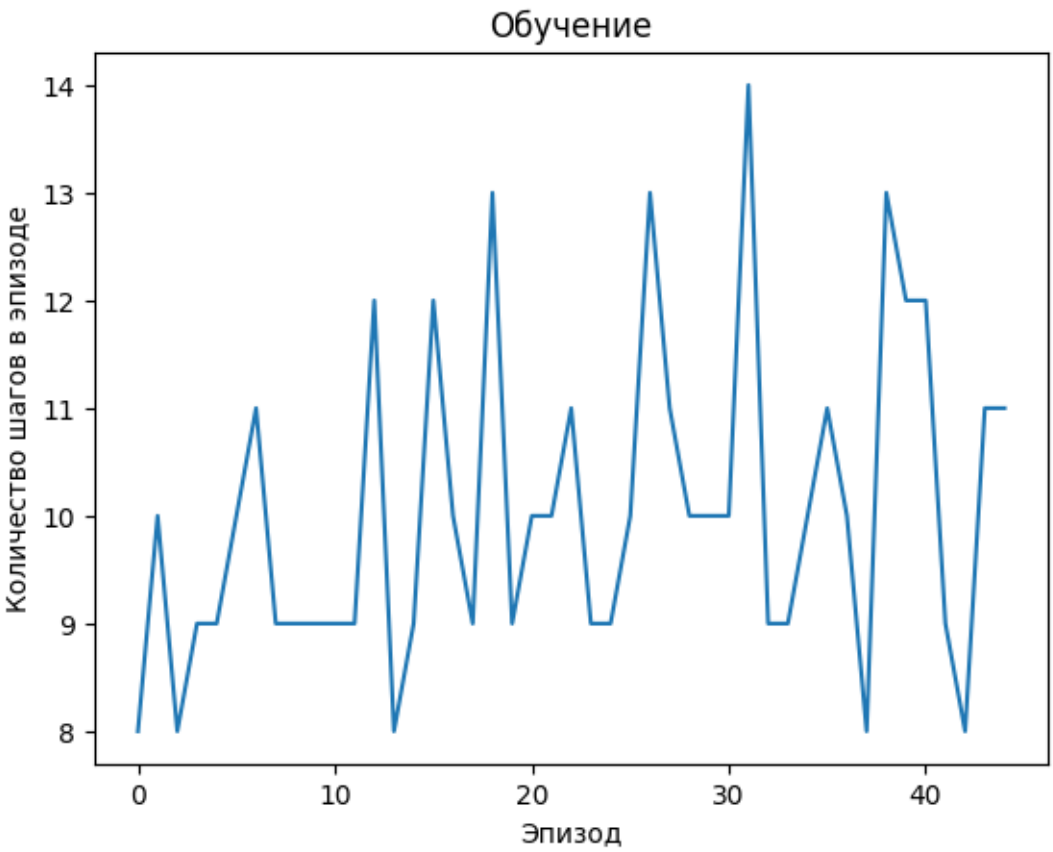
Обучение
Количество шагов в эпизоде
Эпизод
14
13
12
11
10
9
8
0
10
20
30
40

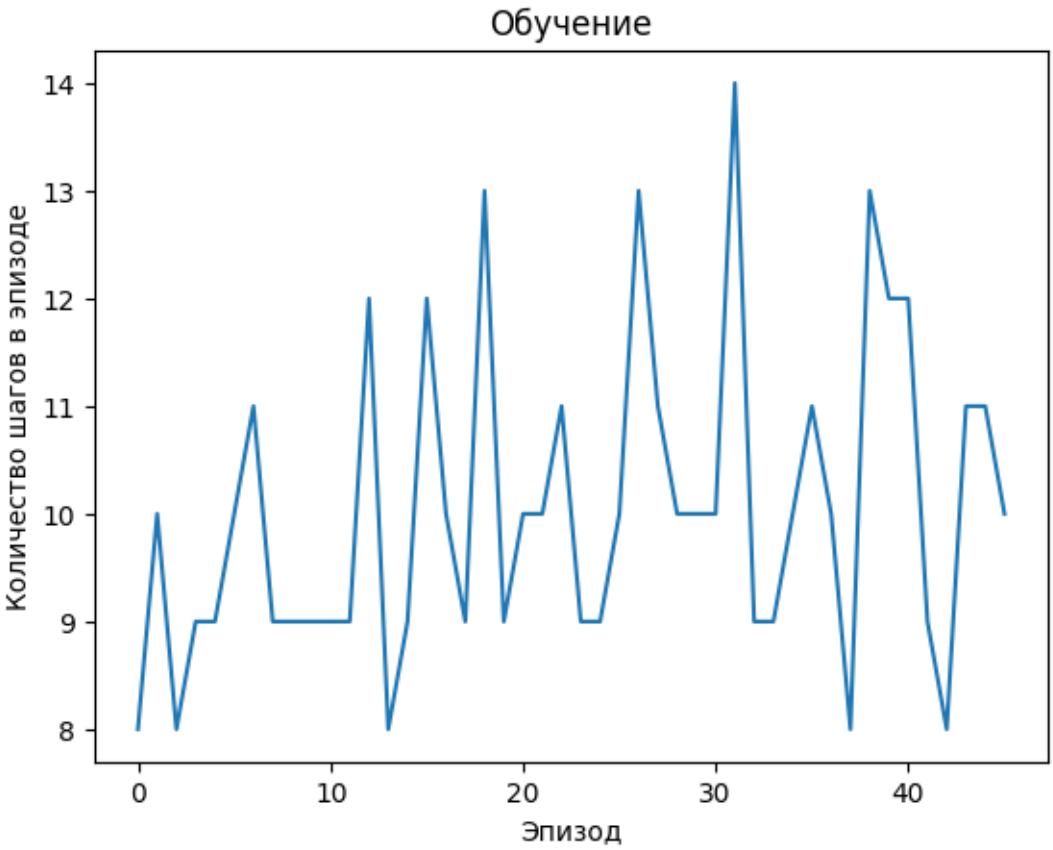
Обучение
Количество шагов в эпизоде
Эпизод
14
13
12
11
10
9
8
0
10
20
30
40

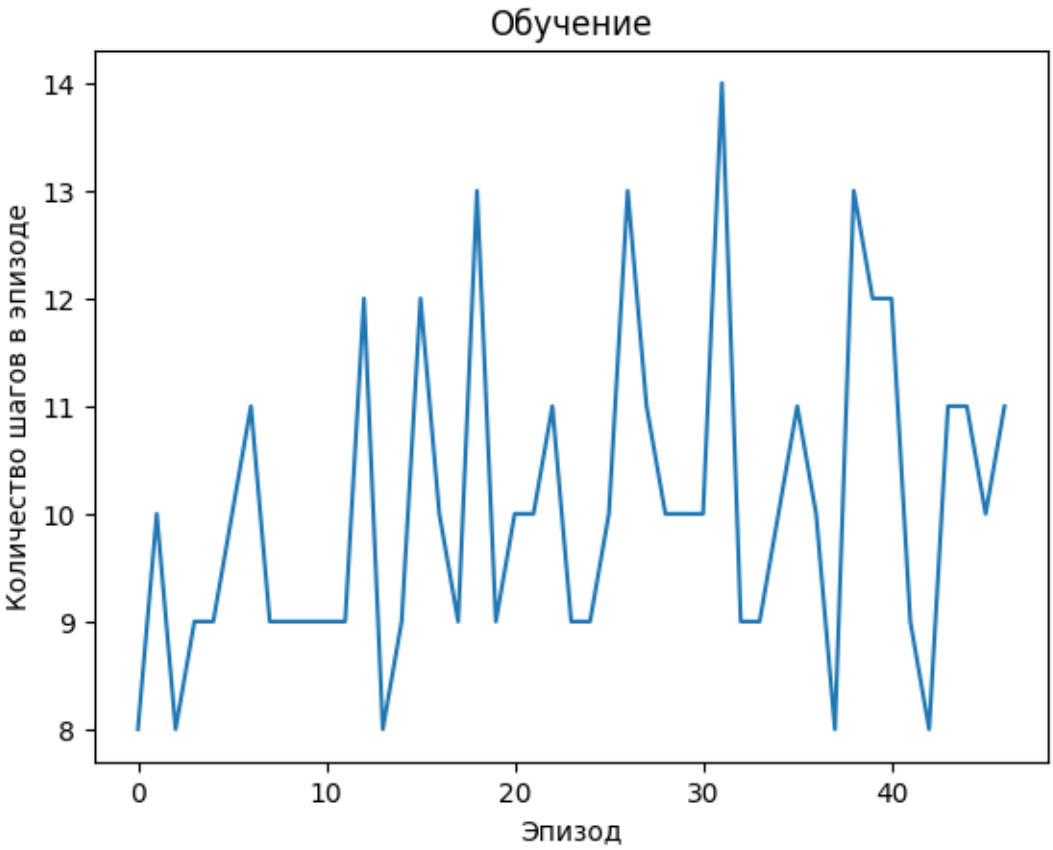
Обучение
Количество шагов в эпизоде
Эпизод
14
13
12
11
10
9
8
0
10
20
30
40

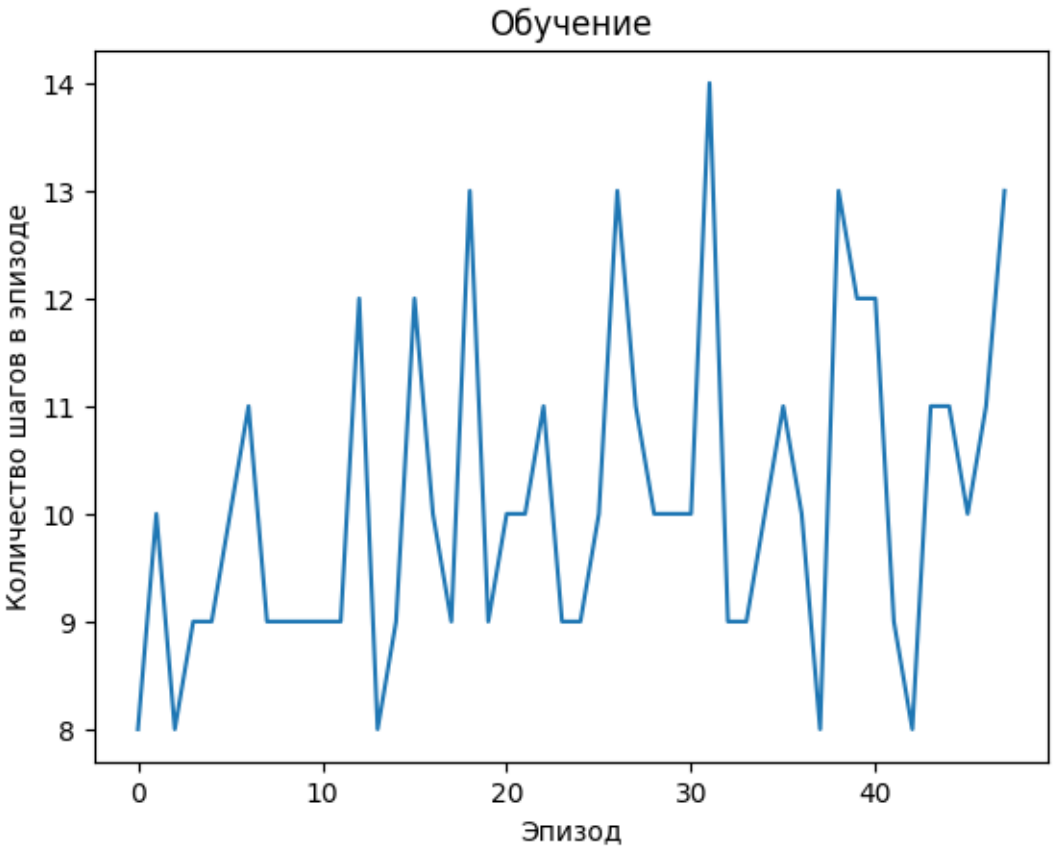
Обучение
Количество шагов в эпизоде
Эпизод
14
13
12
11
10
9
8
0
10
20
30
40

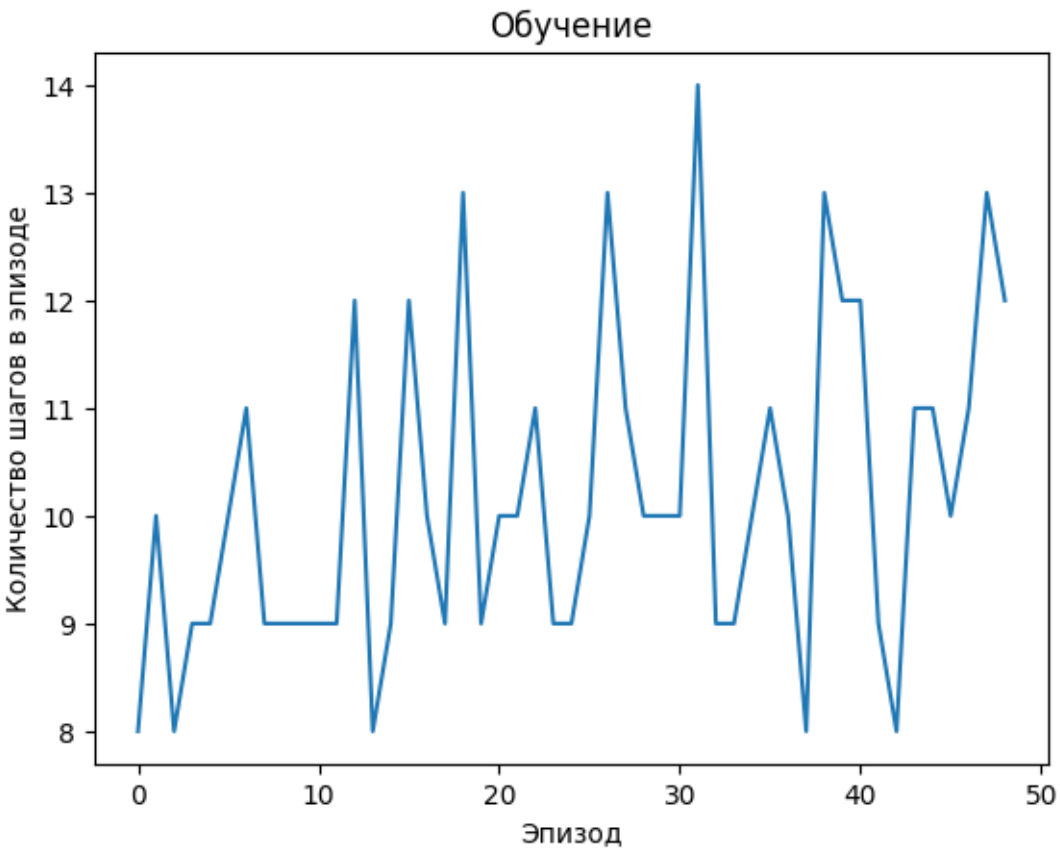
Обучение
Количество шагов в эпизоде
Эпизод
14
13
12
11
10
9
8
0
10
20
30
40
50

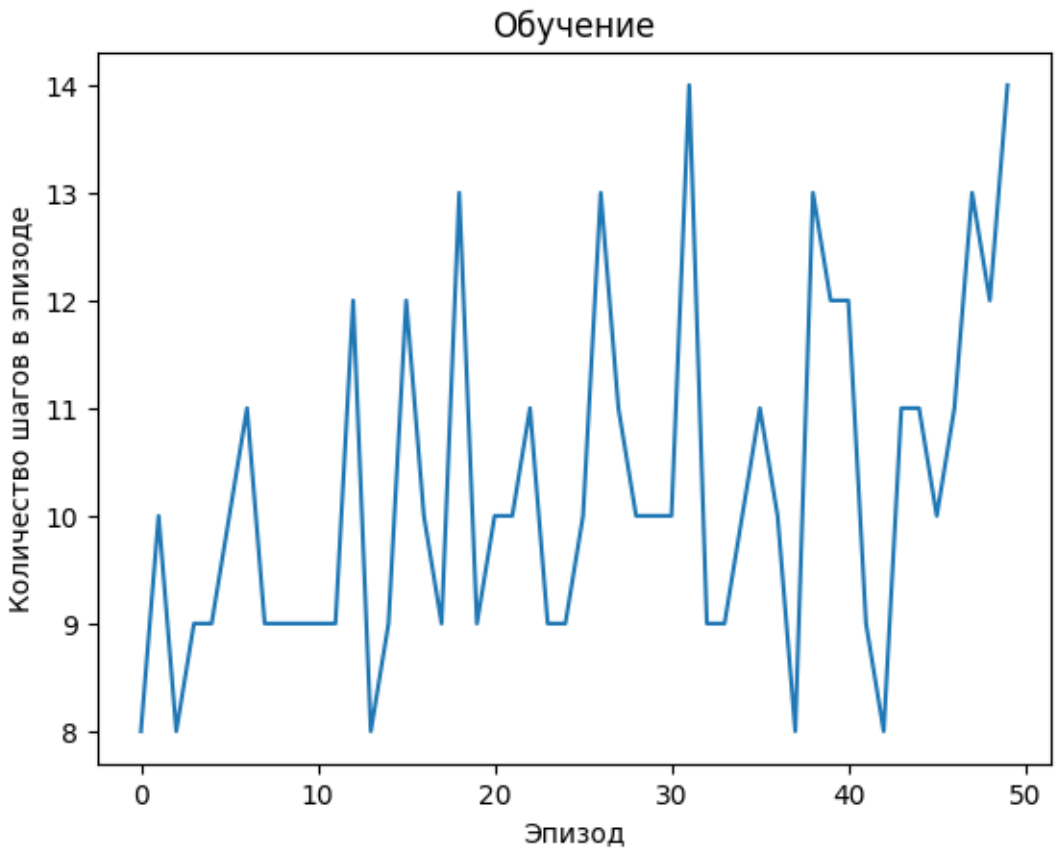


```
done!
          :  [(0, 1.0), (0, 1.0), (0, 1.0), (0, 1.0), (0, 1.0), (0, 1.0),
(1, 1.0), (1, 1.0), (0, 1.0), (0, 1.0), (0, 1.0), (0, 1.0)]
```